

UNIWERSYTET EKONOMICZNY W KATOWICACH

KIERUNEK INFORMATYKA

ADAM KOWALCZYK

147643

**ANALIZA WIELOWYMIAROWA CZYNNIKÓW
WPŁYWAJĄCYCH NA MIGRACJE WEWNĘTRZNE W
POLSCE Z WYKORZYSTANIEM METODY PCA ORAZ
MODELI REGRESJI**

**MULTIVARIATE ANALYSIS OF FACTORS
INFLUENCING INTERNAL MIGRATION IN POLAND USING PCA METHOD AND
REGRESSION MODELS**

Praca magisterska

Napisana pod kierunkiem

dr. hab. Dominika Krężółka, prof. UE

KATOWICE 2026

Oświadczenie o samodzielnym napisaniu pracy

Świadomy odpowiedzialności oświadczam, że złożona praca magisterska pt.: „Analiza wielowymiarowa czynników wpływających na migracje wewnętrzne w Polsce z wykorzystaniem metody PCA oraz modeli regresji” została napisana przeze mnie samodzielnie oraz że złożona wersja papierowa jest taka sama, jak wersja zamieszczona w systemie Archiwum Prac Dyplomowych DSW.

Równocześnie oświadczam, że praca ta nie narusza praw autorskich w rozumieniu ustawy z dnia 4 lutego 1994 roku o prawie autorskim i prawach pokrewnych (Dz. U. 1994, nr 24, poz. 83) oraz dóbr osobistych chronionych prawem cywilnym.

Ponadto praca nie zawiera informacji i danych uzyskanych w sposób nielegalny i nie była wcześniej przedmiotem innych procedur urzędowych związanych z uzyskaniem dyplomów lub tytułów zawodowych uczelni wyższej.

Adam Kowalczyk

Spis treści

Spis treści.....	3
Wstęp.....	4
1. Kontekst pracy.....	4
1.1. Cele pracy.....	6
1.2. Metodologia pracy.....	6
2. Migracje wewnętrzne i struktura demograficzna Polski.....	8
2.1. Istota i definicja migracji wewnętrznych.....	9
2.1.1. Trendy demograficzne migracji wewnętrznych w Polsce.....	11
2.2. Czynniki różnicujące strukturę ludności w Polsce.....	17
2.2.1. Czynniki demograficzne.....	18
2.2.2. Czynniki ekonomiczne.....	20
2.2.3. Czynniki społeczne.....	25
2.3. Konsekwencje migracji wewnętrznych.....	28
2.3.1. Korzyści dla regionów atrakcyjnych.....	28
2.3.2. Bariery rozwoju regionów peryferyjnych.....	30
3. Metodyka badań.....	31
3.1. Istota analizy regresji.....	31
3.2. Istota analizy redukcji wymiaru metodą PCA.....	39
4. Analiza głównych składowych i regresji dla województw w latach 2010-2024.....	43
4.1. Charakterystyka zmiennych badawczych.....	45
4.2. Analiza eksploracyjna danych.....	47
4.3. Analiza regresji przed redukcją wymiarów.....	56
4.4. Redukcja wymiarów metodą PCA i jej wpływ na regresję.....	67
4.5. Wnioski z przeprowadzonej analizy.....	79
Zakończenie.....	81
Literatura.....	83
Spis rysunków.....	86

Wstęp

Zjawisko migracji wewnętrznych stanowi jeden z najważniejszych procesów przestrzennych kształtujących współczesną strukturę demograficzną oraz społeczno-gospodarczą Polski. W obliczu narastających wyzwań, takich jak postępująca depopulacja, starzenie się społeczeństwa oraz pogłębiające się dysproporcje rozwojowe między centralnymi aglomeracjami a obszarami peryferyjnymi, konieczne jest zrozumienie mechanizmów decydujących o ruchu ludności. Głównym celem niniejszej pracy jest ilościowa ocena i identyfikacja czynników determinujących saldo migracji wewnętrznych w 16 polskich województwach w latach 2010–2024, z wykorzystaniem zaawansowanych technik uczenia maszynowego oraz metod redukcji wielowymiarowości. Praca składa się z trzech głównych rozdziałów, łączących aparat teoretyczny z badaniami empirycznymi. W pierwszym rozdziale nakreślony zostanie kontekst, cele i metodologia badań. Rozdział drugi stanowi przegląd literatury przedmiotu. Zdefiniowano w tej części ramy pojęciowe migracji wewnętrznych, nakreślono historyczne i współczesne trendy demograficzne, a także scharakteryzowano kluczowe determinanty ekonomiczne, demograficzne i społeczne różnicujące polskie regiony na obszary atrakcyjne oraz wyludniające się peryferie. Trzeci rozdział stanowi autorską część badawczą przeprowadzoną w środowisku Google Colab z wykorzystaniem języka Python. Obejmuje ona analizę eksploracyjną panelowego zbioru danych dla polskich województw, modelowanie regresyjne z użyciem czterech algorytmów takich jak regresja grzbietowa (z angielskiego „Ridge”), „SVR”, „Random Forest” i „Gradient Boosting” wraz z analizą wpływu redukcji wymiarów za pomocą klasycznej i jądrowej analizy składowych głównych na precyzję predykcji zmiennej docelowej.

1. Kontekst pracy

Istota występowania migracji oraz jej wpływ na kształtowanie się społeczeństwa staje się coraz powszechniej omawianą problematyką poruszaną w badaniach naukowych i debacie publicznej. Pomimo częstych dyskusji i badań na temat wpływu migracji zewnętrznych- zarówno na świecie jak i w Polsce w literaturze przedmiotu istnieje potrzeba kompleksowej analizy i rozważań na temat migracji

wewnętrznych w polskich realiach. Taka analiza będzie badała czynniki wpływające na przepływy ludności między regionami Polski. W regionach państwa zauważa się istniejące nierówności, które dzielą nasz kraj na „Polską A i Polską B”. Badanie te może pomóc w identyfikacji kluczowych wpływów na ten podział i pomóc w pogrupowaniu cech różnicujących zjawisko migracji w regionach na podstawie danych zebranych dla województw. Rozwój obszarów zabudowanych może być determinowany przez czynniki geograficzne, historyczne i kapitał ludzki. Niektóre regiony w Polsce są diametralnie zróżnicowane pod względem rozwinięcia. Jak donosi „Projekt Inwestor” w 2023 roku 53,8% PKB pochodziło z tylko 4 województw¹. W regionach najbardziej zamożnych średnia krajowa produktu krajowego brutto jest w wysokim stopniu przekraczana. W regionie warszawskim obserwuje się nadwyżkę wynoszącą nawet 201,2%. Zjawisko nierównomiernego rozwoju społecznego i gospodarczego terenów naszego kraju oraz postępująca depopulacja ludności z obszarów peryferyjnych stanowią istotne wyzwania dla polityki regionalnej Polski.

Charakter niniejszej pracy zostanie zaprezentowany w formie teoretyczno-praktycznej, wpięrow zbierając informacje na temat struktury demograficznej Polski skupiając się na charakterze wewnętrznych procesów migracyjnych a następnie przeprowadzeniu własnej analizy czynników wpływających na ich zdarzenia. Odbędzie się to za pomocą użytych metod statystyki wielowymiarowej. Badanie zostanie przeprowadzone na podstawie danych ze strony „Głównego Urzędu Statystycznego” dla wszystkich polskich województw na przestrzeni lat 2010-2025. Okres ten charakteryzuje się widocznymi przemianami demograficznymi, społecznymi i ekonomicznymi, które mogą wykazać jak zmieniały się zależności wobec poruszanego procesu migracji wewnętrznych. Już w latach XX, to właśnie te migracje znacząco wpłynęły na przyrost ludności w obszarach miejskich. Jak zauważa Andrzej Gawryszewski na podstawie danych statystycznych z GUS, „przyrost migracyjny górował w pięcioleciu powojennym... a przede wszystkim w ostatniej dekadzie stulecia”.² Migracje wewnętrzne stanowią istotny czynnik kształtujący strukturę demograficzną i społeczno-ekonomiczną regionów Polski. Będą one stanowić charakter zmiennej zależnej w modelach regresji budowanych na podstawie składowych głównych otrzymanych z zastosowania metody analizy

¹ Paweł Janukowicz, *Nierówności regionalne w Polsce – Polska A i B wciąż wyraźnie podzielone*, Projekt Inwestor, 6 Marzec, 2025

² Gawryszewski, A. *LUDNOŚĆ POLSKI W XX WIEKU*, str. 127, Instytut Geografii i Przestrzennego Zagospodarowania im. Stanisława Leszczyckiego PAN, Warszawa 2005

głównych składowych, która nie tylko będzie stanowić narzędzie do późniejszego zidentyfikowania czynników wpływających na ruch ludności w województwach poprzez analizę regresji, ale także zredukuje wielowymiarowość danych do najważniejszych składowych zmiennych wpływających na to zjawisko. Zmienne przyjęte do analizy PCA zostały pogrupowane na różne kategorie demograficzne, ekonomiczne i społeczne. Zostaną one zdefiniowane w nadchodzących rozdziałach, gdzie omówiony będzie ich dotychczasowy wpływ, charakter i tendencja rozwoju w województwach Polski biorąc pod uwagę kluczowe wydarzenia gospodarcze i społeczne- jak wprowadzanie charakterystycznych rządowych programów czy okres pandemii COVID-19.

1.1. Cele pracy

Do głównych celów pracy należą:

- Omówienie tematu migracji wewnętrznej występującej pomiędzy regionami Polski oraz zdefiniowanie czynników różnicujących strukturę ludności w Polsce.
- Przedstawienie metody PCA oraz modeli regresji i ich roli zastosowania w badaniach demograficznych i regionalnych.
- Przeprowadzenie analizy regresji grup czynników wpływających na wartość migracji wewnętrznych z saldem migracji wewnętrznych, jako zmienną zależną.
- Przeprowadzenie redukcji wymiarowości i jej analizy na zbiorze danych z okresu lat 2010-2024 dla wszystkich polskich województw.

1.2. Metodologia pracy

Aby zebrać informacje na badany temat, przeprowadzono studium przypadków składające się na różne rodzaje sposobów poboru wiadomości. W

nadchodzących rozdziałach omawiających teoretyczne fundamenty problemu migracji wewnętrznych, posłużono się literaturą naukową, aby zbadać istniejącą wiedzę i teorię związanych z tą problematyką. W pracy znajdują się odniesienia do artykułów internetowych, prac naukowych poruszających zbliżone merytorycznie tematy i innych odpowiednich sprawdzonych źródeł wiedzy. W pracy zostanie zdefiniowana sama istota występowania migracji wewnętrznych w Polsce i opisany trend zmian tego zjawiska na przestrzeni lat 2010-2025. W późniejszej części, opisane zostaną przedstawione grupy czynników najbardziej wpływających na migracje. Poruszone zostaną czynniki ekonomiczne, demograficzne oraz społeczne. Cechy, które należą do opisanych zestawów czynników, zostaną później również opisane i głębiej przedstawione w kontekście pracy w części praktycznej, gdzie zostanie opisany skomponowany zestaw danych, który będzie użyty w głównej analizie wielowymiarowej struktury demograficznej regionów Polski. Na koniec części teoretycznej zostaną opisane zarówno korzyści dla regionów, do których odbywa się największa liczba migracji jak i bariery rozwoju terenów peryferyjnych, które powodują konieczność opuszczenia obecnie zamieszkaanej lokacji. Następnie w rozdziale trzecim zdefiniowane zostaną głównie metody użyte w przeprowadzonej praktycznej części pracy. Opisana zostanie istota analizy regresji wraz z rozróżnieniem grup modeli regresyjnych i okolicznościami do ich zastosowania. Następnie nastąpi wprowadzenie do metody redukcji wymiaru poprzez pierwotne opisanie przyporządkowanym jej metodom oraz procedur badawczych.

Empiryczna część pracy w rozdziale czwartym rozpocznie się wprowadzeniem do problemu badawczego. Przedstawione zostanie źródło danych i zdefiniowane użytych cech badawczych oraz ich nakreślenie ich istotności w analizie. Rozpocznie się omówienie procesu realizacji badania poprzez wstępne przetwarzanie zebranych danych oraz przygotowanie ich do następujących analiz. Przedstawione zostaną statystyki opisowe, rozkłady zmiennych i macierz korelacji, które wstępnie wizualizują zróżnicowanie województw w czasie. Po eksploracji danych, przeprowadzona zostanie analiza regresji przed redukcją wymiarów dla pełnego okresu lat 2010-2024 gdzie nastąpi budowa czterech wybranych modeli regresji. Następnie po ocenieniu wyników modeli bazowych, rozpocznie się analiza PCA. Wpierw nastąpi określenie wyboru liczby głównych składowych. Interpretacja wyodrębnionych składowych pozwoli na identyfikację kluczowych wzorców różnicujących województwa oraz ich ewolucji w badanym okresie. Po zdefiniowaniu wyników cech po redukcji wymiaru,

nastąpi druga część analizy- porównanie modeli regresji, które zostały użyte, aby sprawdzić wpływ utworzonych grup cech w metodzie PCA na wynik regresji dla wskaźnika migracji wewnętrznych dla kolejnych województw w czasie. Zbadana zostanie siła i istotność statystyczna wpływu każdej składowej głównej na migracje, a także porównana zostanie moc wyjaśniająca modeli opartych na różnych grupach zmiennych. Na podstawie tych metod analitycznych, opisane zostaną wyniki a do ich dokładniejszej wizualizacji zostaną wygenerowane wykresy. Analizy statystyczne zostaną przeprowadzone z użyciem języka Python w środowisku Google Colab gdzie zostaną wspomniane wykorzystane biblioteki do manipulowania danymi, wykonywania obliczeń i przeprowadzania wizualizacji.

2. Migracje wewnętrzne i struktura demograficzna Polski

Migracje wewnętrzne stanowią główny przedmiot teoretycznych rozważań tej pracy. Stanowią one jedną z kluczowych zjawisk, które kształtują obecną strukturę ludności w Polsce. Jak zaznacza Alicja Dolińska dla samego województwa dolnośląskiego, od ponad dwóch dekad migracje poakcesyjne z obszarów słabych ekonomicznie mają znaczący wpływ na strukturę społeczną i potencjał rozwojowy dla wielu regionów zawartych w skład tego województwa. Jest to spowodowane głównie emigracją młodych ambitnych ludzi chcących kontynuować swoją edukację lub poszukiwać nowych perspektyw zawodowych. To jeden z powodów występowania tego problemu. Całe zjawisko to nabiera szczególnego znaczenia w kontekście wyzwań demograficznych, przed którymi stoi Polska takich jak „postępująca depopulacja, starzenie się ludności oraz pogłębiające się dysproporcje rozwojowe między centrum a peryferiami”.³ W niniejszym rozdziale, przedstawione zostaną kluczowe aspekty migracji wewnętrznych na terenie Polski. Od definicji tego terminu nastąpi analiza obserwowalnych zmian, jaki wywoływał na przestrzeni ostatnich lat. Opisane zostaną czynniki wpływające na same decyzje, które podejmuje ludność chcąc zmienić swoje dotychczasowe miejsce zamieszkania. Na końcu dokonana zostanie charakterystyka konsekwencji, jakie niesie zjawisko migracji pomiędzy

³ Dolińska, A. (2025). *Migracje poakcesyjne młodzieży z regionów peryferyjnych a wykształcenie rodziców – ryzyko utraty kapitału społeczno-gospodarczego. Dowody empiryczne z wybranych powiatów województwa dolnośląskiego*. W: A. Do-lińska, R. Jończy, J. Rokitowska-Malcher (red.), *Migracje Polaków w pierwszych deka-dach XXI wieku w kontekście przemian społeczno-gospodarczych*. Wybrane zagadnienia (str. 13-24). Wydawnictwo Uniwersytetu Ekonomicznego we Wrocławiu.

regionami terytorialnymi zarówno dla obszarów będących miejscami docelowymi emigrantów jak terenów peryferyjnych, dla których problemem jest odpływ tej ludności.

2.1. Istota i definicja migracji wewnętrznych

W przeciwieństwie do migracji zagranicznych, według definicji występującej na stronie „Głównego Urzędu Statystycznego”- w skrócie „GUS”, pojęcie migracji wewnętrznej można zrównać do zmiany pobytu stałego lub tymczasowego w obrębie kraju, polegającym na przekroczeniu granicy administracyjnej gminy lub zmiany miejsca zamieszkania w obrębie gminy.⁴ Dla metodologii stosowanej przez „Główny Urząd Statystyczny”, czas przemieszczenia osób obejmuje minimum 3 miesiące. Dzięki tej restrykcji, migracje wewnętrzne są odróżnione od krótkotrwałych pobytów w celach zawodowych lub rekreacyjnych. Przemieszczenia terytorialne na dłuższe okresy czasu dla województw, są wyróżnione na 4 grupy. Wyróżnia się migracje międzywojewódzkie obejmujące przemieszczenia się ludności z jednego województwa do innego i migracje wewnątrzwojewódzkie dotyczące zmianę miejsca zamieszkania w tym samym województwie. Oprócz dwóch wcześniej wymienionych, wyróżnia się również migracje międzypowiatowe i wewnątrzpowiatowe z taką samą analogią. Podział ten odzwierciedla różną skalę w przestrzeni procesów migracyjnych oraz ich zróżnicowane czynniki i konsekwencje.

Migracje wewnętrzne można również klasyfikować względem kierunku przepływu odpływu ludności- pod względem rozwinięcia administracyjnego obszarów wyróżnia się kierunki migracji ze wsi do miasta, z miasta na wieś oraz z miasta do innego miasta lub ze wsi do innej wsi. Warto zaznaczyć, że pomimo popularniejszego rozległego ruchu obywateli z miejsc mniej rozwiniętych do większych miast na przestrzeni lat to rok 2000, jako pierwszy zaznaczył się ujemnym saldem migracji dla miast. Obserwuje się coraz większy napływ ludności do stref podmiejskich z dużych ośrodków miejskich.⁵ Zjawisko to można nazwać migracją rezydencjalną- zmianą miejsca zamieszkania w celu poprawienia warunków życia. Jedną z obserwacji dotyczącej kierunku i czasu pobytu przemieszczenia jest

⁴ Główny Urząd Statystyczny. (2026) *Pojęcia stosowane w statystyce publicznej. Migracje wewnętrzne.*

⁵ Fuhrmann M. Ruszczyk A. *Kierunki i przyczyny migracji zagranicznych i wewnętrznych Polaków. Zmiany salda migracji zagranicznych i wewnętrznych Polaków i ich przyczyny.* 2020

zależność wieku osoby opuszczającej swoją obecną lokację mieszkaniową. Jak wcześniej wspomniano, osoby w wieku 20-29 przemieszczają się częściej z wsi i mniejszych miast do bardziej atrakcyjnych pod względem rozwoju dużych miast- do największych należą Warszawa, Kraków, Wrocław, Gdańsk oraz Poznań. Z kolei wśród osób w wieku 35-45 lat, występuje sytuacja odwrotna. Obywatele w tej granicy wieku, po ustabilizowaniu finansowym, spełnieniu osobistym i często już po założeniu rodziny, decydują się na emigrację na wsie lub skrajne dzielnice miast zwane suburbią, aby zamieszkać w swoim zbudowanym domu doceniając swoją niezależność i bezpieczeństwo.

Aby przeanalizować wpływ migracji w kraju, w badaniach statystycznych do pomiaru ich poziomu zastosowano podstawowe miary. Saldo migracji to różnica między napływem a odpływem ludności. Miara ta może przyjmować wartości dodatnie (przyrost wędrowniczy) lub ujemne (ubytek wędrowniczy).⁶ Wyróżnia się także obrót migracyjny będący sumą napływu i odpływu oraz współczynniki natężenia migracji, które najczęściej tak jak w na stronie „GUS”, wyrażone są na 1000 mieszkańców miasta lub wsi. Miary te często wykorzystuje się w badaniach dynamiki ludności danego obszaru. Saldo migracji stanowi jeden z kluczowych wskaźników atrakcyjności danego regionu- jego dodatnie wartości świadczą o korzystnych warunkach ekonomicznych i społecznych.

Migracje wewnętrzne wynikają z racjonalnych podjętych decyzji obywateli często w oparciu o analizę kosztów i ich korzyści ze zmiany miejsca zamieszkania. Jako klasyczną teorię migracji, przytoczyć można teorię „push-pull” pierwotnie sformułowaną przez Everetta Lee. Zakłada ona istnienie czynników „wypychających”, na które się składa miejsce pochodzenia oraz czynników „przyciągających” związanych z celem emigracji.⁷ Oprócz tego wymienia także przeszkody pośrednie i czynniki osobiste. Teoria ta jest uzasadniona subiektywnym charakterem tych decyzji, które często zależą od cech osobistych. Jednakże migracje występujące w Polsce nie są wynikiem tylko indywidualnych decyzji, ale również wyrazem panujących nierówności regionalnych, na które pojedyncze jednostki nie mają wpływu.

⁶ Sojka E. *Statystyka w praktyce. Odległość geograficzna jako determinanta migracji — na przykładzie województwa śląskiego*. 2017

⁷ Górny A, Kaczmarczyk P. *Uwarunkowania i mechanizmy migracji zarobkowych w świetle wybranych koncepcji teoretycznych* str. 40. Listopad 2003

2.1.1. Trendy demograficzne migracji wewnętrznych w Polsce

Na przestrzeni lat Polski zaszło wiele przemian gospodarczych i społecznych, które wpłynęły na ukształtowanie się zmiennych trendów dla procesów migracyjnych. Dla lepszego punktu odniesienia wobec lat 2010-2025, których dane demograficzne, społeczne i ekonomiczne zostaną głębiej poddane analizie w praktycznej części badania, w pierwszej kolejności należy uwzględnić kontekst historyczny dla przemian liczby ludności z powodów migracji wewnętrznych w XX wieku. Po zakończeniu II wojny światowej doszło do zmian ukształtowania granic Polski. Skutkiem tych wdrożonych zmian było nastąpienie fal migracyjnych. W latach 1944-1946 doszło do pierwszej repatriacji- powrotu Polaków z terenów, które były zajęte przez najeźdźców ze Związku Radzieckiego.⁸ Ludzie ci głównie osiedlili się na odzyskanych ziemiach- Dolnym Śląsku, Pomorzu czy Warmii i Mazurach. Zaznaczyć można także, że w tym czasie z Polski została przesiedlona ludność ukraińska do ZSRR. Po 1946 roku nastąpiło znaczące nasilenie migracji wewnętrznych- ludność podróżowała z wsi, które były przeludnione do rozwijających się przemysłowo miast. Jak zaznacza Karolina Lewandowska-Gwarda i Elżbieta Antczak w artykule poświęconym migracji wewnętrznym w polskich miastach, to zjawisko doprowadziło do zwiększenia się odsetka mieszkańców miast z 37% do 56%.⁹ Druga fala przeludnień ziem odzyskanych nastąpiła w latach 1955- 1959. Objęła ona 250 tysięcy Polaków przesiedlonych ze Związki Radzieckiego. Podczas tego czasu, następował ciągły wzrost współczynnika urbanizacji aż do 62%. Zobrazowane przesiedlenia Polaków po drugiej wojnie światowej obrazuje rysunek 1, który obejmuje kierunki migracji wewnętrznych i zewnętrznych ludności polskiej, ukraińskiej, niemieckiej i żydowskiej.

⁸ Rudnicki J. Wierchowski M. Dardzińska J. Instytut Pamięci Narodowej we Wrocławiu. *Ekspatriacje z Kresów Wschodnich 1944-1959*. Maj 2021.

⁹ Lewandowska-Gwarda K. Antczak E. *Migracje wewnętrzne w polskich miastach – analiza z wykorzystaniem przestrzennej dynamicznej metody przesunięć udziałów*. str 2. 2015




Rysunek 1 Mapa kierunków migracji po II wojnie światowej w Polsce.

Źródło: Zintegrowana Platforma Edukacyjna. *Między propagandą a rzeczywistością. W PRL.*
<https://zpe.gov.pl/a/miedzy-propaganda-a-rzeczywistoscia-w-prl/DDAtcheAR>

Kierunek migracji ze wsi do miast kontynuował w znaczącym tempie aż do lat 90 XX wieku. Po upadku systemu komunistycznego w Polsce, zniknęły blokady dotyczące ograniczeń migracji za granicę, co przyczyniło się do migracji ekonomicznych- przepływu ludności motywowanymi chęcią poprawy sytuacji materialnej. Jak obrazuje rysunek 2, tendencja napływu do miast zaczęła przyjmować pomniejszający się trend na początku lat osiemdziesiątych. Podobna tendencja była obserwowalna dla migracji na tereny wiejskie, lecz z mniejszym spadkiem. Lata dziewięćdziesiąte charakteryzują się rozpoczęciem w Polsce depresji demograficznej. Jest to długotrwały kryzys, który polega na systematycznym spadku liczby urodzeń i starzenia się społeczeństwa. Od roku 1989, reprodukcja w naszym kraju nie gwarantuje prostego procesu zastępowalności pokoleń. Doprowadza to do późniejszych skutków, w których zauważalny jest spadek liczby ludności od 1999 roku.¹⁰

¹⁰ Główny Urząd Statystyczny. *Migracje długookresowe ludności w latach 1989-2002- na podstawie ankiety migracyjnej 2002.* Warszawa. Grudzień. 2004



Rysunek 2 Tendencja migracji wewnętrznych na pobyt stały w latach 1974- 1998.

Źródło: GUS. *Migracje wewnętrzne ludności na pobyt stały według województw w latach 1974-2024*.
<https://stat.gov.pl/obszary-tematyczne/ludnosc/migracje-wewnetrzne-ludnosci/migracje-wewnetrzne-ludnosci-na-pobyt-staly-wedlug-wojewodztw-w-latach-1974-2024,3,1.html>


Jak wspomniano w rozdziale „2.1.” w celu wskazania na zmienny kierunek migracji wewnętrznych, rok 2000 stanowi punkt zwrotny w historii migracji na terenach Polski z uwagi na ujemny wskaźnik salda migracji dla miast. Jako zmianę społeczną zaznaczyć należy, że w 1999 roku nastąpiła reforma szkolnictwa wprowadzająca podział na szkołę podstawową, gimnazjum i liceum. Dzięki badaniu „Głównego Urzędu Statystycznego” dotyczącego migracji z lat 1989-2002, dowiedzieć się można ciekawych zależności. Po pierwsze, że większość migrantów dla tego czasu stanowiły kobiety. Większość ankietowanych- 98% z 3 439 tys. migrantów zmieniła miejsce zamieszkania w granicach naszego kraju. Większość migracji była długoterminowych- na okres dłuższy niż 12 miesięcy. Dla długookresowych migracji wewnętrznych, dla badanych lat dominującym kierunkiem był przepływ ludności z miast do innych miast. Przeważały migracje wewnętrzne w obrębie tego samego województwa, w którym do tej pory mieszkała ludność. Wewnątrzwojewódzkie migracje były najczęściej przeprowadzane w województwie podkarpackim. Istotnym wnioskiem z tej analizy jest jednak fakt, że pobyt na mniejszy okres czasu wiązał się z przemieszczeniem na większą odległość- najczęściej do innych województw. Zmiana pobytu stałego wiązała się z mniejszym dystansem i głównie miała miejsce w tym samym województwie. Do najważniejszych przyczyn migracji należały sprawy rodzinne. Do kolejnych należała zmiana miejsca pracy, zmiana warunków mieszkaniowych czy lepsza możliwość zdobycia wykształcenia. Jak wcześniej

wskazano, okres po 2000 roku rozpoczął powiększanie się ubocznych miejsc zamieszkania miast- suburbiów. Wspomnieć należy także, że w przypadku migracji zewnętrznych, wejście Polski do Unii Europejskiej w 2004 roku otworzyło kolejną możliwość wystąpienia migracji ekonomicznych do krajów lepiej rozwiniętych.


Proces suburbanizacji dokonywał stabilizacji w latach 2010-2015. Kontynuowana była tendencja rozpoczęta w poprzednim dziesięcioleciu- następowała dominacja odpływu ludności z miast nad ich przyływem do miast oraz dominacja przyływu ludności na wieś nad odpływem mieszkańców wsi. Obrazują to wykresy na rysunku 3 i 4. W tym okresie czasu uformowały się dominujące obszary zurbanizowane, które były liderami pod względem dodatnich wartości salda migracji. Największym z nich było województwo mazowieckie, dla którego saldo migracji oscylowało w liczbach 10-15 tysięcy aż do 2021 roku. Kształtowała się też niezmienna do dziś tendencja województw z dodatnim jak i ujemnym saldem migracji. Województwa pomorskie, wielkopolskie, małopolskie i dolnośląskie są pozostałymi obszarami o dodatnim saldzie migracji, podczas gdy reszta województw charakteryzuje się ujemnym saldem migracji. Od rozpoczęcia ostatniego dwudziestolecia, zdaniem Józefiny Hryniewicz, Janusza Witkowskiego i Aliny Potrykowskiej w „Migracje a sytuacja demograficzna Polski” wzmaganie się migracji wewnętrznych spowodowane zostało przez masową ekspansję szkolnictwa wyższego oraz przerwania harmonizacji procesu rozwoju regionalnego i lokalnego.¹¹ Do dzisiaj migracje wewnętrzne charakteryzuje przepływ ludności do dużych miejsc regionalnych i akademickich, wraz z ekspansją obszarów zamieszkania na obrzeżach. Przyczyny migracji pozostają niezmiennie jak z ankietowanymi w poprzednim akapicie.

Z powodu wyludniającej się tendencji Polski, w 2016 wprowadzony program „Rodzina 500+” miał na celu zwiększenie przyrostu naturalnego w kraju.

¹¹ Hryniewicz J. Witkowski J. Potrykowska A. *Migracje a sytuacja demograficzna Polski*. Warszawa 2019



Rysunek 3 Tendencja migracji w miastach na pobyt stały w latach 1988-2024. Źródło: GUS. Migracje wewnętrzne ludności na pobyt stały według województw w latach 1974-2024.



Rysunek 4 Tendencja migracji na wsiach na pobyt stały w latach 1988-2024. Źródło: GUS. Migracje wewnętrzne ludności na pobyt stały według województw w latach 1974-2024.

Niestety wpływ tego programu nie był znaczący. Od tego czasu zwiększa się poziom migracji zagranicznych, który jest spowodowany problemami z niewystarczającą obecnością miejsc pracy oraz obszarów zamieszkania. Zauważalna jest tendencja dominowania województw z niskim saldem migracji przez osoby w starszym wieku. Pomimo ciągłego istnienia migracji wewnętrznych, poziom przyjazdu ludzi młodych na przykład do województwa pomorskiego, nie jest zadowalający.¹² Kontynuowana jest tendencja migracji do miast ludzi w granicy wieku 20-29 i migracji na wieś obywateli w granicach wieku 35-45. Rok 2020 wyróżnia się na przestrzeni czasu wybuchem pandemii covid-19. Ograniczony został ruch graniczny a w kraju został wprowadzony stan epidemii z ograniczeniem kontaktów międzyludzkich. Ważnym


¹² Netka K. Netka.gda.pl *Polska się wyludnia. Staje się krajem starców. Po wprowadzeniu Programu 500+ nieco wzrosła liczba narodzin ale to za mało. Potrzebne są kolejne przedsięwzięcia, by dobrze wykształconych ludzi zatrzymać w swej ojczyźnie. Najlepiej jest w Pomorskiem, ale...* 19 czerwiec 2017

trendem była w wyniku opcja pracy i nauczania zdalnego, które umożliwiły rozwój i aktywność z dowolnego miasta bez możliwości transportu osobistego. Saldo migracji wewnętrznych spadło w całym kraju w miastach. Zaczęło jednak ono wzrastać na wsiach jak obrazują wykresy na rysunkach 3 i 4. Wartość salda migracji w 2020 roku obrazuje też mapa przedstawiona na rysunku 5. Tendencje salda migracji w dużych miastach województw o dodatnim saldzie migracji i mniej rozwiniętych obszarach pozostała utrzymała się na wcześniej panującej tendencji nawet w tym czasie. Można wywnioskować, że krótkotrwałe ograniczenie naturalnego porządku podczas pandemii w niewielkim stopniu wpłynęła na obecne trendy migracji wewnętrznej. Zauważyć można było, lecz spadek ilości Polaków za granicą naszego kraju.¹³

Do 2025 roku, zauważalny jest odpływ ludności z miast- najczęściej o średniej powierzchni do gmin- najczęściej graniczących z nimi bezpośrednio. Saldo migracji na wsiach pozostaje dodatnie. Według prognoz, na terenach odzyskanych przez Polskę depopulacja będzie dalej pogłębianą z uwagi na przemieszczanie się ludności na obrzeża. Trendy te mogą być kontynuowane z uwagi na chęć kontaktu ludności z naturą, rozwój infrastruktury i niższych na tych obszarach kosztów mieszkań.¹⁴ Kontynuowane będą także emigracje do centrum wysoko rozwiniętych województw w poszukiwaniu wyższej edukacji i większego rynku

¹³ Żołędowski C. *Wpływ pandemii COVID-19 na procesy migracji i sytuację migrantów- przypadek Polski 2022*

¹⁴ Żróbek-Różańska A. Zysk E. *Wieś i rolnictwo, NR 4 Czy rozlewające się miasto odmładza Podmiejską wieś? Studium podolsztyńskich gmin wiejskich.* 2015



Rysunek 5 Wartość salda migracji w poszczególnych powiatach Polski w 2020 roku. Źródło: Zintegrowana Platforma Edukacyjna.ZPE.gov.pl *Kierunki i przyczyny migracji zagranicznych i wewnętrznych Polaków. Zmiany salda migracji zagranicznych i wewnętrznych Polaków i ich przyczyny.* <https://zpe.gov.pl/a/przeczytaj/DqkplBP8y>

zawodowego. Podsumowując, ewolucja tendencji migracji wewnętrznych w Polsce przeszła diametralną zmianę od powojennych przesiedleń i socjalistycznej urbanizacji, aż po współczesny proces suburbanizacji i koncentracji ludności w kilku najsilniejszych ośrodkach regionalnych. Obecny krajobraz demograficzny kraju charakteryzuje się wyraźnym podziałem na nieliczne regiony, których cechuje oddane saldo migracji, takie jak województwo mazowieckie czy pomorskie, oraz obszary dotknięte pogłębiającą się depopulacją. Nawet gwałtowne zjawiska o charakterze globalnym, jak pandemia COVID-19, nie zdołały odwrócić utrwalonych trendów przemieszczeń ludności, a jedynie czasowo utwardziły ich dynamikę. Celem omówionego zarysu historycznego jest przyjęcie roli fundamentu do dalszej, wielowymiarowej analizy czynników demograficznych, ekonomicznych i społecznych, które kształtują współczesne tendencje migracji polskich regionów.

2.2. Czynniki różnicujące strukturę ludności w Polsce

Struktura demograficzna naszego kraju cechuje pogłębianiem się różnic pomiędzy obszarów, tworząc w wyniku dwie skrajne grupy regionów rozbudowanych i peryferyjnych. Zjawisko jest to spowodowane ustalonymi poprzez historyczne uwarunkowania osadnicze oraz współczesne procesy zmieniające układ rozmieszczenia ludności. Decyzje, która podejmuje ludność chcąc zmienić miejsce

zamieszkania w obrębie swojej gminy, województwa, lub przekroczyć ich granicę, nie są podejmowane bez wcześniejszej analizy powiązanych ze sobą czynników. Wcześniej wspomniana teoria „push-pull” Everetta Lee utrwała istnienie czynników, które nakierowują jednostki do opuszczenia obecnej lokalizacji na określony przedział czasu i dzielą się na czynniki przyciągające do celu planowanego przemieszczenia i wypychające od obecnego. Teoria ta kładzie nacisk na migracyjne wpływy na strukturę ludności. Należy jednak zaznaczyć, że jest to jedna z grup czynników wpływających na całość obrazu rozmieszczenia obywateli Polski. W niniejszym rozdziale dokonana została analiza cech różnicujących rozmieszczenie ludności w regionach kraju na trzy główne kategorie: demograficzne, ekonomiczne i społeczne. Cechy definiujące strukturę ludności w województwach oraz korelujące z migracją wewnętrzną skutki, które mogą odbiegać od wymienionych grup, zostaną zaprezentowane po wskazaniu głównych czynników w określonych kategoriach. Analiza ta stanowi podstawę teoretyczną do przeprowadzenia empirycznej części badania gdzie wybrane opisane cechy zostaną wykorzystane w metodzie analizy głównych składowych.

2.2.1. Czynniki demograficzne

Do tej pory na podstawie zjawiska migracji wewnętrznych ustalono, że proces ten wpływa na rozmieszczenie ludności po różnych terenach zamieszkania kraju, co skutkuje przemianami w strukturze regionalnych pod względem demograficznym społeczeństwa. Czynniki demograficzne bezpośrednio wpływają na sposób rozwoju terenów mieszkalnych. Pierwszym rodzajem rozróżnienia struktury jest wpływ różnych dominujących grup wiekowych na badanym obszarze. Grupy wiekowe można podzielić na trzy części: przedprodukcyjną, produkcyjną i poprodukcyjną. Dominacja grupy poprodukcyjnej zakładana dla obywateli w wieku emerytalnym, jest nazywana „starzeniem się” demograficznym. Taka sytuacja prowadzi do ujemnego przyrostu naturalnego, który w 2013 roku na tysiąc ludności wynosił -0,5. Ma on zasadniczy wpływ na liczbę mieszkańców i jest również spowodowany tendencją do emigracji osób młodych. Wpływa na niego też zmniejszająca się liczba urodzeń a także postęp cywilizacyjny i zmiany, w jakości życia na wyższą.¹⁵ W wyniku jego,

¹⁵ Antczak E. Lewndowska-Gwarda K. *Dynamika procesu starzenia się ludności w Polsce. Ocena z wykorzystaniem metod strukturalno-geograficznych*. str. 90. Grudzień 2018.

rodzą się wyzwania w zwiększonej opiece medycznej oraz w polityce gospodarczej i społecznej w państwie. Powoduje to też zwiększenie fiskalnych opłat dla ludności w wieku produkcyjnym pracującym w zawodzie z uwagi na pieniężne wsparcia dla emerytów.

Jak wskazuje Joanna Szczepaniak-Sienniak w „Relacje międzypokoleniowe we współczesnych polskich rodzinach” zmiany demograficzne wiążą się z wydłużeniem się średniej życia obywateli naszego kraju. Implikuje to proces wertykalizacji- zmiany wielopokoleniowości z formy „piramid” w „kolumny”. Powoduje to brak większego rozprzestrzenia nowych potomków, czemu towarzyszy zmiana tradycyjnych modeli rodzin.¹⁶ Wielodzietność jest zjawiskiem coraz bardziej zanikającym i zastępowalnym przez posiadanie przez przedstawicieli młodych par jednego dziecka lub jego brak. Taka oszczędna reprodukcja wiąże się z wydłużeniem trwania życia, małą płodnością i starzeniem się populacji.¹⁷ Warto zaznaczyć, że dla województw o dodatnim saldzie migracji, problem braku osób w wieku przedprodukcyjnym i produkcyjnym nie występuje dzięki imigracji osób młodych w celu kształcenia się lub poszukujący pracy. Dla regionów o wyższym poziomie urbanizacji z uwagi na bardziej rozwiniętą infrastrukturę notuje się relatywnie wyższą liczbę urodzeń z uwagi na lepsze warunki do założenia rodzin.

Wzrost przeciętnego trwania życia w Polsce wiąże się z tendencją zmniejszającego się współczynnika umieralności społeczeństwa. Do dziś główny wpływ ma na to rozwój medycyny oraz rosnąca w ludności świadomość zagrożeń dla zdrowia i propagacja sprzyjających zachowań dla dłuższego życia¹⁸. Długość trwania przeciętnego życia w Polsce jest traktowane, jako miernik dobrostanu i jakości kapitału ludzkiego. Warto wspomnieć o dwuletnim czasie 2020-2021 podczas którego panowała pandemia covid-19. Okres ten skrócił długość życia w Polsce o ponad 2 lata. Jednakże po ustępie tej globalnej sytuacji, następował systematyczny proces odbudowy tego wskaźnika aż do jego wzrostu przekraczającego wartość z 2019 roku.¹⁹ Wpływ wcześniejszych wymienionych cech powoduje również zmiany w gęstości zaludnienia. Jest to miernik koncentracji ludności i stopnia

¹⁶ Szczepaniak-Sienniak J. *Relacje międzypokoleniowe we współczesnych polskich rodzinach*. str. 10 2014

¹⁷ Praca zbiorowa pod redakcją Anny Tucholskiej. *Europejskie wyzwania dla Polski i jej regionów*. Ministerstwo Rozwoju Regionalnego. Warszawa 2010

¹⁸ Okolski M. *Wyzwania Demograficzne Europy i Polski*. str 41. 2010

¹⁹ Maciążek P. *Cowzdrowiu.pl GUS: Długość życia Polaków znów rośnie. "Przełamany trend pandemii"* 30 lipiec 2025

zagospodarowania terenu. Zauważalna jest tendencja niskiej wartości tego wskaźnika dla regionów peryferyjnych będących głównie wsiami i mniejszymi miastami. Wysoka gęstość zaludnienia jest obserwowalna dla miast charakteryzujących historyczne uprzemysłowienie jak np. dla województwa śląskiego. Proces ten również jest wiązany z wcześniej wspomnianą suburbanizacją polegającą na przemieszczeniu się ludności z centrum miast na obrzeża.

Podsumowując, czynniki demograficzne tworzą powiązany układ, w którym struktura wieku, urodzeń i śmierci wspólnie oddziałuje na siebie również uwzględniając migracje i zaludnienie obszarów miejskich. Regiony posiadające zasoby ludności w wieku przedprodukcyjnym i produkcyjnym wykazują większą odporność na kryzysy demograficzne, co czyni wymienione cechy kluczowymi zmiennymi w planowanej analizie PCA.

2.2.2. Czynniki ekonomiczne

Kolejny zbiór czynników różnicujących strukturę ludności w Polsce cechuje wpływ na omawiane wcześniej migracje wewnętrzne. Ekonomiczne czynniki są determinującymi wskaźnikami współczesnych kierunków przemieszczeń ludności. Opisana wcześniej neoklasyczna teoria migracji ustala, że podjęcie decyzji o zmianie miejsca zamieszkania jest wynikiem osobistych badań obywatela, który dąży do maksymalizacji swoich dochodów i poprawy standardów życia. Jednak jak teoria ta ma dwa wymiary analityczne: makro i mikro. Podczas, gdy wcześniejsza chęć jednostki do maksymalizacji dobrostanu ekonomicznego opisywała formę mikro, na poziomie makro teoria ta głosi o efekcie nierównomiernej dystrybucji pracy i kapitału przez geograficzne usytuowanie. Zakłada wysoki popyt na pracę dla regionów rozwiniętych wiążący się z niską podażą pracy. Skutkuje to wysokimi płacami.²⁰ Kraje rozwijające się, niedysponujące kapitałem charakteryzuje wysoka podaż pracy i niskie płace. Według tej teorii, efektem tego zjawiska jest migracja pracowników z miejsc charakteryzujące bezrobocie i przeludnienie do obszarów posiadających wyższe płace. Co ciekawe, teoria ta implikuje, że w dłuższym okresie czasu zniknie główna przyczyna migracji, jaką jest różnica w wartości płac. W polskiej przestrzeni

²⁰ Jaskułowski K. *GŁÓWNE TEORIE MIGRACJI MIĘDZYNARODOWYCH: PRZEGLĄD*, Kr y t y k a , PERSPEKTYWY str.130 2016

regionalnej, te czynniki ekonomiczne tworzą wyraźną strukturę dzielącą kraj na obszary dynamicznie rozwijające się oraz regiony peryferyjne, dotknięte problemami strukturalnymi. Miernikiem poziomu rozwoju gospodarki na danym obszarze jest produkt krajowy brutto (PKB). Jest to wskaźnik reprezentowany, jako „wartość rynkowa wszystkich finalnych dóbr i usług wytworzonych w gospodarce w danym okresie”.²¹ Dane Głównego Urzędu Statystycznego wskazują na stałe dysproporcje dla tej metryki. Najwyższy wskaźnik PKB charakterystyczny jest dla województw posiadających silnie rozwinięte aglomeracje. Skalę nierówności dokładnie obrazuje wartość PKB w przeliczeniu na jednego mieszkańca, która jest kluczowym miernikiem zamożności regionu. Podkreśleniem znaczenia tego zjawiska są dane produktu krajowego brutto na jednego mieszkańca według regionów z 2024 roku. Zebrane informacje wskazują na dominację pięciu jednostek terytorialnych w Polsce, które wytworzyły razem ponad połowę krajowej wartości PKB. W skład tych jednostek wchodzi region warszawski stołeczny, śląski, wielkopolski, dolnośląski i małopolski.²² Dane te utrwalają tendencję podziału kraju na silne centra wzrostu i obszary peryferyjne. Wyniki prognozy dla gmin dla lat 2017- 2030 wskazują pogłębianie tego procesu, co grozi marginalizacją ekonomiczną i społeczną znacznej części kraju.²³ Wysoki poziom PKB jest sygnałem dla migrantów o obecności zaawansowanej infrastruktury, nowoczesnego sektora usług oraz stabilnego otoczenia biznesowego. Warto wskazać, że w kontekście migracji zagranicznych, mimo powolnej konwergencji, wciąż utrzymuje się luka dochodowa między Polską a krajami Europy Zachodniej będącymi częstymi celami emigracji, co wskazuje na istotność tego czynnika stymulującego mobilność Polaków. Zjawiskiem wskazującym na wpływ rosnącego PKB na migracje, jest „garb migracyjny” (z angielskiego „migration hump”), które nosi tezę, dla której wzrost gospodarczy nie musi hamować emigrację a może on nawet je pobudzać poprzez dostarczanie środków potrzebnych do opłacenia kosztów migracji.²⁴

Kolejnym czynnikiem ekonomicznym, który determinuje procesy ludnościowe jest sytuacja panująca na danych obszarach regionalnych i lokalnych rynkach pracy.

²¹ Mankiw N. G. Makroekonomia str. 504 2008

²² Słomski D. *Te regiony stanowią o sile polskiej gospodarki [TABELA]*. Business Insider. <https://businessinsider.com.pl/gospodarka/pkb-polski-z-podzialem-na-wojewodztwa-nowe-dane-gus-tabela/bvf341s>

²³ Hryniewicz J. Witkowski J. Potrykowska A. *Sytuacja demograficzna Polski jako wyzwanie dla polityki społecznej i gospodarczej*. Warszawa 2018.

²⁴ Kaczmarczyk P. Tyrowicz J. *Współczesne procesy migracyjne w Polsce a aktywność organizacji pozarządowych w obszarach powiązanych z rynkiem pracy*. Warszawa, listopad 2007

Wyrażana jest ona przede wszystkim, jako stopa bezrobocia. Jest to procentowy udział liczby osób bezrobotnych w liczbie aktywnych zawodowo.²⁵ W pracy autorstwa Pawła Kaczmarczyka i Joanny Tyrowicz, wzrost poziomu bezrobocia w obszarze zamieszkałym jest wskazywany, jako istotny czynnik wypychający (z wcześniej opisanej teorii „push-pull”) wpływający na wzrost skali migracji ludności w wieku produkcyjnym. W Polsce, krajowa stopa bezrobocia utrzymuje się na stosunkowo niskim poziomie. Na koniec grudnia w 2025 roku wyniosła ona 5,7%. To pokazuje wzrost tego zjawiska, które w 2024 roku wyniosło 5,1%. Z danych zebranych przez Ministerstwo Rodziny, Pracy i Polityki Społecznej zebranych z grudnia 2025 roku wynika, że trzema województwami o największym procentowym udziale osób bezrobotnych są województwa świętokrzyskie (8,3%), warmińsko-mazurskie (9,2%) i lubelskie (8,1%). Regionami o najniższej stopie bezrobocia są województwa wielkopolskie (3,6%), mazowieckie (4,3%) i śląskie (4,4%). Zatem polski rynek pracy w poszczególnych województwach charakteryzuje się silnym zróżnicowaniem w zależności od poziomu rozwinięcia danych regionów. Ministerstwo zaznacza, że wzrost bezrobocia może być skutkiem zmniejszenia liczby rekrutacji w firmach zauważalnej poprzez spadek liczby ofert pracy na rynku. Zwraca też uwagę na występowanie sezonowości prac w niektórych sektorach, co również wpływa na zmienną wartość tej metryki w różnych obiegach czasowych.²⁶ Warto zaznaczyć, że zjawisko polaryzacji występującej na rynku pracy jest zauważalne również w ujęciu wewnątrz regionu. Przykład stanowi województwo mazowieckie dla którego w grudniu 2024 zaobserwowano największą dysproporcję stopy bezrobocia wyniosła 21,9 punktów procentowych (23,3% w powiecie szydłowieckim oraz 1,4% w powiecie miasta Warszawy). W grudniu 2023 obserwuje się również najgłębszy spadek zróżnicowania w województwie podlaskim i największy wzrost w lubuskim o jeden cały punkt procentowy z 6,8 do 7,8%.²⁷ Przeprowadzone analizy wskazują na odwrotność proporcji w zależności poziomu bezrobocia od wielkości miasta- im mniejsze miasto, tym zauważalny odsetek bezrobotnych bywa wyższy. Skutkuje to postępującym rozdzielaniem społeczeństwa i wyludnienia obszarów o mniejszej gęstości zaludnienia. Zatem wysoki współczynnik bezrobocia wskazuje na zarówno większą ilość migracji wewnętrznych z regionów peryferyjnych jak i migracji

²⁵ Kubel-Grabau A. Gov.pl *Monitorowanie stopy bezrobocia* 4 marzec 2021


²⁶ Gov.pl *Bezrobocie w końcu 2025 roku. Przedstawiamy wstępne dane* 9 styczeń 2026

²⁷ Główny Urząd Statystyczny. *Sytuacja społeczno-gospodarcza Warszawa województw Nr 4/2024* Warszawa 2025

zagranicznych. Paweł Kaczmarczyk i Joanna Tyrowicz zauważają, że strategie polegające na ciągłej sezonowej krótkoterminowej migracji, choć ratują budżety domowe, w dłuższej perspektywie mogą prowadzić do zjawiska „zamrożenia” bezrobocia w kraju, zniechęcając do zagwarantowania stałej pracy czy otworzenia własnej działalności gospodarczej, jednocześnie uszczuplając lokalny potencjał demograficzny poprzez odpływ młodych ludzi skłonnych do podjęcia sezonowej pracy do bardziej rozwiniętych regionów Polski lub państw zagranicznych.

Konsekwencją zróżnicowania stopnia rozwinięcia gospodarki w różnych regionach Polski jest zjawisko dysproporcji w średniej wartości dochodów pracującej ludności. Według wcześniej wspomnianej neoklasycznej teorii migracji, to skala różnic oczekiwanych wynagrodzeń zarówno w jednym państwie jak i za granicą ustala rozmiary przepływów migracji między krajami i służy, jako czynnik nakłaniający do emigracji. W 2025 roku, według raportu Głównego Urzędu Statystycznego, przeciętne miesięczne wynagrodzenie brutto w sektorze przedsiębiorstw wyniosło 8934,98 zł. Wynik jest o 8,1% wyższy niż w poprzednim roku gdzie wzrost wynosił 11%.²⁸ Rysunek 6 prezentuje zmianę przeciętnych miesięcznych wynagrodzeń brutto w sektorze przedsiębiorstw od lat 2017 do 2025. Jak można zauważyć, wykres porównuje dwa wskaźniki- płace nominalne pokazujące o ile procent wzrosła kwota w porównaniu do tych z lat ubiegłych oraz płace realne, które uwzględniają inflację pokazującą zmianę w siły nabywczej pieniędzy w tym czasie. Obserwowalny jest nominalny wzrost wynagrodzeń na przestrzeni lat do roku 2022, po którym nastąpił ich stopniowy spadek powiązany ze wzrostem realnej wartości zarobków. Z raportu można się również dowiedzieć o tym, w jakich przedsiębiorstwach zaobserwowano największy wzrost. Wymienione zostały działalności związane z kulturą, rozrywką i

²⁸ Główny Urząd Statystyczny. *Sytuacja społeczno-gospodarcza kraju w 2025 r.* Warszawa Grudzień 2026



Rysunek 6 Przeciętne miesięczne wynagrodzenia brutto 2017-2025. Źródło: GUS. Sytuacja społeczno-gospodarcza kraju w 2025 r. Warszawa Grudzień2026

rekreacją o 10,2% z dostawą wody gospodarowaniu odpadami o 9,7% oraz związane z transportem i gospodarce magazynowej o 9,5%. Najmniejszy wzrost zaobserwowano w górnictwie. Najwyższy poziom płac jest notowany w województwie mazowieckim. Jako inne regiony przewyższające średnią dla Polski wymieniane są województwa: dolnośląskie, małopolskie, śląskie i pomorskie. Najniższe wynagrodzenia zaobserwowano w województwach: podkarpackim, podlaskim, świętokrzyskim oraz lubelskim. Dane statystyczne wskazują, że rozpiętości między regionami o najwyższych i najniższych płacach nieznacznie maleją. Wskazuje na to wynosząca w 2024 roku różnica 31,4 punktu procentowego. W mniej rozwiniętych regionach odnotowano w ostatnich latach najwyższą dynamikę wzrostu. Pomimo tego, strukturalne różnice w poziomie dochodów wciąż stanowią znaczny czynnik wypychający, kierujący migrantów wewnętrznych z rodzinnych prowincji do bardziej rozwiniętych ośrodków. W przypadku migracji zewnętrznych przede wszystkim do zachodnich krajów Europy, kwestia wynagrodzeń posiada jeszcze bardziej znaczącą rolę w podjęciu decyzji o emigracji. W pracy Joanny Turowicz i Pawła Kaczmarczyka z 2007 roku można się dowiedzieć, że z projektu badającego zarobki pracowników sezonowych emigrujących do Niemiec wynika, że zarabiane wynagrodzenia wahało się w przedziale od 750 do 1000 euro miesięcznie. Pomimo przeciętności wartości tego wyniku dla warunków niemieckich i tak mogły pięciokrotnie przewyższać przeciętne wynagrodzenie w Polsce przy przeciętnym okresie trwania kontraktów. Obecnie, różnica ta spadła do dwukrotności, choć biorąc pod uwagę zwiększające się koszty życia w Niemczech, ta różnica zmniejszyła się w jeszcze większym

stopniu. Aktualna jednak pozostaje obserwacja, że odpływ kapitału ludzkiego wywołuje zjawisko sprzężenia zwrotnego na polskim rynku pracy. Następujący spadek podaży rąk do pracy zwiększa presję płacową, wymuszając na pracodawcach podnoszenie wynagrodzeń, stopniowo transformując polską gospodarkę z rynku pracodawcy w rynek pracownika.


2.2.3. Czynniki społeczne

Następstwem występujących zjawisk ekonomicznych na terenie naszego kraju z uwzględnieniem deficytów na rynku pracy w kontekście regionalnym stają się powstające procesy o charakterze społecznym. Z uwagi na opisany w rozdziale dotyczącym czynników demograficznych problem starzenia się społeczeństwa w Polsce i zmniejszającej się liczby urodzeń dzieci, kluczowym czynnikiem wynikającym z tych zdarzeń związanym z funkcjonowaniem gospodarki jest liczba pracujących cudzoziemców. Zatrudnianie obcokrajowców jest obecnie w naszym kraju obserwowalne w coraz większym tempie i na coraz większą skalę. Wykazane zostało 329 zawodów deficytowych przez Ministerstwo rodziny, pracy i polityki społecznej, które wymagają zwiększonego zatrudnienia cudzoziemców. Dla osób wykonujących te profesje jest nawet obiecana „przyspieszona legalizacja pobytu i prostsze procedury zatrudnienia”.²⁹ Według danych GUS z 2025 roku, pracę w Polsce wykonywało 1068900 obcokrajowców. Daje to wynik większy od tego z 2024 o 4,4%. Zauważono, że większość (około 59,9%) imigrantów stanowili mężczyźni. W związku z panującym konflikcie zbrojnym na terenie Ukrainy, dominującą grupę niezmiennie stanowią obywatele tego kraju. Stanowią oni 66,8% zagranicznej siły roboczej. Jako inne kraje z mniejszym odsetkiem imigrantów pracujących w Polsce wymienia się Białoruś, Gruzję, Indie oraz inne mniej istotne. Zaobserwować można polaryzację dla tej imigracji gdyż ustalono, że co piąty cudzoziemiec osiedla się w regionie warszawskim stołecznym o najwyższym potencjale gospodarczym w naszym państwie. Inne regiony o wysokiej populacji imigrantów zza granicy stanowią województwo dolnośląskie, wielkopolskie oraz śląskie, które również charakteryzuje się bogaty rynek pracy i rozwinięta gospodarka. Trzema najmniej zamieszkałymi

²⁹ Waluszko F. Business Insider *Rekordowa liczba cudzoziemców w ZUS. Z tych krajów przybywa ich najwięcej.* 5 Luty 2026

regionami okazały się być województwo podkarpackie, warmińsko-mazurskie i świętokrzyskie.³⁰

Następnym czynnikiem, który stanowi wskaźnik potencjału społecznego i rozwoju poziomu edukacji w regionach naszego kraju jest liczba osób uczęszczających na uczelnie wyższe. Jako, że migracje wewnętrzne często dotyczą osób młodych, duże miasta z ośrodkami akademickimi stanowią często docelowy punkt i przyczynę zmiany miejsca zamieszkania. Na zamieszczonym poniżej wykresie obrazującym zmianę w liczbie studentów na przestrzeni lat wraz z prognozą do 2035 roku. Najwyższy punkt ich ilości nastąpił w 2005 roku, który jest uzasadniony wystąpieniem w latach osiemdziesiątych wyżu demograficznego. Od tego czasu obserwowalny jest spadek liczby studentów z prognozą na ponowne jej stopniowe wyniesienie od 2030 roku.



Rysunek 7 Wykres liczby studentów w Polsce. Źródło: Ministerstwo Nauki Szkolnictwa Wyższego (2013). Kancelaria Prezydenta RP (2013)

W roku akademickim 2024/2025, dzięki danym z GUS można się dowiedzieć o 2,8-procentowym wzroście liczby studentów w stosunku do poprzedniego roku. Rozmieszczenie studentów w Polsce jest wysoce nierównomierne. Województwo mazowieckie ponownie nosi tytuł lidera spośród reszty województw w Polsce osiągając wynik 288 tysięcy osób uczęszczających na uczelnie. Wyróżnić można również województwa: małopolskie z 152 tysiącami studentów, wielkopolskie z 134 tysiącami oraz dolnośląskie z blisko 125 tysiącami studentów. Województwa z obserwowalnymi problemami strukturalnymi i wysokim odpływem młodych ludzi w

³⁰ Główny Urząd Statystyczny. *Cudzoziemcy wykonujący pracę w Polsce w maju 04.11.2025 r.* 2025

wieku produkcyjnym posiadają najmniejsze liczby studentów. W województwie lubuskim uczyło się zaledwie 11,6 tysięcy studentów, w opolskim 17,8 tysięcy, a w świętokrzyskim około 20,6 tysięcy. Z racji na obserwowalne ubytki na polskich uczelniach, coraz bardziej rozwijane są projekty mające na celu pozyskanie studentów zza granicy jak prowadzenie zajęć języku obcym czy przeprowadzenie wymian studenckich. Poza uzupełnieniem braków, taka kwestia jest ważna głównie z powodu regulacji finansowych oraz uzyskiwanej przez uczelnie renomy. Obecnie w Polsce kształcą się 108,6 tysięcy studentów zagranicznych, z których niemal jedna trzecia uczy się w samym województwie mazowieckim.³¹

Następnym elementem różnicowania się wymiaru społecznego w Polsce jest proces kształtowania rodzin. Aby zbadać dynamikę tego procesu, w analizie uwzględniona zostanie również liczba zawartych małżeństw w kolejnych województwach. Jest to cecha, która poprzez przekładanie się na wskaźnik dzietności na badanych regionach wpływa na przyszłą strukturę demograficzną. Na podstawie danych z Głównego Urzędu Statystycznego możemy się dowiedzieć, że W Polsce od 2010 roku obserwowalny jest spadek powstawania nowych związków małżeńskich. Tendencja ta jest skutkiem priorytetyzacji kariery zawodowej oraz dłuższego trwania procesu edukacji wyższej. W wyniku tych czynników, zauważalny jest późniejszy wiek wstępowania w związek małżeński. W 2024 roku mediana wieku w momencie zawierania małżeństwa wynosiła już 32 lata dla mężczyzn i niemal 30 lat dla kobiet, co stanowi wzrost o około 6 lat w stosunku do roku 2000. Województwami, w których obserwuje się największą liczbę nowych zawartych małżeństw są kolejno województwa: mazowieckie, śląskie, małopolskie i wielkopolskie, co ma związek z wysoką gęstością zaludnienia oraz rozwinięciem tych regionów. Najmniej małżeństw w 2024 roku zawarto w województwie świętokrzyskim i opolskim. Wraz ze zmniejszającą się liczbą małżeństw, obserwowalna jest również rosnąca liczba rozpadających się związków. Te procesy demograficzne głęboko transformują strukturę społeczną i powiększają trudności przez je kreowane dla lokalnych rynków pracy i polityki publicznej w Polsce.

³¹ Malesa P. *Czynniki determinujące liczbę studentów w Polsce ze szczególnym uwzględnieniem trendów demograficznych*. 2015

2.3. Konsekwencje migracji wewnętrznych

Na podstawie wymienionych do tej pory czynników uwarunkowanych przez zmiany w obserwacjach procesów demograficznych, ekonomicznych i społecznych, w poprzednich rozdziałach, można przejść do badania przyczyn, wpływu i prognoz, jakie mają one na dynamiczny rozwój obszarów „centralnych” oraz traceniu potencjału przez tereny peryferyjne. Zauważono istotę migracji wewnętrznych i to jak odzwierciedlają różnice w poziomie życia Polaków i korelują z kondycją lokalnych rynków pracy. Zjawisko to samo w sobie jest się ważnym czynnikiem transformującym struktury demograficzne, społeczne i gospodarcze naszego kraju. Zauważyć można, że migracje wewnętrzne mają charakter dualny. Masowe napływy przyczynia się do rozwoju i poszerzenia potencjału w obrębie ośrodków przyciągających imigrantów głównie w obrębie największych aglomeracji. Z drugiej strony, ten sam proces oznacza zakłócenie kapitału ludzkiego z obszarów słabiej rozwiniętych i prowadzi do wyludnienia obywateli mniejszych miast i wsi. W obecnym rozdziale omówione zostaną korzyści czerpane przez regiony atrakcyjne oraz bariery rozwoju narzucane pod wpływem emigracji ludności z regionów peryferyjnych.

2.3.1. Korzyści dla regionów atrakcyjnych

Migracje wewnętrzne umożliwiają realne zjawisko rozwoju regionów, do których przybywa ludność. Są to głównie najlepiej rozwinięte miejskie aglomeracje, które w największym stopniu przyciągają imigrantów z bardziej odległych terenów. Obszary te zgodnie z koncepcją ekonomisty François Perroux o pełnią funkcję „biegunów wzrostu”, które generują wysoki poziom rozwoju. Koncepcja biegunów ewoluowała z odniesienia się wyłącznie do podmiotów gospodarczych na rynku pracy do zaznaczenia występowania zjawiska nierównomiernego poszerzania potencjału aglomeracji w wymiarze przestrzennym zaznaczając lokację zaawansowanych technologicznie gałęzi przemysłowych budujące konkurencję i powiększające dalsze napływy ludności.³² Obecnie w Polsce na podstawie danych statystycznych, jako beneficjentów tego zjawiska wyróżnia się między innymi aglomerację warszawską, górnośląską, krakowską czy trójmiasto. Dla wszystkich tych obszarów obserwuje się dodatnie saldo migracji. Korzyścią o charakterze

³² Kotarski H. *Kapitał ludzki i kapitał społeczny a rozwój województwa podkarpackiego* 2013

demograficznym stanowi poprawienie się struktury wieku ludności poprzez transfer obywateli w wieku produkcyjnym. W wyniku tego zjawiska dla atrakcyjnych regionów zaobserwować można zmniejszenie wskaźnika starzenia się społeczeństwa oraz pozyskanie korzystniejszego wskaźnika przyrostu naturalnego. Na podstawie prognozy Głównego urzędu statystycznego dotyczącego ludności gmin na rok 2030, przewidziano kontynuację zmniejszania się przyrostu naturalnego, lecz zaobserwowano tendencję głoścącą, że większość gmin w bliskiej odległości z większymi miastami odnotuje jego dodatnie wartości. Dodatnie wyniki dla takich obszarów zostaną zaobserwowane również dla metryk salda migracji.³³ Konsekwencją migracji wewnętrznych poprzez napływ wykwalifikowanych potencjalnych pracowników jest redystrybucja kapitału ludzkiego i społecznego do dużych miast. Co więcej te regiony centralne mogą pozyskać siłę roboczą, której okres edukacji został już zrealizowany w poprzednim miejscu zamieszkania, co stanowi zysk dla ich gospodarki. Korzystają z tego również zróżnicowane przedsiębiorstwa, które chętnie przyjmują siłę roboczą w sektorze drugorzędym dotyczącym przetwórstwa surowców.³⁴ Pozwala to na kształtowanie się równowagi na lokalnych rynkach pracy gdzie zarówno pracodawcy jak i potencjalni pracownicy stają się od siebie zależni. W wyniku koncentracji ludności w regionach rozbudowanych zwiększa się zapotrzebowanie na lokalne produkty i usługi oraz na budowę nowych mieszkań. Zdaniem Pawła Kaczmarczyka i Joanny Tyrowicz, transfer takich środków wpływa na rozwój lokalnej i regionalnej gospodarki poprzez efekt mnożnikowy. Efekt ten polega na ciągłym wielokrotnym wzroście wydatków produkcji narodowej. Poprzez ten rosnący popyt konsumentów powstaje coraz więcej zakładów pracy oraz mieszkań i generowane są dodatkowe środki finansowe. Proces migracji wewnętrznych przekłada się również na ekonomię lokalnych samorządów. Przybycie na tereny wysoko rozwinięte aktywnych zawodowo mieszkańców łączy się ze wzrostem wpływających dochodów do budżetu lokalnego poprzez spłacane podatki. Otwiera to możliwości na finansowanie rozbudowywania infrastruktury publicznej lub miejscowej opieki społecznej. Dzięki zwiększającym się dochodom i dalszemu procesowi urbanizacji, poziom atrakcyjności tych obszarów jeszcze bardziej się zwiększa dla potencjalnych nowych fal imigrantów.

³³ Hryniewicz J. Witkowski J. Potrykowska A. *Sytuacja demograficzna Polski jako wyzwanie dla polityki społecznej i gospodarczej* Warszawa 2018

³⁴ Fuhrmann M. *ZPE Konsekwencje migracji wewnętrznych i zagranicznych Polaków*

2.3.2. Bariery rozwoju regionów peryferyjnych

Drugą stroną migracji wewnętrznych jest ich wpływ na wytwarzanie barier rozwojowych obszarów opuszczanych przez obywateli w poszukiwaniu pewniejszej ścieżki rozwoju. Regiony peryferyjne, które znajdują się w dalekiej odległości od rozwiniętych centrów aglomeracji w wyniku utraty kapitału ludzkiego napotykają przeszkody prowadzące do stopniowej stagnacji. W wyniku odejścia obywateli w wieku produkcyjnym w poszukiwaniu wyższej edukacji i pracy, następuje zjawisko depopulacji i starzenia się społeczeństwa. Prowadzi to do spadku liczby urodzeń i braku zastępowalności pokoleń. Powołując się ponownie na pracę Rządowej Rady Ludnościowej z przypisu numer 33, w samych latach 1990-2015 we wewnętrznych ruchach ludności Polski odnotowano 11,7 mln wymeldowań, gdy liczba urodzeń wyniosła ok. 10 mln a zgonów 9,5 mln. Podkreślić należy również, że obserwowalny jest większy odpływ kobiet niż mężczyzn, który powoduje maskulinizację wsi i zmniejsza szanse na założenie rodzin. W wyniku spadku liczby potencjalnych pracowników- z uwagą na odpływ jednostek wyżej wykształconych na regionach peryferyjnych, obserwowalna jest utrata czynnika rozwoju lokalnych rynków. Problem emigracji dużej liczby ludności prowadzi do „migracyjnej pułapki nierównowagi”.³⁵ Romuald Jończy używa tego terminu aby nazwać proces nierównowagi między dochodami mieszkańców generowanych głównie przez migracje a aktywnością gospodarczą i zatrudnieniem na rynkach lokalnych. Taki odpływ ludzi zdolnych do pracy zmniejsza podaż pracy i zwiększa popyt na usługi i dobra, które trudno zaspokoić. Wymusza to zwiększony nacisk na import tych dóbr spoza regionu a kapitał wygenerowany przez ojczysty region nie przyczynia się do tworzenia nowych miejsc pracy. Obserwowalną barierą jest także spadek dochodów jednostki samorządu terytorialnego występujący przez zmniejszoną ilość podatników. Prowadzi to do utrudnienia utrzymania procesu rozbudowania infrastruktury oraz powoduje ryzyko zapaści sfery usług publicznych na arenie lokalnej. Za przykład takich placówek publicznych można podać szkoły, które na mniejszych terenach miejskich i wiejskich pełnią funkcję zarówno edukacyjną jak i kulturową budując wspólnotę lokalną. Mała liczba potencjalnych uczniów może grozić brakiem utworzenia się grup szkoleniowych, co może skutkować zamknięciem placówek.

³⁵ Jończy R. *Wpływ migracji zagranicznych na dysharmonię rozwoju województwa opolskiego (ze szczególnym uwzględnieniem rynku pracy)*. Opole: Instytut Śląski 2006

Poprzez nasilenie wymienionych czynników, obszary peryferyjne wpadają w „błędne koło stagnacji” gdzie brak perspektyw dla obecnych mieszkańców spowodowany emigracjami wymusza również konieczność ich emigracji do obszarów bardziej atrakcyjnych, tym samym zmniejszając szanse na rozwój społeczny i gospodarczy swojego pierwotnego miejsca zamieszkania.

3. Metodyka badań

Przed przystąpieniem do właściwej analizy empirycznej dotyczącej uwarunkowań migracji wewnętrznych w Polsce, konieczne jest nakreślenie teoretycznych i metodologicznych ram wykorzystanych narzędzi badawczych. Niniejszy rozdział poświęcony jest charakterystyce zaawansowanych metod analizy danych oraz algorytmów uczenia maszynowego, które stanowią fundament części praktycznej niniejszej pracy. W pierwszej kolejności omówiona zostanie istota analizy regresji, jako głównego narzędzia modelowania predykcyjnego dla zmiennych ciągłych. Przybliżone zostaną mechanizmy działania czterech zróżnicowanych algorytmów regresyjnych, które posłużą prognozowaniu salda migracji wewnętrznych w badanych województwach na przestrzeni lat. Następna część rozdziału skupi się na technice analizy głównych składowych, przedstawiając zarówno jej klasyczny wariant jak i również wariant transformacji nieliniowej. Dany rozdział stanowi merytoryczną i matematyczną bazę informacji, która jest niezbędna do prawidłowego przeprowadzenia empirycznej analizy i interpretacji jej wyników w rozdziale badawczym.

3.1. Istota analizy regresji


Z uwagi na rozpowszechnienie się potrzeb do zbadania powiązań występujących pomiędzy badanymi cechami w dziedzinach badań empirycznych, konieczne było znalezienie narzędzia, które umożliwi ustalenie tejże oceny. Aby ocenić wpływ obserwowanych czynników na końcowy wynik danego zjawiska, stosuje się metodę statystyczną będącą analiza regresji wielorakiej. Jako przykład praktyczny może posłużyć potrzeba ekonomicznego sprawdzenia, jakie cechy kształtują końcową sprzedaż danych produktów lub sprawdzenie, jaki wpływ na

wynik choroby mają czynniki zdrowotne pacjentów.³⁶ Analiza regresji opiera się na sprawdzeniu, w jaki sposób jedna zmienna docelowa kształtuje się pod wpływem kilku zmiennych objaśniających, starając się to ująć w sposób ilościowy. Metoda ta umożliwia też wykryć obserwacje „odstające” od reszty- mają znacznie różniące się wartości o wyższym lub niższym nominale. Problem obliczeniowy, który rozwiązuje się w analizie regresji wielorakiej można zaprezentować na wykresie rozrzutu, na którym zaobserwować należy dopasowanie linii prostej do zbioru punktów. Przykład takiego wykresu przedstawia rysunek 8, który prezentuje najprostszy przypadek z jedną zmienną zależną i jedną niezależną. Jest to przykład dla regresji liniowej. Celem tej metody jest dopasowanie linii do rozproszonych punktów. Program tej metody dobiera takie równanie dla tej linii, „że suma kwadratów odległości punktów na wykresie rozrzutu od linii regresji będzie minimalna”.³⁷ Wspomniana metoda dopasowująca współczynniki nosi nazwę „metody najmniejszych kwadratów”. Jej celem jest zminimalizowanie sumy kwadratów odległości błędów, zwanych resztami między rzeczywistymi punktami danych a wyznaczoną teoretyczną linią regresji. Linia prosta na płaszczyźnie zdefiniowana jest przez równanie „ $Y=a+b*X$ ”. „Y” oznacza zmienną, dla której oblicza się sumę wartości stałej „a” z iloczynem nachylenia „b” przez drugą zmienną „X”. Jeśli dla przykładu przyjmie się, że dla średniej ocen ucznia „Y” obliczymy „1+0,02” dla cechy „X” równej 134 (za którą przyjmujemy poziom inteligencji ucznia), jego średnia ocen wyniesie 3,68.

³⁶ Wątroba J. *Prosto o dopasowaniu prostych, czyli analiza regresji liniowej w praktyce*. StatSoft Polska. z o.o. 2011

³⁷ Statsoft.pl *Regresja Wieloraka*.

https://www.statsoft.pl/textbook/stathome_stat.html?https%3A%2F%2Fwww.statsoft.pl%2Ftextbook%2Fstmulreg.html



Rysunek 8 Przykładowy wykres rozrzutu dla dwóch cech. Źródło: https://www.statsoft.pl/textbook/stathome_stat.html?https%3A%2F%2Fwww.statsoft.pl%2Ftextbook%2Fstmulreg.html

Mając do czynienia z regresją wielowymiarową, linia nie będzie już móc być przedstawiana w dwóch wymiarach. We wzorze matematycznym tej metody, dodawane zostają kolejne cechy opisujące zmienną docelową:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

Rysunek 9 Wzór liniowej regresji. Źródło: J. Wątroba, *Prosto o dopasowaniu prostych, czyli analiza regresji liniowej w praktyce*. StatSoft Polska. z o.o. 2011

Na wzorze powyżej zobaczyć można też wyraz wolny wyrażony, jako „ β_0 ”. Jest to punkt przecięcia linii regresji z osią Y. Kolejne współczynniki β określają wpływ wymienianych zmiennych na badaną cechę docelową.

Obliczenia dla analizy regresji wykonuje się przy użyciu języków programowania. Dla języka Python wyróżnia się dwie główne biblioteki, które używa się do przeprowadzenia tej metody: „scikit-learn” i „statsmodels”. Pierwsza z nich zawiera kluczowe funkcje potrzebne dla większości przeprowadzonych analiz, podczas gdy „statsmodels” stanowi jej większe rozbudowanie. W celu wizualizacji wyników na wykresach używa się też biblioteki „matplotlib” oraz „numpy” dla obliczeń na macierzach.³⁸ Wyniki regresji najczęściej prezentuje się poprzez statystyczne zestawienia tabelaryczne ukazujące oszacowania współczynników, błędy standardowe i poziomy istotności statystycznej. Przedstawia się je również w formie graficznej tak jak na wcześniej wspomnianych wykresach rozrzutu, które nakładają

³⁸ Skoneczny S. Softinery.com Python – regresja liniowa. <https://softinery.com/pl/blog/python-regresja-liniowa/>

rzeczywiste obserwacje na linię modelu, a także wykresów reszt, które pozwalają sprawdzić, czy błędy predykcji modelu są losowo rozproszone. Po wykonaniu obliczeń algorytmu regresji przechodzi się do oceny jakości dopasowania modelu. W tym celu generowanych jest kilka wskaźników służących do ewaluacji wyników.

Podstawową miarą przyjmującą wartości od ujemnej nieskończoności do 1 jest współczynnik determinacji „ R^2 ”. Wskazuje on, jaką część lub procent zmienności docelowej zmiennej zależnej zdołano wyjaśnić przez uwzględnione cechy w zbiorze danych. Im wartość jest bliższa jedynce, tym wariancja wartości celu jest lepiej wyjaśniona, z czym wiąże się sprawdzona większa istotność wprowadzonych cech. Niska wartość współczynnika determinacji może świadczyć o niewystarczających zależnościach i ważności podanych zmiennych do analizy regresji. Może też dać znak o nieoptymalnie zastosowanym modelu regresji na przykład poprzez nieliniowy charakter zmiennych użytych do przeprowadzenia regresji liniowej. Naturalny współczynnik R^2 rośnie z każdą nową wprowadzaną zmienną nawet, gdy nie poprawia wartości stosuje się go, gdy w modelu występuje tylko jeden predyktor. W modelach z wieloma predyktorami, czyli w zastosowanej regresji wielorakiej wykorzystuje się skorygowany współczynnik R^2 , który uwzględnia liczbę zmiennych i pozwala na bardziej ostrożny sposób oceniania dopasowania cech penalizując te, które nie wnoszą rzeczywistej wartości. Następną metryką jest pierwiastek średniej kwadratowej błędu oznaczany przez „RMSE”. Jest to średnia oczekiwanej różnicy pomiędzy wartością przewidywaną przez model regresji a tą prawdziwą wartością. Metrykę tę definiuje się, jako odchylenie standardowe reszt- różnicy między obserwowaną wartością a przewidywaną dla danej cechy. Dąży się do otrzymania jak najniższej wartości RMSE, aby mieć pewność, że przewidywane wyniki przez model są podobne do rzeczywistych. Jednostka tej metryki jest taka sama jak ta dla zmiennej docelowej. Kolejną metryką jest błąd średniokwadratowy „MSE”, który jest wartością poprzednio wspomnianych błędów podniesioną do kwadratu. Interpretuje się go, jako średnio spodziewaną różnicę +/- od kwadratu między przewidywaną wartością a rzeczywistą. Zaletą podnoszenia tych różnic do kwadratu jest to, że ujemne błędy nie znoszą się z dodatnimi a model jest w wysokim stopniu karany za duże pomyłki prognoz w wynikach. Średni błąd bezwzględny „MAE” definiuje się, jako średnią arytmetyczną absolutnych odchyłeń predykcji od wartości rzeczywistych. Metrykę tę również mierzy się w tej samej jednostce jak wartość docelowa. Dodatkową metryką, którą można wprowadzić do algorytmu regresji jest

czas wykonywania predykcji. W uczeniu maszynowym stanowi to ocenę szybkości przewidywania modelu i stanowi informacje o charakterze zbioru danych. Dąży się do otrzymania modelu, który będzie łączył precyzyjną predykcję z optymalnie szybkim czasem wykonania operacji.³⁹ Z uwagi na ograniczenia klasycznej regresji liniowej, gdy wprowadzone zmienne są ze sobą zbyt silnie skorelowane lub gdy posiadają bardziej złożony nieliniowy charakter, w profesjonalnych analizach empirycznych wykorzystuje się inne, bardziej złożone algorytmy regresji. W autorskiej analizie czynników wpływających na migracje wewnętrzne w Polsce wybrane zostały cztery różne modele uczenia maszynowego, aby badanie te pełniło również funkcję porównania zastosowania zróżnicowanych modeli, które również wykażą charakter zbioru danych. Rozszerzeniem regresji liniowej i użytej w niej metodzie najmniejszych kwadratów jest wprowadzona przez Arthura E. Hoerl i Roberta W. Kennard w 1970 roku regresja grzbietowa.⁴⁰ Metoda ta szczególnie znajduje swoje użycie w przypadku wystąpienia współliniowości predyktorów, czyli silnej korelacji cech. W modelu tym do wcześniej pokazanego równania regresji dodana została kara „ ℓ_2 ” nakładająca ograniczenia na wielkość parametrów strukturalnych modelu. W poniższym matematycznym zbiorze sumy kwadratów reszt oznacza to dodanie parametru kary „ λ ” przyjmującej wartości powyżej zera. Taki mechanizm wprowadza do estymatora obciążenie- tak zwany „bias”, lecz redukuje jego wariancję.

$$\begin{aligned}\hat{\beta}^{\text{ridge}} &= \arg \min_{\beta} \|y - X\beta\|_2^2 + n\lambda \|\beta\|_2^2 \\ &= \arg \min_{\beta} \frac{1}{n} \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2,\end{aligned}$$

Rysunek 10 Wzór regresji grzbietowej. Źródło: Zhu R. *Ridge Regression and the Bias-variance Trade-off*. 20 Sierpień 2024.

Takie zjawisko nosi nazwę kompromisu między obciążeniem a wariancją („bias-variance trade-off”) i pozwala uzyskać model o znacznie mniejszym ogólnym błędzie predykcji w porównaniu do klasycznej regresji liniowej.

Innym rozwiązaniem dla analizy regresji stanowi algorytm „Support Vector Regression” z jądrem RBF (w skrócie SVR). Jest to rozwinięcie maszyn wektorów nośnych. W odróżnieniu od poprzedniej regresji, która dąży do minimalizacji

³⁹ Help.qlik.com Ocena modeli regresji. https://help.qlik.com/pl-PL/cloud-services/Subsystems/Hub/Content/Sense_Hub/AutoML/scoring-regression.htm

⁴⁰ Zhu R. *Ridge Regression and the Bias-variance Trade-off*. 20 Sierpień 2024

wszystkich błędów, celem SVR jest znalezienie takiej funkcji, która mieści się w określonym marginesie tolerancji błędu oznaczanym, jako strefa niewrażliwości „ ϵ ” (epsilon).⁴¹ Funkcja, do której dąży musi jednocześnie zachować prostotę modelu i uniknięcie nadmiernego dopasowania wyników zwanego przeuczeniem. Model SVR sprawdza się w obsłudze zależności nieliniowych, gdy cechy w zbiorze danych nie mają wspólnych zależnych oddziaływań na siebie. Funkcja regresji SVR ma postać:

$$f(x) = w^T \phi(x) + b$$

Rysunek 11 Funkcja regresji SVR. Źródło: Sihombing D. *Comparison of algorithm performance, Random Forest Regression*. Wrzesień 2025

Symbol „ $\phi(x)$ ” oznacza nieliniową transformację cech wejściowych do przestrzeni cech o wyższym wymiarze. „ W ” stanowi wektor wag a „ b ” to parametr określający przesunięcie „hiperpłaszczyzny” regresji od początku układu współrzędnych zwany „bias”. Błędy predykcji, które wpadają wewnątrz tej strefy gdzie różnica między wartością rzeczywistą a przewidywaną jest mniejsza niż epsilon, są przez model ignorowane a ich koszt wynosi zero. Jeśli jednak bezwzględna różnica jest większa od „ ϵ ” to strata jest równa różnicy między rzeczywistą a przewidywaną wartością a „ ϵ ”. Dzięki temu model skupia się na ograniczaniu dużych błędów i ignoruje niewielkie wahania, czyniąc go bardziej odpornym na zakłócenia.⁴² W przypadku, gdy nie wszystkie punkty mogą się mieścić w przedziale strefy niewrażliwości wprowadza się zmienne pomocnicze, których odchylenia podlegają karze kontrolowanej przez parametr kosztu C powyżej i poniżej granicy epsilon. Model SVR do badania skomplikowanych i nieliniowych relacji stosuje funkcje jądrowe (z angielskiego „kernel”). Zastosowanie nieliniowego jądra RBF rozumianego, jako „Radialną Funkcję Bazową” pozwala algorytmowi zmapować dane wejściowe do przestrzeni cech o wyższym wymiarze, w której nieliniowa zależność staje się możliwa do opisanie za pomocą liniowej hiperpłaszczyzny.

⁴¹ Sihombing D. *Comparison of algorithm performance, Random Forest Regression, SVR, and Gradient Boosting in predicting academic grades based on student life style*. Wrzesień 2025

⁴² Norovsambuu M. *Investigating hyperparameter tuning for popular statistical learning algorithms*. 2023

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp \left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2 \right).$$

Rysunek 12 Wzór jądra RBF. Źródło: Norovsambuu M. *Investigating hyperparameter tuning for popular statistical learning algorithm*. 10 Lipiec 2025

Powyższy wzór jądra RBF pokazuje hiperparametr „ γ ” (gamma), który jest większy od zera. Definiuje on zachowanie algorytmu i nie wynika z danych. Mniejsza wartość „ γ ” prowadzi do uzyskania bardziej płynnej powierzchni decyzyjnej, natomiast większa wartość „ γ ” skutkuje powstaniem bardziej złożonego modelu o zachowaniu lokalnym. Gamma, zatem odpowiada za zasięg wpływu pojedynczych punktów treningowych. Model SVR ma kilka możliwych hiperparametrów lecz trzy z nich są najistotniejsze: epsilon „ ϵ ”, koszt „C” będący parametrem regularyzacji i hiperparametr gamma. Konieczne może być ich manualne dostosowanie w celu otrzymania najbardziej pożądaných wyników.

Następne rozwiązanie dla modeli regresji stanowi grupa metod zespołowych opartych na budowie zbioru niezależnych od siebie drzew decyzyjnych. Do kluczowych komponentów drzewa decyzyjnego należy jego „korzeń” (z angielskiego słowa „root”), który jest początkowym węzłem i reprezentuje cały zbiór danych. Następnie dzieli się on na węzły wewnętrzne, za które rozumie się punkty decyzyjne gdzie dokonano podzielenia danych według wybranych cech. Na podstawie spełnienia warunku, jeden węzeł rozdziela się na „gałęzie”, na których ostatecznie znajdują się końcowe węzły zwane „liśćmi”. W nich przypisywana jest etykieta klasy i wartość predykcji. Najpopularniejszym modelem z grupy modeli drzew decyzyjnych jest „Random Forest”- model lasów losowych. Algorytm ten wykorzystuje technikę agregacji zwaną „bagging”.⁴³ Technika ta polega na tym, że każde drzewo w lesie trenowane jest na innym, losowo dobranym podzbiorze danych treningowych. Co więcej, w każdym węźle drzewa algorytm wybiera najlepszy podział na podstawie jedynie losowej podgrupy dostępnych zmiennych objaśniających. Zatem główną ideą lasów losowych jest połączenie wielu drzew decyzyjnych w jeden spójny model, który jest bardziej odporny na błędy i uogólnia się lepiej niż pojedyncze drzewo. Końcowa predykcja dla danego przypadku wejściowego jest obliczana poprzez średnią z wszystkich wyników wygenerowanych przez pojedyncze drzewa w całym zbiorze drzew decyzyjnych. Dzięki takiemu zachowaniu, wszystkie mniejsze modele uczą się

na innych danych, co pozytywnie wpływa na różnorodność predykcji.⁴⁴ Zaletą modeli zespołowych jest zwiększona poprawność predykcji z uwagi na ostateczną zbiorczą decyzję nawet przy starciu z nieliniowymi zależnościami danych przy minimalnej edycji hiperparametrów. Model cechuje również odporność na zjawisko przeuczenia. Należy, lecz zaznaczyć, że algorytmy decyzyjne charakteryzują się również bardziej złożoną strukturą, która jest trudniej interpretowalna i zużywają więcej czasu i pamięci. Drugą wybraną metodą zespołową bazującą na drzewach decyzyjnych w analizie jest wzmacnianie gradientowe (Gradient Boosting), które od lasów losowych różni się sposobem procesu uczenia. Drzewa decyzyjne nie są tworzone równolegle tylko sekwencyjnie sumowanie wielu słabszych drzew decyzyjnych. Celem każdego nowo dodanego drzewa jest skorygowanie błędów popełnionych przez wszystkie poprzednie drzewa w sekwencji poprzez minimalizację funkcji straty przy użyciu gradientowej aproksymacji. Wpierw trenowane jest pierwsze drzewo decyzyjne, które uczy się na wszystkich danych i cechach. Następnie obliczane są jego prognozy i porównuje się je z wynikami rzeczywistymi. Jeśli wyniki nie są dokładne, dopasowuje się kolejny regresor do reszt. Proces ten jest powtarzany, aż błędy zostaną zredukowane do akceptowalnego poziomu lub osiągnięta zostanie maksymalna liczba drzew ustalona przez parametr.⁴⁵

x	y	$f_1(x)$	$f_2(x)$	$y - f_1(x) - f_2(x)$
x_1	10	9	0.5	0.5
x_2	11	13	1	-3
x_3	13	15	-1	-1
x_4	20	25	-2	-3
x_5	22	31	-4	-5

Rysunek 13 Tabela obrazująca sposób dodawania kolejnych drzew w modelu Gradient Boosting. Źródło: Simic M. Baeldung.com *Gradient Boosting Trees vs. Random Forests*. 28 Luty 2025. <https://www.baeldung.com/cs/gradient-boosting-trees-vs-random-forests>

Powyższy rysunek obrazuje sposób dodawania kolejnego drzewa w modelu „Gradient Boosting”. „Y” odpowiada wartości rzeczywistej zmiennej docelowej. Kolejne „f(x)” stanowią dodawane drzewa decyzyjne. Odjęcie od wyniku końcowego wartości przewidywanej z drzewa reprezentuje wyliczenie błędu predykcyjnego. Poprzez wprowadzanie poprawki przy każdym kroku, model „Gradient Boosting” jest w stanie modelować bardzo złożone wzorce i często osiąga wyższą dokładność niż model lasów losowych. Wymaga jednak precyzyjnego doboru hiperparametrów.

⁴⁴ Cognity.pl Czym są lasy losowe i jak działają? 10 Październik 2024

⁴⁵ Simic M. Baeldung.com *Gradient Boosting Trees vs. Random Forests*. 28 Luty 2025.

Kluczowy może być współczynnik uczenia (z angielskiego „learning rate”), który kontroluje wkład każdego drzewa, aby uniknąć dopasowania się modelu do ewentualnego istniejącego szumu w danych i przeuczenia. Manualnie można również dobrać liczbę korzeni, aby określić „głębokość” drzewa decyzyjnego. Opisane modele predykcyjne dla analizy regresji będą stanowić ocenę zbioru danych cech wpływających na migracje wewnętrzne oraz pomogą określić najważniejsze zmienne wpływające na docelową cechę „saldo migracji wewnętrznych na 1000 osób” dla każdego województwa z lat 2010-2024.

3.2. Istota analizy redukcji wymiaru metodą PCA

Jak już wspomniano, analiza regresji stanowi rolę potężnego narzędzia predykcyjnego do przewidzenia wyników liczbowych. Pomimo jej uniwersalności wynikającej z różnych specyfikacji wielu modeli regresyjnych, w przypadku obszernych zbiorów danych ze znaczną ilością cech je opisujących mogą wystąpić trudności z celną oceną prawdziwości wyników. Silna korelacja dużej liczby zmiennych utrudnia interpretację końcowych danych wyjściowych oraz może powodować problemy analityczne w modelowaniu. Przykładem takiego problemu jest wielokolinearność, która powoduje niewystarczające unikalne i niezależne informacje w wynikach modelu regresji.⁴⁶ Aby tego uniknąć w analizach predykcyjnych stosuje się analizę głównych składowych- w skrócie „PCA” (z angielskiego „Principal component analysis”). Stanowi jedną z najpopularniejszych metod eksploracyjnej analizy danych i redukcji ich wymiarowości. Główny cel analizy PCA stanowi sprowadzenie dużego, wyjściowego zbioru zmiennych do znacznie mniejszej liczby nowych wzajemnie nieskorelowanych cech, które nazywa się „składowymi głównymi”.⁴⁷ Nowo utworzone cechy składowe skonstruowane są w taki sposób, aby zachować maksimum oryginalnej wariancji. Za tak wysoką wariancję rozumie się jak najwięcej zachowanych oryginalnych informacji ukrytych w pierwotnych danych. Mechanizm działania analizy składowych głównych opiera się na transformacji liniowej układu współrzędnych, aby maksymalizować wariancję pierwszej współrzędnej a następnie kolejnych. Dzięki tak przekształconym ładunkom

⁴⁶ Anderson B. *Przewodnik po wielowspółliniowości i VIF w regresji*. 29 Lipiec 2023

⁴⁷ Czopek A. *ANALIZA PORÓWNAWCZA EFEKTYWNOŚCI METOD REDUKCJI ZMIENNYCH – ANALIZA SKŁADOWYCH GŁÓWNYCH I ANALIZA CZYNNIKOWA*. 2013

wygenerowanych czynników konstruowana jest nowa przestrzeń obserwacji, w której najwięcej zmienności jest wyjaśniane przez początkowe cechy. Należy pamiętać, że przed przystąpieniem do tej analizy konieczna jest standaryzacja zmiennych pierwotnych, która wyrównuje skalę cech w taki sposób, aby ich średnia wynosiła zero a wariancja wynosiła jeden. Operacja ta jest potrzebna z uwagi na możliwość wystąpienia różnych jednostek w zbiorze danych. Brak standaryzacji dla zmiennych o dużym rozrzucie zakresu wartości może spowodować fałszywy wzrostu znaczenia składowych o dużych wartościach.⁴⁸ Po przyjęciu zbioru danych po procesie standaryzacji w algorytmie PCA zachodzi do wyznaczenia macierzy kowariancji. Macierz ta opisuje jak rozproszony jest rozkład wielowymiarowy. Podczas gdy diagonalą tej macierzy zawiera wariancje składowych wektora losowego, na reszcie pozycji znajdują się kowariancje tych składowych. Wariancje poszczególnych cech mogą stanowić informacje o tym jak bardzo różnią się dwie cechy a przykładowe kowariancje informują o tym jak dwie cechy zmieniają się wobec siebie. Rysunek 14 przedstawia wzór wyjaśniający szukany wektor własny macierzy. Cecha „a” oznacza wektor kierunku na który dane są rzutowane. „A^Tx” oznacza współrzędne danych po rzutowaniu na daną linię. Ostatecznie zatem wzór wskazuje, że aby poznać wartość rozproszenia danych w danym kierunku „a” należy pomnożyć macierz kowariancji przez dany wektor z obu stron. Zatem kierunkiem maksymalizującym wariancję jest wektor własny macierzy kowariancji odpowiadający jej największej wartości własnej. Wektory własne wyznaczają kierunki nowych składowych głównych a wartości własne odpowiadają wariancji danych wzdłuż poszczególnych osi.⁴⁹

$$\begin{aligned} Var(\mathbf{a}^T \mathbf{x}) &= E(\mathbf{a}^T \mathbf{x} - E(\mathbf{a}^T \mathbf{x}))^2 = E[\mathbf{a}^T (\mathbf{x} - E\mathbf{x})(\mathbf{x} - E\mathbf{x})^T \mathbf{a}] = \\ &= \mathbf{a}^T Cov(\mathbf{x}) \mathbf{a} = \mathbf{a}^T \Sigma \mathbf{a}. \end{aligned}$$

Rysunek 14 Wzór na wariancję zmiennej losowej dla analizy PCA Źródło: Dutkowski J. *Eksploracyjna analiza danych. Metody rzutowania: analiza składowych głównych oraz skalowanie wielowymiarowe*. 22 Maj 2007

Wyznaczane są rzuty ortogonalne- inaczej prostopadłe oryginalnych zmiennych na nowe osie, które maksymalizują wariancję wektora losowego. Pierwsza składowa główna przedstawiona na rysunku 15 jest rozumiana, jako rzutowanie scentrowanego wektora losowego „x” na kierunek wyznaczony przez wektor wag „v”.

⁴⁸ Krzanowski W.J. *Principles of Multivariate Analysis: A User's Perspective* Oxford University Press, 2000

⁴⁹ Dutkowski J. *Eksploracyjna analiza danych. Metody rzutowania: analiza składowych głównych oraz skalowanie wielowymiarowe*. 22 Maj 2007

Poprzez centrowanie „x-m” przesuwany jest środek masy rozkładu do początku układu współrzędnych.

$$\mathbf{v}_1^T(\mathbf{x} - \mathbf{m}),$$

Rysunek 15 Wzór na pierwszą składową dla analizy PCA. Źródło: Dutkowski J. *Eksploracyjna analiza danych. Metody rzutowania: analiza składowych głównych oraz skalowanie wielowymiarowe*. 22 Maj 2007

Kolejne główne składowe są wyznaczane analogicznie. Należy jednak wziąć pod uwagę, aby kolejne składowe nie były skorelowane z poprzednimi. Kolejne wektory „v” mają za zadanie wyznaczanie kolejnych kierunków największej wariancji wektora losowego „x”. Składowe porządkuje się malejąco. To pierwsza składowa główna tłumaczy największą część całkowitej zmienności danych. Następna składowa, która jest prostopadła do pierwszej wyjaśnia największą część pozostałości od poprzedniej. Z racji, że to początkowe składowe wyjaśniają najwięcej wariancji w celu zredukowania wymiaru, najmniej istotne cechy powinny być odrzucone. Wybór optymalnej liczby składowej jest uzyskiwany przez szereg różnych metod cechującymi różne kryteria. W przypadku skumulowanego procentu wyjaśnionej wariancji wybierana jest najmniejsza liczba składowych, których skumulowana suma wartości własnych w stosunku do wariancji całkowitej przekracza próg, który jest z góry przyjęty przez analityka. Źródła wskazują, że ograniczenie dolne dla przekroczenia przez sumę wynoszą 75%, 80% lub 90%.⁵⁰ Kolejne kryterium zwane „wykres osypiska” polega na wizualnej analizie wykresu przedstawiającego wartości własne uporządkowane niemalejąco. Punktem odcięcia dla tego kryterium jest punkt, od którego następuje widoczny spadek wartości własnych. Dla tego przypadku nie uwzględnia się więcej czynników od tych znajdujących się po lewej stronie tego punktu. Inną metodą jest kryterium Kaisera, która postuluje pozostawienie wyłącznie tych składowych, których wartość własna wyliczona z macierzy korelacji jest wynosi więcej od wartości jeden. Ta metoda powinna być stosowana, gdy wartość zmiennych jest większa od dwudziestu. Przy mniejszej liczbie zmiennych istnieje szansa wyodrębniania zbyt małej ilości czynników głównych składowych. Po zrealizowanej redukcji z metodą PCA należy nadać nowo utworzonym cechom merytorycznego znaczenia. W tym celu wykorzystuje się ładunki czynnikowe, które

⁵⁰ Płaszczyca M. Statystyka od A do Z. *PCA - Założenia oraz kryteria wyboru*. 2013

stanowią współczynniki korelacji między poszczególnymi oryginalnymi cechami a nowo wyznaczonymi składowymi głównymi.

$$r_{X_i, Z_j} = \frac{\text{cov}(X_i, Z_j)}{s_i \sqrt{\lambda_j}} = \frac{\lambda_j a_{ij}}{s_i \sqrt{\lambda_j}} = \frac{\sqrt{\lambda_j} a_{ij}}{s_i}$$

Rysunek 16 Współczynnik korelacji- Ładunek czynnikowy. Źródło: A. Czopek ANALIZA PORÓWNAWCZA EFEKTYWNOŚCI METOD REDUKCJI ZMIENNYCH – ANALIZA SKŁADOWYCH GŁÓWNYCH I ANALIZA CZYNNIKOWA 2013

Rysunek 16 przedstawia wzór wyliczenia współczynnika korelacji- ładunku czynnikowego na podstawie macierzy kowariancji. Jest zdefiniowany jako „r”. Litera „i” to zmienna pierwotna a „j” to składowa główna. Kowariancję między zmienną a składową dzieli się przez iloczyn ich odchyłeń standardowych. Wartość własna reprezentowana przez lambdę reprezentuje wariancję składowej. Pierwiastek tej wartości stanowi zatem jej odchylenie standardowe. Ostateczna postać wzoru pokazuje, że ładunek zależy od udziału zmiennej w wektorze własnym oraz od stosunku zmienności składowej do zmienności zmiennej oryginalnej. Dla ułatwienia wizualnego rozkładu ładunków oraz pozycji samych obserwacji w nowej przestrzeni, stosuje się wykresy typu „biplot”. Analizując te wartości można ocenić wkład pierwotnej zmiennej w powstanie danej osi. Pomimo efektywności standardowej metody PCA przy występujących liniowych zależnościach cech, w przypadku występowania w zbiorze danych bardziej złożonych i nieliniowych zależności stosuje się algorytm „Kernel PCA”. Tak jak we wcześniej wspomnianym modelu regresji SVR, ta technika redukcji składowych głównych bazuje na nieliniowej funkcji jądrowej. Transformuje oryginalną dwuwymiarową przestrzeń cech do wyższego wymiaru. W tej nowej przestrzeni relacje, które w pierwotnym zbiorze nie charakteryzowały się liniowością, zyskują liniowe właściwości, co umożliwia uchwycenie przez klasyczne metody. Kluczowym elementem tego algorytmu, odróżniającym go od klasycznego podejścia PCA, jest zamiast rozwiązania problemu dla macierzy kowariancji, rozwiązanie dla znormalizowanej macierzy jądrowej „K”.

$$N\lambda \mathbf{a} = K \mathbf{a}$$

$$K = k(\mathbf{x}, \mathbf{y}) = (\Phi(\mathbf{x}), \Phi(\mathbf{y})) = \Phi(\mathbf{x})^T \Phi(\mathbf{y})$$

Rysunek 17 Wzór scentrowanej macierzy jądrowej. Źródło: Wikipedia Kernel principal component analysis. https://en.wikipedia.org/wiki/Kernel_principal_component_analysis

Rysunek 17 przedstawia wzór scentrowanej macierzy jądrowej. Proces ten sprowadza się dla liczby obserwacji „N” do wyznaczenia wartości własnych („ λ ”) oraz odpowiadających im wektorów własnych „ α ”. Symbol „ κ ” oznacza wybraną funkcję jądra, która pozwala na obliczenie iloczynu skalarnego w przestrzeni o wysokim wymiarze bez konieczności jawnego definiowania transformacji „ Φ ” („fi”). Dzięki tego sformułowania, metoda Kernel PCA umożliwia dekompozycję struktur danych o skomplikowanym kształcie, które nie mogłyby być wyodrębnione przez regularną metodę PCA. Końcowe główne składowe uzyskuje się poprzez rzutowanie zmapowanych danych na wyznaczone wektory własne w przestrzeni cech, co w praktyce realizowane jest wyłącznie poprzez operacje na funkcji jądra.⁵¹ Zastosowanie tych metod redukcji wymiarów w analizie czynników wpływających na migracje wewnętrzne może pomóc w określeniu najbardziej wpływowych cech różnicujących wyniki, województw o najwyższym stopniu atrakcyjności migracyjnej oraz wykryć specyficzne korelacje i odstępstwa zależności pomiędzy badanymi zmiennymi.

4. Analiza głównych składowych i regresji dla województw w latach 2010-2024

Dotychczasowe rozważania teoretyczne przedstawione w poprzednich rozdziałach dosadnie wskazują, że procesy migracji wewnętrznych w Polsce są zdeterminowane złożoną i wielowymiarową siecią czynników na nie wpływających. Niniejszy rozdział służy, jako przedstawienie przebiegu i wyników analizy przeprowadzonej na ułożonym zbiorze danych dotyczącej ilościowej oceny wpływu uwarunkowań demograficznych, społecznych i ekonomicznych na kształtowanie się salda migracji wewnętrznych w szesnastu polskich województwach w latach 2010–2024. Z uwagi na złożoność i wielowymiarowość zjawiska, badanie zostało przeprowadzone z wykorzystaniem języka Python w środowisku programistycznym Google Colab, opierając się na zaawansowanych technikach eksploracji danych, uczenia maszynowego oraz redukcji wielowymiarowości.

⁵¹ Hoffmann H. *Kernel PCA for Novelty Detection*. Max Planck Institute for Human Cognitive and Brain Sciences, Amalienstr. 33, 80799 Munich, Germany

Aby ukierunkować nadchodzący proces praktyczny, do niniejszej analizy sformułowano następujące pytania badawcze:

- Które czynniki wykazują największą siłę oddziaływania na saldo migracji wewnętrznych w ujęciu algorytmicznym?
- Czy zjawisko migracji wewnętrznych opiera się w większej mierze na czynnikach wypychających czy przyciągających?
- Jakie ukryte profile zróżnicowania przestrzennego polskich województw można wyodrębnić za pomocą metod redukcji wymiarów?
- Jak zastosowanie algorytmów uczenia maszynowego pozwala na poprawę jakości predykcji zjawisk demograficznych przy współliniowości danych?

Dla postawionych pytań, przedstawiono główną alternatywą dla hipotezy zerowej hipotezę badawczą zakładającą, że zależności między uwarunkowaniami regionalnymi a saldem migracji mają charakter wysoce nieliniowy w efekcie, czego algorytmy nieliniowe i zespołowe charakteryzują się wyższą precyzją prognozowania niż klasyczne modele liniowe. Jako hipotezę pomocniczą założono, że infrastruktura mieszkaniowa oraz potencjał akademicki regionów stanowią silniejsze stymulanty napływu ludności niż zmienne ekonomiczne zakładając także, że rynek pracy ma mniejszy udział w napływie ludności niż poziom rozwoju regionu wykazany przez PKB. Trzecia hipoteza wiąże się z redukcją wymiarowości i zakłada, że zastosowanie nieliniowych przekształceń przestrzeni cech pozwala zoptymalizować wymiarowość modeli predykcyjnych bez utraty ich zdolności analitycznych i przewyższa liniowy sposób redukcji wymiarów.

Badanie ma na celu wskazać zależności, jakie występują pomiędzy cechami kształtującymi roczne zmiany w międzywojewódzkich przemieszczeniach ludności. Wpierw oceniony zostanie charakter przygotowanego zbioru danych- wskazane zostaną jego zależności, korelacje między cechami i pokazane zostaną sposoby przygotowania danych do dalszej części analizy. Praca pokaże celność predykcji wybranych modeli regresyjnych w przewidywaniu wartości zmiennej docelowej będącej saldem migracji dla danego województwa w danym roku. Po wstępnym porównaniu metryk i wskazaniu istotności kolejnych cech wchodzących w skład zbioru, zastosowana zostanie także analiza składowych głównych. Narzędzie to jest sposobem na przekształcenie cech poprzez redukcję ich ilości z zachowaniem

pierwotnego znaczenia danych.⁵² Analiza sprawdzi, jaki wpływ ma taka redukcja wymiarowości na celność przewidywania modeli i wyodrębnienie kluczowych wzorców przestrzennych zachodzących na terenie Polski.

4.1. Charakterystyka zmiennych badawczych

Po wprowadzeniu teoretycznym przedstawiającym zastosowywane metody badawcze w rozdziale trzecim, może nastąpić przejście do badania empirycznego w postaci analizy statystycznej oraz uczenia maszynowego. W tym celu przygotowany został autorski zbiór danych w skrócie, który zawiera istotne cechy badawcze do następnego zrealizowania głównej analizy regresji i redukcji wymiarowości. Dane zostały zaczerpnięte ze strony Głównego Urzędu Statystycznego za pomocą udostępnionych zbiorów informacji statystycznych o Polsce w „Banku Danych Lokalnych”. Końcowa baza danych do analizy składa się z 240 obserwacji w wierszach, którym przyporządkowane są województwa na przekroju lat 2010-2024. Dla rekordu obserwacji przygotowano formę nazewnictwa składającą się z nazwy województwa i konkretnego roku badawczego- na przykład „Dolnośląskie_2010”. Dla wypisanych wierszy przygotowane zostało 15 kolumn, z których jedna stanowi zmienną zależną a pozostałych 14 pełni rolę niezależnych zmiennych objaśniających. Wybór konkretnych atrybutów został podyktowany wcześniejszym przeglądem literatury w rozdziale drugim z uwagą na opisywane czynniki, który mogą mieć wpływ na końcowy wynik zmiennej docelowej, którą stanowi „Saldo migracji wewnętrznych”. Zmienna ta określa ostateczny bilans przemieszczeń ludności między województwami i stanowi bezpośredni i ilościowy miernik atrakcyjności osadniczej i migracyjnej danego województwa w badanym roku. Aby zapewnić obiektywną porównywalność jednostek terytorialnych o zróżnicowanej wielkości i potencjale, zrezygnowano z miar absolutnych na rzecz wartości względnych wyrażonych w odsetkach poprzez częstą operację dzielenia danej na 1000 mieszkańców. Wybierając zmienne do zbioru danych, kierowano się wcześniej wymienionymi cechami opisywanymi w rozdziale „2.2.” gdzie istotne cechy podzielono na trzy kategorie na czynniki demograficzne, ekonomiczne i społeczne.

⁵² Dutkowski J. *Eksploracyjna analiza danych. Metody rzutowania: analiza składowych głównych oraz skalowanie wielowymiarowe*. 22 Maj 2007

Dla grupy czynników ekonomicznych wybrano dane, które warunkują poziom życia, nabywaną siłę przez województwo oraz perspektywy wynikające z poziomu zatrudnienia. „Produkt Krajowy Brutto na mieszkańca” podawany w złotych oraz „Przeciętne miesięczne wynagrodzenie brutto” dla czwartego kwartału w złotych to wskaźniki obrazujące ogólny poziom bogacenia się regionu, co stanowi istotną informację dla osób poszukujących maksymalizacji swoich dochodów poprzez emigrację. Kolejną cechą jest „Stopa bezrobocia rejestrowanego” podawana w procentach, która stanowi czynnik wypychający. Jest powodowana przez utrudniony dostęp do rynku pracy, który wpływa na odpływ ludności do regionów z większym widocznym popytem na pracowników. Uwzględnienie takiej cechy w zbiorze danych jest uzasadnione chęcią celnego uzasadnienia jak charakter różnych czynników- tych wpływających na odpływ i przyływ ludności mają wpływ w skomponowanych modelach predykcyjnych na zmienną docelową. Miarą mającą na celu reprezentację wpływ problemu infrastrukturalnego w danych województwach jest „Ilość oddanych mieszkań na 1000 ludności”. Odzwierciedla dostępność i zator rynku nieruchomości, będąc koniecznym powodem do napływu i osiedlania się nowych mieszkańców. Kolejne czynniki mają charakter danych demograficznych, które pokazują potencjał, dynamikę oraz stopień zaawansowania procesu starzenia się populacji w poszczególnych regionach. „Przyrost naturalny na 1000 ludności” oraz „Liczba urodzeń na 1000 ludności” to obserwacje wyznaczające dynamikę reprodukcji ludności, która jest ściśle powiązana ze strukturą wieku w Polsce. Manualnie utworzoną zmienną jest „Przeciętne trwanie życia” wyrażaną w latach, którą uzyskano poprzez podzielenie przez dwa sumę przeciętnego trwania życia mężczyzn oraz przeciętnego trwania życia kobiet z uwagi na sposób reprezentacji tych obserwacji przez GUS. Kolejne trzy parametry przedstawiają strukturę wieku populacji Polski. Są to „Liczba ludności w wieku przedprodukcyjnym na 1000 ludności”, „Liczba ludności w wieku produkcyjnym na 1000 ludności” oraz „Liczba ludności w wieku poprodukcyjnym na 1000 ludności”. Parametry te umożliwiają precyzyjne śledzenie skali obciążenia demograficznego w sprawdzeniu, która grupa dominująca grupa wiekowa ma największy wpływ na saldo migracji wewnętrznych. Ostatnią miarą w tej grupie jest „Gęstość zaludnienia”, która jest wyrażana poprzez podzielenie liczby osób na kilometr kwadratowy i wpływa na rozwój rynków lokalnych i panujące mechanizmy aglomeracyjne na terenie danego województwa. Ostatnią grupę stanowiły czynniki społeczne charakteryzujące uformowane struktury

społeczne w danym regionie. Z uwagi na zauważalne tendencje do emigracji młodzieży, do zbioru danych dodano zmienną „Liczba studentów na 10000 ludności”, która stanowi silny czynnik przyciągający gdyż część imigrantów decyduje się na pozostanie w aglomeracji po zakończeniu edukacji. Jako wskaźnik obrazujący formowanie się rodzin wśród obywateli wprowadzona została „Liczba małżeństw na 1000 ludności”, która może w analizie wskazać czy potrzeba stabilizacji ma korelację z przyszłą zwiększoną dzietnością w kraju. Ostatnią zmienną niezależną jest „Liczba cudzoziemców ze zgodą na pracę na 1000 ludności”. Wskaźnik ten pośrednio ilustruje zapotrzebowanie gospodarki na zagraniczną siłę roboczą. Jak wspomniano w rozdziale drugim, popyt ten rośnie w regionach gdzie brakuje rodzimych pracowników. Czynnik ten może podkreślać wysoki potencjał ekonomiczny danego obszaru. Poprzez zgromadzenie zbioru danych z powyżej opisanymi czternastoma predyktorami możliwe będzie ocenienie w sposób wszechstronny, które cechy w największym stopniu uzasadniały poziom migracji wewnętrznych Polaków przez czternaście lat.


4.2. Analiza eksploracyjna danych

Po skompletowaniu utworzonego zbioru danych statystycznych polskich województw, możliwe jest przejście do pierwszego etapu części badawczej. Zacznie się od przeprowadzenia eksploracyjnej analizy danych. Jej nazwa pochodzi od angielskiego sformułowania „Exploratory Data analysis”. Jej celem jest zrozumienie struktury zbioru danych. Skupia się na identyfikacji podstawowych zauważalnych trendów i ocena jakości zmiennych zanim podda się je zaimplementowanym modelom predykcyjnym.⁵³ Wszystkie etapy analizy wraz z wizualizacjami zostały w pracy przeprowadzone w środowisku programistycznym „Google Colaboratory”, które wykorzystuje język python i główne biblioteki „pandas”, „numpy”, „seaborn” i „matplotlib”. Cechy charakteryzujące PKB, przeciętne trwanie życia, liczbę studentów docelowe saldo migracji domyślnie przyjęły typ „int” reprezentujący liczby całkowite bez części dziesiętnej, podczas gdy cała reszta cech numerycznych przyjęła typ

⁵³ Geeksforgeeks.org. *EDA- Exploratory Data Analysis in Python*. 30 Kwiecień 2026.
<https://www.geeksforgeeks.org/data-analysis/exploratory-data-analysis-in-python/>

„float” obejmujący liczby z częścią dziesiętną. Po wczytaniu danych z pliku „csv”, wartości w zbiorze są separowane poprzez średnik. W zbiorze danych nie stwierdzono braków, dzięki czemu niewymagane jest zastosowanie technik imputacji danych. Następnie skupiono się na wyznaczeniu statystyk opisowych poprzez prostą komendę „describe()” z biblioteki pandas. Główny miernik zamożności regionów „Produkt Krajowy Brutto na mieszkańca” charakteryzuje się rozproszeniem. Średnia wartość PKB dla lat 2010-2024 wyniosła 52418 złotych a odchylenie standardowe przekracza 21950. Zauważalny jest znaczny odstęp między wartością minimalną wynoszącą 25875 złotych dla województwa lubelskiego z 2010 roku a maksymalną wartością wynoszącą 195100 złotych dla mazowieckiego z 2024 roku. Obserwacje te wskazują na głębokie dysproporcje w rozwoju gospodarczym województw Polski. Podobną tendencją w mniejszym stopniu można określić zmienną „Przeciętne miesięczne wynagrodzenie brutto (czwarty kwartał)”. Jej średnia wyniosła 5007 złotych a odchylenie standardowe 1570. Jej wartość maksymalna wynosząca 10119 złotych ponownie dla województwa mazowieckiego jest ponad trzykrotnie wyższa od minimum w województwie podkarpackim z 2010 roku. Średnia stopy rejestrowanego bezrobocia wyrażonego w procentach wyniosła 9,29. Jej minimum zaobserwowano w województwie wielkopolskim w 2019 roku i wynosi 2,8%. Wynik maksymalnej stopy bezrobocia wynoszący 21,6%, osiąga województwo warmińsko-mazurskie w 2013 roku. Po głębszymu przyjrzeniu się wszystkim obserwacjom zaobserwowano, że lata 2012 i 2013 osiągały rekordowe wartości stopy bezrobocia w Polsce dla wszystkich województw. Istotną informacją w przypadku cech demograficznych jest ujemny średni przyrost naturalny o wyniku -1,67. Dodatkowo określono, że negatywne wartości dla tej metryki przyjęło aż 173 obserwacji. Potwierdza to ogólnokrajowe trendy depopulacyjne w Polsce. Jego najwyższą wartość zanotowano w województwie pomorskim w 2010 roku wynoszącą 3,33. Najniższy przyrost naturalny zauważono w województwie świętokrzyskim w 2021 roku (-8,12). Analiza struktury wieku wskazuje, że średnio na 1000 mieszkańców województw przypada więcej osób w wieku poprodukcyjnym (205,48) niż przedprodukcyjnym (180,83). Województwem o największej ilości osób w wieku emerytalnym jest województwo świętokrzyskie a największa ilość osób niepełnoletnich na 1000 osób zaobserwowana została w województwie podkarpackim w 2010 roku i wynosiła 202,55. Dominuje jednak grupa ludności w wieku produkcyjnym gdyż ich średnia wynosi 613,68. Najwięcej osób zdolnych do pracy obserwuje się w województwie


lubuskim w 2010 roku (657) a najmniej łódzkie w 2024 (568). Zmienną o największej dynamice wzrostu w ostatnich latach są jest „Zezwolenia na pracę dla cudzoziemców na 1000 ludności” gdzie wartość maksymalna „21,3” wielokrotnie przewyższa średnią wynoszącą 5,32. Odzwierciedla to zmiany na polskim rynku pracy po 2017 roku, od którego nastąpił widoczny wzrost wartości tej zmiennej. Rekordowe wartości tej metryki na przestrzeni lat obserwuje się w województwie mazowieckim. Obserwuje się porównywalne przeciętne trwanie życia we wszystkich województwach Polski. Średnia liczba zmiennej „Mieszkania oddane do użytkowania na 1000 ludności” wynosi 4,39. Jej maksimum wynosi 9,2 i zaobserwowano je w województwie pomorskim w 2021 roku. Jej minimum widoczne jest w województwie opolskim w 2011 roku (1,7). Średnia liczba urodzeń na 1000 ludności w latach 2010-2024 wynosi 9,11 a średnia liczba małżeństw 4,67. Kluczowa zmienna modelu- saldo migracji wewnętrznych posiada średnią bliską zero. Jej wartości wahają się od -6495 do 15777 osób. Wysokie odchylenie standardowe równie 4074,34 wskazuje na istnienie silnych regionów przyciągających imigrantów i regionów dotkniętym znacznym odpływem ludności. Ujemną wartość salda migracji wewnętrznych przyjmuje aż 165 województw na przestrzeni lat. Obserwuje się wysoką dysproporcję między dużymi dodatnimi wartościami w województwie mazowieckim a resztą regionów.



Rysunek 18 Macierz korelacji zmiennych- część 1. Źródło: Opracowanie własne

Kolejną istotną częścią analizy eksploracyjnej jest zbadanie współzależności liniowych pomiędzy zmiennymi objaśniającymi zmienną zależną i wykrycie współliniowości między cechami ją opisującą. Na rysunku 18 i 19 przedstawiono macierz korelacji Pearsona dla cech, których wartość bezwzględna współczynnika „r”


przekracza 0,1. Wartości bliskie zero nie są oznaczone. Najważniejsza w tej analizie jest zbadanie wpływu korelacji wszystkich cech ze zmienną docelową. Na rysunku 19 w ostatnim rzędzie zauważyć można, jakie cechy miały największe korelacje z wynikami salda migracji wewnętrznych. Wartość „r” powyżej 0,51 zyskały cechy „Mieszkania oddane do użytkowania na 1000 ludności”, „Liczba studentów na 10000 ludności” oraz „Produkt Krajowy Brutto na mieszkańca”. Sugeruje to, że rozwój infrastruktury, ośrodków akademickich i największe zyski ekonomiczne w największym stopniu wpływają na kształtowanie salda migracji wewnętrznych.



Rysunek 19 Macierz korelacji zmiennych- część 2. Źródło: Opracowanie własne

Poza wysoko dodatnimi relacjami ze zmienną docelową, zauważalne są również umiarkowane korelacje z czynnikami demograficznymi, takimi jak liczba ludności w wieku przedprodukcyjnym, która wynosi 0,39 oraz liczba urodzeń wynosząca 0,38. Z kolei stopa bezrobocia wykazuje spodziewaną korelację ujemną. Świadczy to, że wzrost niepewności na rynku pracy jest skorelowany z niższym saldem migracji. Poza relacjami ze zmienną docelową, macierz korelacji pokazuje silne związki pomiędzy niektórymi predyktorami, co może mieć znaczenie w przyszłych etapach modelowania predykcji. Jako znaczące korelacje warto wymienić wysoko dodatni związek między PKB a przeciętnymi wynagrodzeniami w czwartym kwartale równy 0,89 oraz negatywną relację PKB ze stopą bezrobocia. Silna ujemna korelacja widoczna jest dla liczby ludności w wieku produkcyjnym a poprodukcyjnym (-0,92). Czynniki demograficzne łączy wysoka współzależność. Przyrost naturalny i liczba urodzeń posiadają wartość „r” równą 0,86. Liczba urodzeń logicznie koreluje z liczbą


małżeństw (0,81). Zjawisko występowania silnych korelacji wskazuje na nadmiarowość informacji wynikającej z multikolinearności cech. Taka obserwacja stanowi roztropne uzasadnienie do przyszłej redukcji wymiarowości zmiennych. W kolejnym etapie, aby poddać zmienne dokładniejszej wizualizacji, dzięki bibliotece „matplotlib” utworzono histogramy za pomocą, których można zweryfikować kształt rozkładów dla każdej zmiennej. Pozwala to na ocenę skupienia obserwacji oraz identyfikację ewentualnie występującej asymetrii. Na rysunku 20 zobaczyć można cztery histogramy badanych cech.



Rysunek 20 Histogramy cech- część 1. Źródło: Opracowanie własne

Histogram prezentujący rozkład PKB na mieszkańca wykazuje silną asymetrię prawostronną poprzez obserwowalne skupienie największej obserwacji w przedziale 25000 do 75000 złotych. Wskazuje to również na wartości odstające dla województwa mazowieckiego w latach 2021-2024. Histogram stopy bezrobocia również wykazuje asymetrię prawostronną, choć w mniejszym stopniu. Największa liczba obserwacji przypada na wartości niskie i umiarkowane w stosunku dla całości. W przypadku cechy określającej liczbę ludności w wieku produkcyjnym na 1000 ludności, rozkład posiada dwa główne szczytowe zbiory wartości. Skupienia określają okolice 590 osób i okolice 635 osób na 1000 mieszkańców. W przypadku


osób w wieku przedprodukcyjnym, dane są jak dotąd najbardziej rozproszone. Żaden dotąd kształt histogramów nie wykazuje normalności rozkładów.



Rysunek 21 Histogramy cech- część 2. Źródło: Opracowanie własne

Rysunek 21 prezentuje kolejne histogramy cech. Wykres przeciętnego miesięcznego wynagrodzenia w czwartym kwartale wykazuje asymetrię prawostronną. Widoczna jest dominacja wynagrodzeń o niższych wartościach niż średnia. Rozkład liczby urodzeń jak dotąd najbardziej przypomina kształt rozkładu normalnego. Zauważalna jest jednak nieregularność spowodowana mniejszą asymetrią lewostronną. Podobny kształt zbliżony do rozkładu normalnego prezentuje liczba ludności w wieku poprodukcyjnym z widocznymi trzema szczytami. Szerokość tego wykresu świadczy o niejednorodności procesu starzenia się na przestrzeni czternastu lat we wszystkich województwach. Ekstremalną symetrię prawostronną wykazuje wykres zezwoleń na pracę dla cudzoziemców. Świadczy to o niskich przypadkach występowania tego zjawiska w początkowych latach badanego przedziału czasowego. Kolejny rysunek numer 22 pokazuje silną asymetrię prawostronną gęstości zaludnienia. Odizolowane wysokie wartości identyfikują regiony o skrajnie wysokim stopniu urbanizacji. Taka struktura może sugerować, że gęstość zaludnienia jest cechą silnie różnicującą regiony na typy gdzie dominują obszary miejskie lub wiejskie. Przyrost naturalny posiada rozkład z zauważalną asymetrią lewostronną poprzez dominację wartości


ujemnych. Z uwagi na niewielki zmienny wachlarz wartości dla przeciętnego trwania życia, rozkład wykazuje charakter dyskretny z dwoma głównymi szczytami lat przetrwania. Rozkład liczby małżeństw wyróżnia istnienie trzech najwyższych wartości na tle pozostałych. Wyniki świadczą o zauważalnym, lecz nie ekstremalnym zróżnicowaniu skłonności do zawierania związków małżeńskich w badanej próbie.



Rysunek 22 Histogramy cech- część 3. Źródło: Opracowanie własne

Na rysunku 23 przedstawione zostały trzy ostatnie histogramy zmiennych w zbiorze danych. Rozkład liczby studentów charakteryzuje rozproszenie wartości oraz wiele przedziałów wartości szczytowych tworzących cztery wyraźne skupienia w przedziale od 200 do 350 studentów. Powoduje to prawostronne wydłużenie rozkładu wyróżniające nieliczne obserwacje z ponadprzeciętną liczbą studentów na 10000 osób w województwach. Wykres mieszkań oddanych do użytkowania wykazuje asymetrię prawostronną. Wykazuje to, zatem dominujący przedział od dwóch do pięciu obszarów zamieszkania dla nowych lokatorów. W końcu poddać analizie można histogram zmiennej docelowej. Rozkład salda migracji wewnętrznych cechuje niesymetryczność spowodowana podziałem na dominujące ujemne wartości i mniejsze oraz odstające dodatnie przypadki. Po przyjrzeniu się kształtom rozkładów dojść można do wniosku o niesymetrycznym i przez to braku ich normalności. Jednak, aby mieć pewność do odrzucenia hipotezy zerowej o normalności

rozkładów, badane zmienne poddano trzem testom normalności. Odrzucenie hipotezy zerowej oznacza odbieganie rozkładów od wykresu rozkładu normalnego lub inaczej krzywej Gaussa. Następuje to, kiedy wynik testu osiągnie wartość poniżej założonego poziomu istotności statystycznej zazwyczaj ustalonego jako $p < 0,05$.⁵⁴



Rysunek 23 Histogramy cech- część 4. Źródło: Opracowanie własne

„Test Shapiro-Wilka” należy do jednej z najpopularniejszych metod testów normalności. Wykazuje dużą zdolność do wykrywania rozkładu normalnego. Jego mechanizm polega na porównaniu odchyłeń standardowych w próbie z wyznaczonym odchyleniem na podstawie wykresu kwantyl-kwantyl. Kiedy stosunek pomiędzy tymi miarami będzie zbliżony do jedności, świadczyć to będzie o obecności rozkładu Gaussa.⁵⁵ Test ten jest zoptymalizowany dla mniejszych prób. Kolejny test badający ocenę normalności rozkładu nosi nazwę „test D’Agostino-Pearsona”. Algorytm tego testu wyznacza skośność, która mierzy asymetrię oraz kurtozę mierzącą stopień spłaszczenia rozkładu i występowania wartości odstających. Test wykazuje normalność rozkładu, gdy wartości tych dwóch statystyk opisowych są zbliżone do zera. Trzeci „test Andersona-Darlinga” za to opiera się na dystrybucji badanej zmiennej, za którą rozumie się funkcję określającą prawdopodobieństwo o

⁵⁴ Białek J. Gadecki H. Szacowanie współczynników w teście normalności Shapiro-Wilka. Maj 2009

⁵⁵ Graphpad.com *Choosing a normality test*.


https://www.graphpad.com/guides/prism/latest/statistics/stat_choosing_a_normality_test.htm

tym, że zmienna przyjmie wartość mniejszą lub równą konkretnej liczbie. Test ten weryfikuje hipotezę zerową poprzez ocenę różnic między skumulowanym rozkładem z zebranych danych a idealnym skumulowanym rozkładem wynikającym z definicji rozkładu Gaussa. W przypadku testu Andersona-Darlinga zamiast pojedynczej wartości „p” wyznacza się statystykę testową, którą następnie porównuje się z szeregiem wartości krytycznych przypisanych do konkretnych poziomów istotności. Szeregi te zazwyczaj przyjmują wartość 1%, 5%, 10% czy 15%. Hipotezę zerową o normalności rozkładu uznaje się za prawdziwą, gdy obliczona statystyka jest niższa od wartości krytycznej dla danego poziomu. W przypadku własnej analizy, wykorzystano próg 5% z wartością krytyczną równą 0,774⁵⁶. Procedura przeprowadzenia poddania wszystkich cechom trzem wybranym testom dostarczyła niemal jednolitych dowodów na brak normalności rozkładów. Dla wszystkich czterdziestu pięciu testów jedynie dwa z nich wykazały wynik dowodzący normalności dwóch zbiorów. Dla liczby ludności w wieku poprodukcyjnym na 1000 ludności test Andersona-Darlinga wykazał normalność podczas gdy testy Shapiro-Wilka i D’Agostino-Pearsona wykazały przeciwnie. Drugi wynik normalności rozkładu otrzymała zmienna przeciętnego trwania życia jedynie przez test D’Agostino-Pearsona. Pomimo dwóch niejednoznacznych przypadków, na potrzeby analizy odrzucono hipotezę o normalności rozkładów dla wszystkich zmiennych. Z powodu braku normalności rozkładów danych, różnorodnych jednostek i chęci zachowania wszystkich obserwacji, aby uniknąć niewystarczającej wielkości próby w przypadku usunięcia odstających obserwacji, aby przystąpić do etapu modelowania regresji i redukcji wymiaru, dane zostały poddane standaryzacji. W jej wyniku zmienne zostają przekształcone do takiej postaci, aby uzyskać średnią wartość oczekiwaną równą zero i odchylenie standardowe równe jeden. Aby wizualizować strukturę cech po standaryzacji, skonstruowano wykres „pudełkowy”, którego nazwa pochodzi z angielskiego „Box plot”. Z uwagi na dominację wysokich wartości dla obserwacji dotyczących województwa mazowieckiego i kilku przypadków dla innych województw, nadal zauważyć można ich odstępstwa dla cech takich jak „saldo migracji wewnętrznych”, „PKB” i „gęstość zaludnienia”. Z uwagi na obniżony poziom liczby urodzeń w latach 2023-2024 dla wszystkich województw. Większość cech demograficznych charakteryzuje podobna struktura bez wartości odstających. Można

⁵⁶ SciPy.org. *Anderson*. 2008

<https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.anderson.html>

zatem wstępnie założyć, że pomimo zróżnicowania procesów demograficznych mają one charakter bardziej systemowy i obejmują wszystkie województwa w sposób bardziej równomierny niż czynniki finansowe.



Rysunek 24 Wykres Boxplot zestandaryzowanych cech. Źródło: Opracowanie własne

4.3. Analiza regresji przed redukcją wymiarów

Po przyjrzeniu się statystykom opisowym i rozkładom badanych cech, dokonano standaryzacji danych, której zrealizowanie pozwala na przejście do etapu oceny wybranych modeli regresji w odniesieniu do pełnego zestawu danych. Analiza ta stanowi pierwszą próbę uczenia maszynowego modeli, aby ocenić ich trafność predykcji na bazowych danych po standaryzacji. Wyniki będą stanowiły punkt odniesienia do późniejszej analizy regresji po redukcji wymiarów metodą PCA. Wpierw w kodzie środowiska wykorzystano metodę „train_test_split()” z biblioteki „scikit-learn”. Służy ona do podzielenia badanego zbioru danych na podzbiór treningowy służący do uczenia modelu i testowy, na którym sprawdza się celność przewidywania testowanego modelu. Dane zostały podzielone w proporcji 70% na podzbiór treningowy i 30% na podzbiór testowy. Do przeprowadzenia analizy regresji wykorzystano cztery modele opisane w rozdziale 3.1. „Istota analizy regresji”. Wybrano zatem algorytmy „Ridge Regression” jako przykład modelu regresji liniowej,

„SVR (RBF)” jako model regresji wektorów nośnych z nieliniowym jądrem radialnym oraz dwa modele drzewiaste- „Random Forest” i „Gradient Boosting”. W pierwszej próbie uczenia modeli, w zaimportowanych regresorach nie dostosowywano hiperparametrów i wykorzystano ich bazowe formy. Pomimo pozytywnych wyników metryk oceniających trafność predykcji dla trzech wybranych modeli, regresor „SVR” z jądrem „RBF” generował ujemne wartości współczynnika determinacji „R²” co wskazywało na niezdolność modelu do poprawnej generalizacji wiedzy. Aby otrzymać trafne wyniki, przeprowadzono procedurę optymalizacji hiperparametrów za pomocą metody „GridSearch” z biblioteki „Scikit-learn”. Umożliwia ona przeprowadzenia pętli, która zastosuje wszystkie możliwe opcje optymalizacji danych metryk po ustaleniu przez użytkownika ich zakresów.

```
#Dobranie parametrów z Gridsearch dla SVR
svr_pipeline = Pipeline([
    ('preprocessing', preprocessor),
    ('regressor', SVR(kernel='rbf'))
])

param_grid = {
    'regressor__C': [0.1, 1, 10, 100, 1000],
    'regressor__gamma': ['scale', 'auto', 0.01, 0.1, 1],
    'regressor__epsilon': [0.1, 0.2, 0.5, 1.0]
}

grid_search = GridSearchCV(
    svr_pipeline,
    param_grid,
    cv=5,
    scoring='r2',
    n_jobs=-1,
    verbose=1
)

grid_search.fit(X_train, y_train)

#Wyciągnięcie najlepszego modelu
best_svr = grid_search.best_estimator_
print(f"\nNajlepsze parametry: {grid_search.best_params_}")
```

Rysunek 25 Kod doboru hiperparametrów z metodą GridSearch Źródło: Opracowanie własne

Jak widać na rysunku 25, proponowane wartości hiperparametrów zostały zawarte w słowniku, aby następnie przekazać je do metody „grid_search”. Wyróżnione hiperparametry modelu SVR to metryka „C” kontrolująca kompromis między błędem a gładkością funkcji, gamma określająca zasięg wpływu pojedynczego punktu treningowego oraz epsilon określający ramę błędów, w której kary nie są naliczane. Po zakończeniu algorytmu, jako najtrafniejsze metryki do optymalizacji współczynnika determinacji wybrany został parametr regularyzacji (C) równy 1000, co oznacza zwiększenie tolerancji na błędy treningowe, aby osiągnąć trafniejszą płaszczyznę


decyzyjną. Poza tym wybrany został epsilon równy 0,1 jako szerokość marginesu błędu i gamma równa „auto”, co oznacza automatyczny dobór zasięgu wpływu pojedynczego przykładu treningowego.

	Metoda	Train R ²	Test R ²	Train RMSE	Test RMSE	Train MAE	Test MAE	Cross-val R ² mean	Czas trenowania [s]
0	Ridge Regression	0.805150	0.696790	1817.688020	2168.001014	1423.138438	1559.560391	0.740982	0.027411
1	SVR (RBF)	0.759230	0.703961	2020.552890	2142.209277	1019.603383	1164.627975	0.683486	0.008375
2	Random Forest	0.986741	0.913253	474.150981	1159.617543	265.319464	736.588056	0.897583	0.858110
3	Gradient Boosting	0.997090	0.918950	222.120305	1120.896818	175.117797	772.466544	0.886637	0.190417

Rysunek 26 Wyniki modeli regresji przed redukcją wymiarowości. Źródło: Opracowanie własne

Następnie wykonano kod za pomocą, którego wczytano wybrane modele regresyjne i zaczęto ich trenowanie. Utworzono listę, w której znalazły się metryki regresji zarówno dla podzbioru treningowego jak i testowego. Oprócz współczynnika determinacji, błędu średniokwadratowego i jego pierwiastku, dodano również metrykę „Cross-val R²”, za którą rozumie się walidację krzyżową będącą średnią wyników R² z przeprowadzonych testów oraz czas, w jakim algorytm uczenia maszynowego przeprowadził trening. Aby porównać wyniki tej próby utworzono widoczną na rysunku 26 tabelę z wszystkimi wymienionymi metrykami dla wszystkich użytych modeli predykcyjnych magazynującej wyniki predykcji zmiennej docelowej „Saldo migracji wewnętrznych”. Model regresji grzbietowej i SVR wykazują porównywalną umiarkowaną zdolność predykcji na zbiorze testowym, osiągając w przybliżeniu współczynnik determinacji równy kolejno 0,697 oraz 0,704. W przypadku współczynnika R² na zbiorze treningowym i walidacji krzyżowej, wyniki są bardziej zróżnicowane, lecz wciąż w niewielkim stopniu. Model SVR, zatem osiągnął najmniejszą trafność predykcyjną dla tego zbioru danych. Modele Random Forest i Gradient Boosting osiągnęły za to bardzo wysoką precyzję predykcji. Regresor Gradient Boosting zyskał najwyższy współczynnik determinacji na zbiorze testowym równy w przybliżeniu 0,919 oraz najniższy błąd średniokwadratowy równy 1120,90. Model Random Forest również osiągnął zadowalające wyniki w tych samych metrykach z wyróżnieniem dla walidacji krzyżowej, gdzie okazał się posiadać najbardziej stabilne średnie wyniki równe 0,897. Świadczy to o tym, że algorytmy zespołowe znacznie lepiej radzą sobie ze zbiorami danych posiadającymi nieliniowe interakcje między cechami oraz wartościami, które odstają od reszty obserwacji. Niskie wartości dla błędów średniokwadratowych wskazują na dobrą precyzję w przywidywaniu salda migracji wewnętrznych na podstawie dostarczonych zmiennych.

Warto jednak zwrócić uwagę na czas trenowania modeli. Złożoność algorytmu modeli drzewiastych łączy się z wymogiem większego nakładu obliczeniowego i dłuższego czasu trenowania. Najdłuższy czas wykonania potrzebował algorytm Random Forest wynoszący 0,858 sekund podczas gdy model SVR wykonał operację w 0,008 sekund. Z racji niewielkiej ilości obserwacji w zbiorze danych, różnica w czasie trenowania może nie być bardzo znacząca, lecz wskazuje to na rosnący stopień skomplikowania algorytmu od prostego modelu jądrowego do bardziej zaawansowanego modelu struktur zespołowych. W przypadku większej próby, za bardziej optymalny model można by uznać regresję grzbietową lub SVR od modeli drzew decyzyjnych. Po przeanalizowaniu i zaakceptowaniu wyników precyzji




Rysunek 27 Wykres Permutation Feature Importance dla modelu Ridge regression Źródło: Opracowanie własne

predykcji przez modele, przystąpiono do zastosowania metody „Permutation Feature Importance” mającej na celu określenia wpływu każdej cechy zbioru danych na wynik redukcji. Metoda ta polega na losowym przemieszczeniu wartości pojedynczej cechy w zbiorze danych i rejestrowaniu wynikającego z tego spadku dokładności predykcyjnej modelu.⁵⁷ Główna idea tego podejścia opiera się na założeniu o spadku skuteczności algorytmu w przypadku permutowanej cechy, która silnie determinuje

⁵⁷ Young N. T. Caballero M. D. *Predictive and explanatory models might miss informative features in educational* . data 26 Marzec 2021


wynik i niewielkim wpływie na współczynnik determinacji w przypadku zaburzenia cechy o małym znaczeniu predykcyjnym. Istotność zmiennej, zatem wyznacza się poprzez obliczenie empirycznej różnicy między średnim błędem modelu na danych po permutacji a wynikiem na danych oryginalnych. Jako wizualizowaną na wykresach miarę porównującą istotność permutowanych cech ustalony został średni spadek współczynnika determinacji R^2 . Rysunek 27 przedstawia pierwszy wykres istotności permutacyjnej dla modelu Ridge Regression.



Rysunek 28 Wykres Permutation Feature Importance dla modelu SVR Źródło: Opracowanie własne

Kluczową skrajną dominantą okazała się być zmienna „Produkt Krajowy Brutto na mieszkańca”. Liczba urodzeń również posiada znaczący wkład w predykcji modelu. Ludność w wieku przedprodukcyjnym i poprodukcyjnym okazały się być istotniejszymi czynnikami demograficznymi. Obserwacje te wskazują na dominację ekonomicznego czynnika PKB województwa, jako najstabilniejszą cechę wpływającą na wartości salda migracji wewnętrznych. Przyrost naturalny i zezwolenia na pracę dla cudzoziemców są dla modelu Ridge Regression najmniej istotne w predykcji wartości zmiennej docelowej. W przypadku modelu regresji SVR z jądrem RBF, wykres rozbieżności cech charakteryzuje bardziej zrównoważony rozkład wag zmiennych. Dominującymi cechami mającymi wpływ na predykcję tego modelu


nieliniowego posiadają „Mieszkania oddane do użytkowania”, „Liczba studentów” i „Produkt Krajowy Brutto”. Model ten, zatem wskazuje na powiązanie między infrastrukturą mieszkaniową a rynkiem akademickim badanych województw. Za najmniej znaczące cechy w tym przypadku zostały uznane „Liczba małżeństw oraz „Przeciętne trwanie życia”, co może być zbyt niskim zróżnicowaniem wartości tych cech w zbiorze danych.



Rysunek 29 Wykres Permutation Feature Importance dla modelu Random Forest Źródło: Opracowanie własne

Rysunki 29 i 30 przedstawiają wykresy istotności permutacyjnej dla modeli drzewiastych Random Forest i Gradient Boosting. Na podstawie danych z nich odczytanych można dojść do wniosku, że dla tych modeli największą istotność w predykcji zmiennej docelowej posiadają cechy charakterystyczne dla województw bogatych w duże ośrodki miejskie, które przyciągają ludność migracyjną. Zarówno dla Random Forest jak i Gradient Boosting najistotniejszą miarą okazała się być liczba studentów. Umiarkowanie istotne okazały się być również produkt krajowy brutto i liczba mieszkań oddanych do użytkowania. Najbardziej widoczną różnicą w strukturze rozłożenia istotności cech pomiędzy sprawdzanymi dwoma modelami predykcyjnymi jest zwiększony nacisk na wysokość miernika aktywności gospodarczej danego regionu. Podsumowując wyniki dla wszystkich modeli, można

dojść do wniosku, że potencjał akademicki jest najsilniejszym predykatem w przeprowadzonej analizie regresji a migracje wewnętrzne w Polsce mają w dużej mierze charakter edukacyjny lub wczesno-zawodowy.



Rysunek 30 Wykres Permutation Feature Importance dla modelu Gradient Boosting Źródło: Opracowanie własne

Siła nabywcza wyrażana przez PKB pozostaje jednak również fundamentalnym czynnikiem ekonomicznym we wszystkich użytych modelach. Potwierdza to klasyczne teorie o przepływie ludności z regionów peryferyjnych do tych bardziej zamożnych. Model SVR wskazuje również na istotność dostępności nowych zasobów mieszkaniowych, jako warunku koniecznego w realizacji wewnętrznych migracyjnych planów. Zastosowane algorytmy wskazują, jako priorytet czynniki przyciągające i osiągające wyższe wartości w zbiorze danych w stosunku do mniej rozwiniętych województw. Metoda „Permutation Feature Importance” przedstawiła rankingi ważności badanych cech w zastosowanych predykcjach modeli. Jednak, aby dokładniej zrozumieć, w jaki sposób wartości tych cech przekładają się na wzrost lub spadek prognozowanego salda migracji, wykorzystano technikę wyjaśnianej sztucznej inteligencji (XAI). Metody XAI pozwalają zrozumieć i interpretować logikę procesów decyzyjnych zachodzących wewnątrz modelu bez utraty jego wysokiej

precyzji.⁵⁸ Do analizy zmiennych wpływających na saldo migracji wewnętrznych zastosowano metodę „SHAP” (od „Shapley Additive Explanations”) zaproponowaną w 2017 roku przez S. Lundberga i S. Lee. Algorytm tej metody wywodzi się z koncepcji wartości Shapleya, która jest zakorzeniona w koalicyjnej teorii gier. Jako główne założenie tego podejścia uznaje się sprawiedliwy podział predykcji pomiędzy poszczególnymi cechami w zbiorze danych. W przeciwieństwie do wcześniej użytej metody Permutation Feature Importance, która ocenia globalny wpływ zmiennych na podstawie pogorszenia jakości modelu, SHAP wylicza addytywny wkład każdej cechy z osobna dla każdej pojedynczej obserwacji w zbiorze.⁵⁹ Wartości SHAP przybierają postać dodatnią lub ujemną i sumują się do różnicy pomiędzy prognozą dla konkretnej instancji a średnią prognozą dla całego zbioru. W kontekście przeprowadzanego badania oznacza to, że dodatnia wartość SHAP przypisana do danej cechy wskazuje na to jak ona przyczynia się do wzrostu prognozowanego salda migracji, podczas gdy wartość ujemna pokazuje jak dana cecha pogarsza wynik predykcji, stymulując przewidywanie spadku salda migracji wewnętrznych. Z uwagi na życie czterech modeli regresyjnych o różnej architekturze, dla każdej z nich technika SHAP wykorzystuje inne dedykowane estymatory, które są optymalizowane dla danego modelu uczenia maszynowego. Dla modelu regresji grzbietowej wykorzystano estymator liniowy „Linear Explainer”, dla modelu SVR zastosowano uniwersalny algorytm „Kernel Explainer”, który szacuje udział cech poprzez ich powtarzalne próbkowanie wektorów. Do wyjaśnienia predykcji modeli drzewiastych Random Forest i Gradient Boosting wykorzystano algorytm „Tree Explainer”, który wykorzystuje ścieżki badanych drzew decyzyjnych. Analiza uzyskanych w ten sposób lokalnych wartości SHAP umożliwia przedstawienie precyzyjnych wniosków o wpływie poszczególnych cech demograficznych, społecznych i ekonomicznych na kształtowanie się salda migracji w polskich województwach.

⁵⁸ Lota S. *Analiza wyjaśnialności algorytmów uczenia maszynowego w zadaniach detekcji ataków w programowalnych sieciach komputerowych*. Łódź 2025.

⁵⁹ Lin J. Fukuyama J. *A comparative analysis of machine learning models in SHAP analysis* str. 2. 8 Kwiecień 2026.


```

shap_results = {}
X_sample = X_test

for name, model in models.items():
    curr_pipeline = Pipeline([
        ('preprocessing', preprocessor),
        ('regressor', model)
    ])

    curr_pipeline.fit(X_train, y_train)
    X_sample_transformed = preprocessor.transform(X_sample)
    X_sample_df = pd.DataFrame(X_sample_transformed, columns=num_features)

    if name in ['Random Forest', 'Gradient Boosting']:
        explainer = shap.TreeExplainer(curr_pipeline.named_steps['regressor'])
        shap_values = explainer.shap_values(X_sample_df)
    elif name == 'Ridge Regression':
        explainer = shap.LinearExplainer(curr_pipeline.named_steps['regressor'], X_train)
        shap_values = explainer.shap_values(X_sample_df)
    else:
        X_train_summary = shap.kmeans(preprocessor.transform(X_train), 5)
        explainer = shap.KernelExplainer(curr_pipeline.named_steps['regressor'].predict, X_train_summary)
        shap_values = explainer.shap_values(X_sample_df)


    shap_results[name] = {
        'explainer': explainer,
        'shap_values': shap_values,
        'X_sample': X_sample_df
    }

```

Rysunek 31 Kod obsługujący obliczenie wartości SHAP. Źródło: Opracowanie własne


Sposób obliczenia wartości SHAP dla kolejnych modeli został przedstawiony na rysunku 31. Jak można na nim dostrzec, po zaimportowaniu biblioteki SHAP, zaimplementowany algorytm rozpoczyna iterację po słowniku „models”, w którym zawarte są kolejne użyte modele regresyjne. Następnie dochodzi do transformacji danych testowych „X_sample” na postać pasującą do formatu wymaganego przez algorytmy SHAP. W zależności od nazwy modelu wybierany jest pasujący algorytm, który najszybciej znajdzie dla nich pożądane wartości. Dla modelu SVR zastosowano przyspieszenie wyliczenia wartości SHAP dla próbek testowych poprzez użycie metody „shap.kmeans” grupującej dane treningowe do pięciu reprezentatywnych punktów. Wyniki dla są zapisywane do słownika „shap_results”. Następnie utworzone zostały wykresy „summary plot”, które pokazują, w jaki sposób badane cechy wpływają na wynik predykcji salda migracji. Wyższy wpływ na wynik reprezentują barwy czerwone a niższy wpływ reprezentują barwy niebieskie. Dla przykładu, rysunek 32 obrazuje istotność cech od tych najbardziej znaczących na szczycie. Najważniejsza zmienna dotycząca produktu krajowego brutto ponownie stanowi najważniejszą właściwość dla tego modelu. Jak można zauważyć na wykresie, wraz ze wzrostem PKB, wzrasta również wartość SHAP. Dowodzi to, że najwyższe wartości dla tej cechy wpływają na wysokie dodatnie saldo migracji. Podobne tendencje zaobserwować można dla kolejnych cech dotyczących oddanych

mieszkań, liczby urodzeń, ludności w wieku produkcyjnym czy liczby studentów. Odwrotną tendencję obserwuje się dla liczby ludności w wieku przedprodukcyjnym, poprodukcyjnym, liczby małżeństw a nawet średniego wynagrodzenia. Wymienione cechy mają jednak mniejszy wpływ na wynik predykcji salda migracji. Model liniowy swoje predykcje bazuje głównie na cechach będącymi najsilniejszymi predyktorami.



Rysunek 32 Wykres SHAP Summary Plot- Ridge Regression Źródło: Opracowanie własne


Rysunek 33 przedstawia wykres „summary plot” dla nieliniowego modelu SVR (RBF). Liczba oddanych mieszkań, liczba studentów i wartość PKB podobnie jak w istotności permutacyjnej, wciąż najsilniej wpływają na wynik przewidywania. Zauważyć można jednak znacznie bardziej zrównoważony i nieliniowy podział istotności zmiennych w porównaniu do modelu regresji grzbietowej. Zatem zastosowanie jądra radialnego pozwala algorytmowi dostrzec więcej zależności.




Rysunek 33 Wykres SHAP Summary Plot- SVR (RBF) Źródło: Opracowanie własne

Wciąż można zauważyć dominację cech, u których zauważyć można zwiększanie się wartości SHAP wraz ze wzrostem wartości zmiennej. Zauważyć można podobną korelację wpływu większej liczby osób w wieku emerytalnym i szkolnym na ujemne saldo migracji. Widoczną zmianę zaobserwować można dla stopy bezrobocia. W

przeciwieństwie do modelu Ridge, dla SVR cecha ma ta większe znaczenie na wynik zmiennej docelowej a jej wyższa wartość wiąże się z niższą wartością salda migracji.



Rysunek 34 Wykres SHAP Summary Plot- Random Forest Źródło: Opracowanie własne




Rysunek 35 Wykres SHAP Summary Plot- Gradient Boosting Źródło: Opracowanie własne

W przypadku modeli zespołowych Random Forest i Gradient Boosting, na wykresach zaprezentowanych na rysunkach 34 i 35 zauważyć można zbieżność w interpretacji kluczowych zmiennych determinujących wynik regresji. Liczba studentów, ilość oddanych mieszkań, liczba urodzeń i wartość PKB posiadają największy wpływ na wysokie wyniki salda migracji wewnętrznych. Dla obu modeli wiodącą cechą jest jednak wartość dotycząca stopniu rozwinięcia akademickiego województwa. Sugeruje to o największej skali wewnętrznej migracji edukacyjnej. W przeciwieństwie do modeli Ridge i SVR, gęstość zaludnienia dla modeli drzewiastych ma większy wpływ na wyniki zmiennej docelowej i pokazuje, że zbyt wysoka ilość zagęszczenia ludności może wpływać negatywnie na wyższe wartości salda migracji. Przeprowadzona analiza regresji i technik oceny zmiennych wykazuje, że polskie migracje wewnętrzne są najbardziej napędzane przez poszukiwanie miejsca do poszerzenia wyższej edukacji, znalezienie miejsca zamieszkania oraz determinowane są przez poziom zamożności województwa. Struktura demograficzna

regionów również wpływa na atrakcyjność obszarów, o czym świadczy pozytywny wpływ na ilość imigrantów przy wysokiej liczbie urodzeń czy liczby ludności w wieku produkcyjnym. Modele zespołowe Random Forest i Gradient Boosting osiągnęły najwyższe współczynniki determinacji, otrzymując tym samym najbardziej precyzyjne predykcje dla zmiennej docelowej pomimo nieliniowych zależności cech zawartych w zbiorze danych. Największy wpływ na predykcję miały cechy charakteryzujące przyciągający charakter regionów najbardziej rozwiniętych w Polsce.

4.4. Redukcja wymiarów metodą PCA i jej wpływ na regresję

W kolejnym etapie analizy cech powiązanych ze zjawiskiem migracji wewnętrznych skupiono się na wdrożeniu algorytmu analizy głównych składowych. Zgodnie z informacjami zawartymi we wprowadzającym do tej metody rozdziale „3.2”, transformacja ta pozwala na rzutowanie oryginalnej, ortogonalnej przestrzeni cech na nowy układ współrzędnych, w którym wyznaczone składowe główne są wzajemnie nieskorelowane i uporządkowane według ilości zachowywanej informacji. Analiza ma na celu sprawdzenie wpływu redukcji wymiaru na wyniki celności predykcji w analizie regresji na badanym zbiorze danych oraz zbadanie ładunków czynnikowych na podstawie, których możliwa będzie ocena wkładu kolejnych zmiennych na podział składowych. W pierwszym kroku przystąpiono do precyzyjnego wyznaczenia liczby składowych, które zostaną przekazane do ostatecznych modeli regresji. Poprzez ograniczenie liczby wymiarów, należy znaleźć kompromis między maksymalną redukcją złożoności modelu a minimalizacją utraty informacji ukrytych w pierwotnych danych. Do podjęcia tej decyzji wykorzystano kryterium skumulowanej wariancji oraz wizualną analizę wykresu osypiska. Rysunek 36 przedstawia utworzone na podstawie badanych zestandaryzowanych danych wykresy przedstawiające relacje pomiędzy ilością utworzonych składowych a procentową liczbą wyjaśnionej przez nie wariancji. Lewy wykres przedstawia proporcję wariancji przypadającą na poszczególne osie wraz z czerwoną linią schodkową ułatwiającą identyfikację punktu,



Rysunek 36 Wykres piargowy i wykres skumulowanej wyjściowej wariancji. Źródło: Opracowanie własne

na którym widoczne jest pierwsze największe załamanie krzywej. W przedstawionym przypadku pierwsze spłaszczenie wykresu następuje po trzeciej składowej a kolejne ustabilizowanie osypiska jest formowane po piątej. Jako cel wyjaśnionej wariancji wybrano założenie o spełnieniu minimum 85% oryginalnej wariancji. Na obu wykresach można zauważyć, że pierwsza składowa samodzielnie tłumaczy już około 48,6% całkowitej zmienności zbioru danych. Druga składowej podnosi ten wskaźnik do poziomu około 68,6%. Docelowy próg reprezentowany, jako zielona przerywana linia na prawym wykresie za to osiąga liczba czterech składowych głównych. Kolejne istotne progi wynoszące 90% oraz 100% zostają osiągnięte kolejno dla pięciu i dziesięciu składowych. Na podstawie uzyskanych informacji do kolejnego etapu, w którym nastąpi porównanie modeli regresji na zbiorach z różną ilością składowych, wybrano liczbę składowych „k” równą 3, 4, 5 i 10, które są uzasadnione kryteriami formalnymi oraz w celach porównawczych- wartości równe 7 i 14. Podobnie jak w teście sprawdzającym wartość metryk regresji dla czterech wprowadzonych modeli, w analizie wyników dla tych modeli po redukcji wymiarów z różną ilością składowych, również sporządzona została tabela porównawcza posiadająca wszystkie poprzednie metryki uczenia maszynowego dla analizy regresji. Jednak z uwagi na jej rozległość wynikającą z dwadzieścia siedmiu przypadków i dwunastu kolumn, sporządzone zostały dwie osobne tabele zestawiające kluczowe metryki dla modeli o niższej liczbie składowych wynikającej z minimalnego progu wyjaśnionej wariancji zaprezentowane na rysunku 37 oraz metryki dla modeli o większej liczbie składowych prezentujących wyższe wyniki zaprezentowane na rysunku 38.

	Model	k	explained_variance_sum	Test R2	Cross-val R2 mean	Test RMSE	Czas trenowania [s]
0	Gradient Boosting	5	0.906722	0.768811	0.831871	1893.089191	0.116035
1	Gradient Boosting	4	0.855266	0.750918	0.824188	1964.982674	0.101482
2	Gradient Boosting	3	0.775106	0.744541	0.772891	1989.976807	0.093222
3	Random Forest	4	0.855266	0.773474	0.791629	1873.903483	0.196096
4	Random Forest	3	0.775106	0.768873	0.804332	1892.837991	0.333411
5	Random Forest	5	0.906722	0.717388	0.829729	2093.067637	0.210972
6	Ridge	5	0.906722	0.531967	0.597819	2693.555715	0.005769
7	Ridge	3	0.775106	0.518097	0.540599	2733.177348	0.005778
8	Ridge	4	0.855266	0.466826	0.549342	2874.895588	0.005640
9	SVR (RBF)	5	0.906722	0.595492	0.572060	2504.098238	0.007439
10	SVR (RBF)	3	0.775106	0.552946	0.558474	2632.495791	0.007590
11	SVR (RBF)	4	0.855266	0.531088	0.533363	2696.083424	0.006817

Rysunek 37 Tabela wyników regresji dla przedziału wartości k od 3 do 5. Źródło: Opracowanie własne

Na podstawie wyników w pierwszej tabeli, zauważyć można spadek jakości modelu regresji grzbietowej i modelu SVR w porównaniu do wyników bazowych przed zastosowaniem PCA. Dla ustalonej minimalnej wariacji równej 85%, model Ridge osiągnął na zbiorze testowym współczynnik determinacji równy 0,466. Dla modelu SVR wynosi on 0,531. Można zatem wywnioskować, że dla tej liczby składowych klasyczna metoda PCA usunęła ze zbioru danych kluczowe informacje, bez których te algorytmy nie są w stanie poprawnie przewidywać salda migracji. Modele zespołowe Random Forest i Gradient Boosting otrzymały bardziej satysfakcjonujące wyniki. Przy zaledwie trzech składowych były w stanie osiągnąć wartość R^2 równą kolejno 0,76 i 0,74. Modele oparte o drzewa decyzyjne, zatem wykazują lepsze predyspozycje do skuteczniejszego wydobywania informacji z silniej skompresowanych składowych redukując również czas trenowania. Następnie porównane zostaną modele o mniejszej końcowej kompresji danych. Zobrazowane na rysunku 38 wyniki współczynnika determinacji dla danych testowych są bardziej zbliżone do wartości predykcji modeli bazowych. Dla regresji modelu Ridge z dziesięcioma składowymi, współczynnik R^2 osiągnął wyższy wynik niż dla modelu bazowego tego rodzaju regresji. W tym przypadku odrzucenie czterech składowych usunęło z danych wystarczająco szumu informacyjnego, aby ten model liniowy osiągnął bardziej dokładną generalizację. Widoczny jest również istotny skrócony czas trenowania modelu Ridge. W przypadku modelu SVR, wynik predykcji się nie poprawił. Random Forest i Gradient Boosting otrzymały bardzo zbliżone wartości dla współczynnika determinacji bazowego modelu przy zaledwie siedmiu składowych.

	Model	k	explained_variance_sum	Test R2	Cross-val R2 mean	Test RMSE	Czas trenowania [s]
0	Gradient Boosting	14	1.000000	0.882395	0.838990	1350.207406	0.181130
1	Gradient Boosting	7	0.956227	0.874106	0.877671	1396.982007	0.190251
2	Gradient Boosting	10	0.990655	0.872817	0.902648	1404.116127	0.152693
3	Random Forest	14	1.000000	0.879099	0.824495	1368.999796	0.315075
4	Random Forest	10	0.990655	0.811449	0.848670	1709.628578	0.284855
5	Random Forest	7	0.956227	0.811264	0.856983	1710.471108	0.258587
6	Ridge	10	0.990655	0.711365	0.726123	2115.251959	0.005716
7	Ridge	14	1.000000	0.696790	0.740982	2168.001014	0.005948
8	Ridge	7	0.956227	0.657344	0.691270	2304.712342	0.006027
9	SVR (RBF)	14	1.000000	0.703961	0.683486	2142.209277	0.007917
10	SVR (RBF)	10	0.990655	0.689635	0.672922	2193.431196	0.007673
11	SVR (RBF)	7	0.956227	0.672160	0.626432	2254.337592	0.007543

Rysunek 38 Tabela wyników regresji dla przedziału wartości k od 7 do 14. Źródło: Opracowanie własne

Można to uznać za udany kompromis wynikający ze zredukowania wymiarowości problemu o połowę cech przy utracie niewielkiej ilości punktów procentowych w precyzji predykcji. Dla modelu Random Forest obserwuje się również skrócenie czasu trenowania o ponad połowę (z 0.685 sekundy). Na tym etapie analizy PCA, zaobserwować można, że analiza głównych składowych na chwilę obecną charakteryzuje się ograniczoną skutecznością dla przedstawionych danych demograficznych, ekonomicznych i społecznych. Optymalna liczba składowych proponowana przez wykres osypiska prowadzi do zbyt wysokiej utraty zdolności predykcyjnej modeli. Uzasadnione może to być przez nieliniowe oddziaływanie zmiennych na saldo migracji. Rzutowanie tych zależności na liniowe osie głównych składowych prowadzi do utraty informacji decyzyjnych dla modeli regresji. Aby dalej zgłębić temat wpływu redukcji wymiarów na wyniki modeli, wdrożono do analizy algorytm Kernel PCA, który bazując na sztuczce jądrowej, pozwala na naukę nieliniowych zależności przy zachowaniu topologii danych. Zastosowanie tej funkcji miało na celu zrealizować rzutowanie nieliniowych zależności między cechami do ortogonalnej przestrzeni, nie tracąc przy tym kluczowych sygnałów wynikających z ich budowy. Algorytm przeprowadzający uczenie maszynowe na składowych, oprócz zrealizowania porównania wyników modeli pod względem liczby wartości „k”, został wzbogacony o dwie nieliniowe konfiguracje Kernel PCA. Celowo zrezygnowano z wariantu liniowego, który z matematycznego punktu widzenia jest tożsamy z przeprowadzonym we wcześniejszym etapie klasycznym PCA. Pod uwagę wzięto natomiast jądro wielomianowe (z angielskiego „Polynomial”), dla którego

przetestowano drugi oraz trzeci stopień wielomianu, oraz jądro RBF, dla którego pod uwagę wzięto trzy opcje parametru gamma wynoszące 0,001 jak również 0,01 oraz 0,1. Definicję tę można zauważyć na rysunku 39, zawierającym część algorytmu służącego do przeprowadzenia analizy regresji na składowych powstałych przy jądrowej redukcji wymiarów.

```
kernels_config = {
    'poly': [2, 3], #Parametr degree- stopień wielomianu
    'rbf': [0.001, 0.01, 0.1] #Parametr gamma
}

models_pca = {
    'Ridge': Ridge(),
    'SVR (RBF)': SVR(kernel='rbf', C=1000, epsilon=0.1, gamma='auto'),
    'Random Forest': RandomForestRegressor(random_state=42),
    'Gradient Boosting': GradientBoostingRegressor(random_state=42)
}

k_list = [3, 4, 5, 7, 10, 14]
max_components = X_train.shape[1]
k_list = sorted(list(k for k in k_list if 1 <= k <= max_components))

results_kpca = []

print(f"Rozpoczynam testy Kernel PCA dla k: {k_list}")

for k in k_list:
    for kernel_name, param_values in kernels_config.items():
        for param_val in param_values:
            for model_name, model in models_pca.items():

                if kernel_name == 'poly':
                    kpca = KernelPCA(n_components=k, kernel='poly', degree=param_val)
                    param_label = f"degree={param_val}"
                else:
                    kpca = KernelPCA(n_components=k, kernel='rbf', gamma=param_val)
                    param_label = f"gamma={param_val}"

                var_sum = None

                pipeline_kpca = Pipeline([
                    ('preprocessing', preprocessor),
                    ('pca', kpca),
                    ('regressor', model)
                ])

                t0 = time.time()
                pipeline_kpca.fit(X_train, y_train)
                t_train = time.time() - t0
```

Rysunek 39 Algorytm konfiguracji porównania wyników analizy regresji dla jądrowej redukcji wymiarów
Źródło: Opracowanie własne

Z uwagi na liczbę czterech badanych modeli regresji oraz wielu kombinacji liczby składowych i parametrów specyficznych dla zastosowanych jąder, uzyskano łącznie sto dwadzieścia instancji testowych. Wyniki dla trzech kombinacji osiągających najwyższe predykcje dla poszczególnych modeli zostały rozpisane na rysunku numer 40. Zauważyć można wzrost czasu trenowania modeli dla wszystkich kombinacji w porównaniu z poprzednią liniową metodą PCA, co jest naturalną konsekwencją zwiększonej złożoności obliczeniowej operacji macierzowych dla wielowymiarowej przestrzeni zmiennych. W znacznej większości przypadków zaobserwować można wzrost testowego współczynnika determinacji w stosunku dla poprzedniej metody PCA. Wzrost jest widoczny dla modeli Random Forest, Gradient Boosting i Ridge. W

przypadku modelu SVR częściej obserwowalny jest spadek wartości R^2 . Wyróżnić należy model Gradient Boosting z dziesięcioma składowymi i jądrem RBF o parametrze $\gamma=0,001$. Kombinacja ta osiągnęła współczynnik determinacji równy 0,9408, co daje najwyższy wynik w dotychczasowej przeprowadzanej wieloetapowej analizie. Dla modelu liniowego Ridge również osiągnięto wynik współczynnika determinacji przewyższający ten dla modelu bazowego zarówno przy użyciu jądra RBF jak i wielomianowego, lecz przy maksymalnej liczbie składowych. Dla modeli Random Forest i SVR (RBF) próg wyników predykcji dla bazowych modeli nie został jednak przekroczony. Godnym wymienienia są także przypadki dla modelu Random Forest z jądrem RBF o γ równym 0,01, który z wartością siedmiu składowych uzyskał współczynnik R^2 równy 0,8835 oraz Gradient Boosting z jądrem RBF o γ równym 0,001 gdzie współczynnik determinacji wynosi 0,9169.

	Model	k	Kernel	Parameter	Test R2	Test RMSE	Test MAE	CV R2 Mean	CV R2 Std	Czas [s]
0	Gradient Boosting	10	RBF	$\gamma=0.001$	0.9408	958.0872	759.3948	0.8967	0.0361	0.1256
1	Gradient Boosting	7	RBF	$\gamma=0.001$	0.9169	1135.2594	855.5841	0.8737	0.0566	0.1034
2	Gradient Boosting	14	RBF	$\gamma=0.001$	0.9069	1201.2904	780.1154	0.8827	0.0625	0.2387
3	Random Forest	7	RBF	$\gamma=0.01$	0.8835	1343.5929	973.1536	0.8663	0.0324	0.1693
4	Random Forest	14	RBF	$\gamma=0.001$	0.8711	1413.6218	875.2003	0.8341	0.0917	0.2153
5	Random Forest	14	RBF	$\gamma=0.01$	0.8626	1459.2378	1027.8821	0.8597	0.0369	0.2280
6	Ridge	14	POLY	degree=2	0.7359	2023.4626	1405.9803	0.7195	0.1117	0.0071
7	Ridge	14	RBF	$\gamma=0.01$	0.7190	2087.1463	1523.0751	0.6782	0.0695	0.0189
8	Ridge	10	POLY	degree=2	0.6979	2163.9310	1566.1312	0.6998	0.0997	0.0073
9	SVR (RBF)	10	POLY	degree=2	0.5981	2496.0675	1590.8040	0.5928	0.0640	0.0095
10	SVR (RBF)	7	POLY	degree=2	0.5852	2535.7135	1605.9767	0.5881	0.0637	0.0087
11	SVR (RBF)	14	POLY	degree=2	0.5789	2554.9676	1643.9242	0.5576	0.0534	0.0092

Rysunek 40 Tabela najwyższych wyników regresji jądrowej dla przedziału wartości k od 7 do 14. Źródło: Opracowanie własne

W przypadku silniejszej kompresji wymiarów, tabela zaprezentowana na rysunku 41 przedstawiająca najwyższe wartości dla $k=3, 4$ i 5 ujawnia dominację jądra wielomianowego drugiego stopnia nad RBF dla mniejszej ilości składowych. Dla wszystkich obserwacji, jądro RBF z parametrem „ γ ” równym 0,1 okazało się najmniej efektywną kombinacją we wszystkich wariantach modeli, Sugeruje to o zbyt gwałtownym zakrzywieniu przestrzeni przez ten wariant. Interesującym odkryciem w zastosowaniu metody Kernel PCA była jej relacja modelem SVR, który już posiada wbudowane jądro RBF. Zastosowanie tej podwójnej transformacji nieliniowej


doprowadziło do znaczącego pogorszenia wyników regresji sięgającymi nawet wartości współczynnika determinacji równej 0,14 dla maksymalnej liczby składowych. W przypadku relacji jądra wielomianowego z modelem SVR (RBF), obserwacja ta się nie powtórzyła i otrzymała wyniki zbliżone, lecz niższe wobec oryginalnego rozkładu wymiarów. Na podstawie tej obserwacji można dojść do wniosku o tym, że algorytmy oparte na jądrach nieliniowych wymagają relatywnie prostej reprezentacji wejściowej, aby uniknąć zjawiska przetrenowania.

	Model	k	Kernel	Parameter	Test R2	Test RMSE	Test MAE	CV R2 Mean	CV R2 Std	Czas [s]
0	Gradient Boosting	3	RBF	gamma=0.001	0.7312	2041.2038	1390.8951	0.7572	0.0941	0.2297
1	Gradient Boosting	4	POLY	degree=2	0.7955	1780.5983	1223.5033	0.6583	0.1221	0.1090
2	Gradient Boosting	5	POLY	degree=2	0.8251	1646.4451	1159.5927	0.7019	0.0916	0.1167
3	Random Forest	3	RBF	gamma=0.001	0.7657	1905.6665	1281.2814	0.7858	0.0757	0.3259
4	Random Forest	4	POLY	degree=2	0.8347	1600.8218	1139.5738	0.7410	0.0694	0.1914
5	Random Forest	5	POLY	degree=2	0.8309	1618.8738	1120.0029	0.7743	0.0418	0.2302
6	Ridge	3	POLY	degree=2	0.5729	2573.0205	1930.4345	0.5821	0.1049	0.0355
7	Ridge	4	POLY	degree=2	0.5731	2572.5444	1926.9726	0.5810	0.1107	0.0089
8	Ridge	5	POLY	degree=2	0.5313	2695.4772	2055.3187	0.5815	0.1108	0.0109
9	SVR (RBF)	3	POLY	degree=2	0.5388	2673.7849	1744.1506	0.5585	0.0782	0.0410
10	SVR (RBF)	4	POLY	degree=2	0.5326	2691.8274	1726.8516	0.5537	0.0748	0.0149
11	SVR (RBF)	5	POLY	degree=2	0.5413	2666.4555	1731.1427	0.5598	0.0740	0.0351

Rysunek 41 Tabela wyników regresji jądrowej dla przedziału wartości k od 3 do 5. Źródło: Opracowanie własne

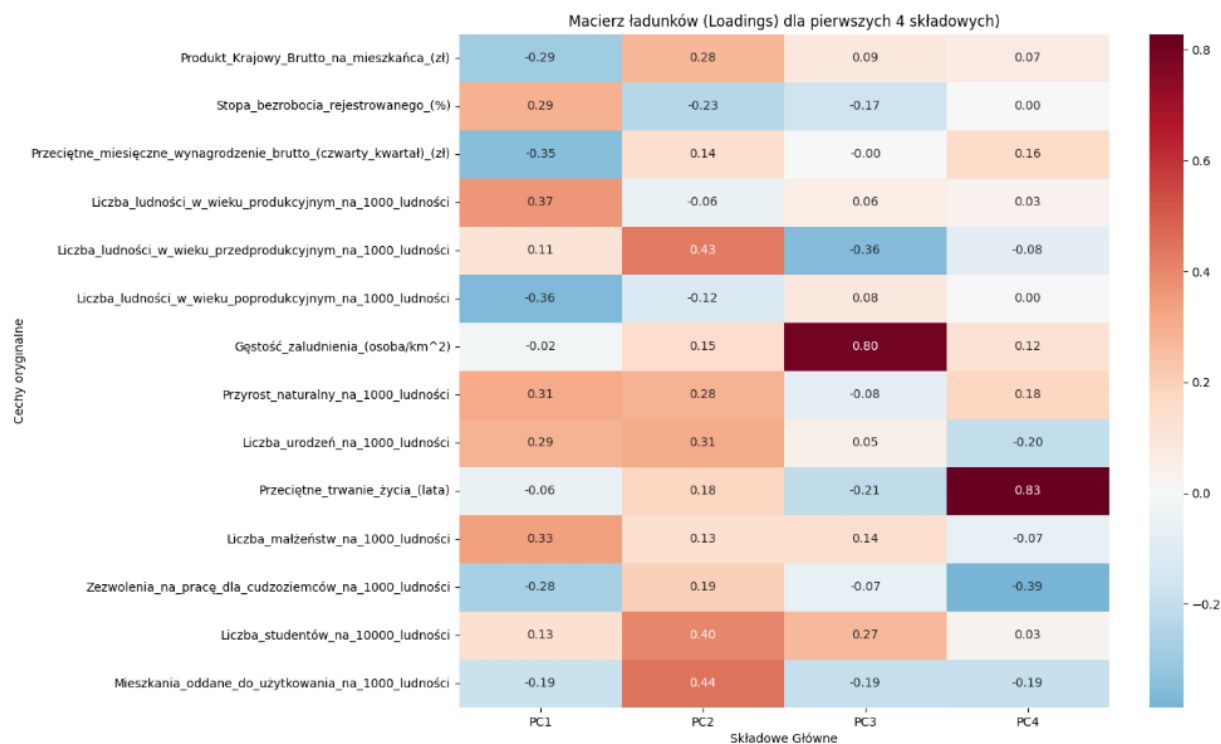
Rysunek 42 przedstawia porównanie wpływu ilości liczby składowej na współczynnik determinacji modeli regresyjnych na zbiorze testowym. Wyróżnia się na nim dwa rodzaje przerywanych linii odpowiadających zastosowanym jądrům PCA. Poza wspomnianej anomalii modelu SVR w kombinacji z PCA RBF oraz przypadku Polynomical PCA dla Random Forest, dla pozostałych modeli obserwuje się wzrost poprawności predykcji od pięciu składowych. Na podstawie przeprowadzonej analizy regresji z redukcją wymiarów cech w badanym zbiorze danych można potwierdzić złożoność relacji zachodzących pomiędzy nimi. W wyniku tego, drastyczniejsze redukcje wymiarów do mniejszej wartości składowych pomimo zachowaniu 85% wariancji powodują utracenie zbyt wielu informacji koniecznych do utworzenia trafnej predykcji. Przykład z modelami drzewiastymi Gradient Boosting i Random Forest świadczy jednak o możliwości eliminacji multikolinearności i poprawie zdolności predykcyjnej modeli. Następnym etapem analizy była próba zrozumienia merytorycznego znaczenia dla utworzonych głównych składowych. W tym celu dla czterech głównych składowych, które na podstawie wykresu wariancji skumulowanej wyjaśniają 85% wariancji zbioru została wygenerowana mapy ciepła (z angielskiego

„heatmap”) zaprezentowana na rysunku 43. Macierz ta pozwala na korelację pierwotnych zmiennych na wygenerowane na ich podstawie składowych początkowej metody PCA.



Rysunek 42 Tabela Wykres pokazujący zależność pomiędzy ilością składowych a jakości predykcji R².

Źródło: Opracowanie własne



Rysunek 43 Macierz ładunków czynnikowych dla czterech składowych. Źródło: Opracowanie własne

Po przyjrzeniu się pierwszej składowej, można zauważyć polaryzację poprzez podział cech na ładunki o charakterze silnie ujemnym a charakterze dodatnim. Kontrast negatywnych wartości dla PKB, przeciętnego wynagrodzenia i liczby ludności w wieku poprodukcyjnym a dodatnimi ładunkami dla liczby ludności w wieku produkcyjnym, liczby urodzeń i małżeństw oraz przyrostu naturalnego świadczy o podziale regionów demograficznych na te osiągające wyższą dzietność, lecz mniejszy rozwój gospodarczy a regiony bardziej zamożne u których zauważyć można bardziej starzenie się społeczeństwa. Składową można zinterpretować, jako przeciwstawienie tradycyjnej struktury demograficznej z poziomem rozwoju gospodarczego. Drugą składową charakteryzują silne dodatnie ładunki występujące dla liczby mieszkań oddanych do użytkowania, liczby studentów i liczby ludności w wieku przedprodukcyjnym. Umiarkowanie dodatnie ładunki posiadają również wartości dla liczby urodzeń, przyrostu naturalnego i PKB. Bardziej znaczący ujemny ładunek osiąga tylko poziom bezrobocia. Biorąc pod uwagę najbardziej znaczące cechy, składową tą można zdefiniować, jako wskaźnik atrakcyjności osadniczej i akademickiej. Dla kolejnych dwóch składowych można zauważyć dominację jednej zmiennej. W przypadku „PC3” jest to gęstość zaludnienia, co czyni tą składową wskaźnikiem urbanizacji regionu. Czwarta składowa wykazując największą wagę dla średniego przeciętnego trwania życia w danym województwie stanowi wskaźnik warunków zdrowotnych i jakości życia. Kolejnym zastosowanym narzędziem służącym do interpretacji przetworzonego zestawu zmiennych został wykres „Biplot”, który stanowi graficzną reprezentację łączącą dwa elementy analizy poprzez zaprezentowanie obserwacji w nowej przestrzeni głównych składowych oraz wektory ładunków dla poszczególnych zmiennych. Dzięki temu narzędziu możliwe jest określenie, które z początkowych cech objaśniających saldo migracji wewnętrznych najsilniej determinują zróżnicowanie wzdłuż dwóch składowych „PC1” i „PC2” wyznaczonych na osi. Zaobserwować można również sposoby, w jakim obserwacje dotyczące województw w latach 2010-2024 wykazują podobne zachowania i łączą się w grupy.⁶⁰ Realizacja wykresu Biplot w środowisku języka Python była wprowadzona z wykorzystaniem biblioteki „plotly”. Implementacja danego narzędzia przedstawiona jest na rysunkach 44 i 45. Wpierw zredukowane dane z PCA zostają przetransformowane do przestrzeni dwuwymiarowej. Wprowadzono etykiety, które

⁶⁰ Parent E. Nextjournal. *Principle component analysis and biplots in Python*. 10 Wrzesień 2024.

umożliwiają wyświetlenie wartości salda migracji dla danej obserwacji na wykresie. Ze względu na różnice rzędów wielkości między rzutami punktów a wartościami wektorów, następnie zastosowano przelicznik skalujący do określenia współrzędnych strzałek. Zastosowane skalowanie dynamiczne bazuje na maksymalnych wartościach bezwzględnych dla rozstępów na dwóch osiach PC1 i PC2.

```
X_pca_transformed = pca_full.transform(X_scaled_PCA)

df_pca = pd.DataFrame(X_pca_transformed[:, 0:2], columns=['PC1', 'PC2'])
df_pca['Label_Full'] = MigracjeZbiór['Województwo i rok']
df_pca['Saldo'] = MigracjeZbiór['Saldo_migracji_wewnętrznych']

df_pca['Województwo'] = df_pca['Label_Full'].str.rsplit('_', n=1).str[0]
df_pca['Rok'] = df_pca['Label_Full'].str.rsplit('_', n=1).str[1]

#Obliczenie współrzędnych strzałek
loadings = pca_full.components_[0:2, :].T
features = X_PCA.columns
scale_factor = max(df_pca['PC1'].abs().max(), df_pca['PC2'].abs().max()) * 0.8

#Bazowy wykres punktowy
fig = px.scatter(
    df_pca,
    x='PC1',
    y='PC2',
    color='Województwo',
    hover_data={'Label_Full': True, 'Saldo': True, 'PC1': ':.2f', 'PC2': ':.2f'},
    title='Interaktywny Biplot PCA: Wektory cech i trajektorie województw',
    labels={'PC1': 'Składowa Główna 1', 'PC2': 'Składowa Główna 2'},
    template='plotly_white',
    opacity=0.6
)


#Dodawanie wektorów cech (strzałki)
for i, feature in enumerate(features):
    x_end = loadings[i, 0] * scale_factor
    y_end = loadings[i, 1] * scale_factor

    fig.add_annotation(
        ax=0, ay=0, #Początek strzałki- środek
        axref='x', ayref='y',
        x=x_end, y=y_end,
        xref='x', yref='y',
        showarrow=True,
        arrowhead=2,
        arrowsize=1,
        arrowwidth=2,
        arrowcolor="red"
    )
```

Rysunek 44 Kod implementujący wykres Biplot. Źródło: Opracowanie własne

W kolejnym etapie z wykorzystaniem modułu „plotly.express” wygenerowano punktowy wykres rozrzutu, dla którego obserwacjami są województwa w badanym roku. Strzałki, które zostaną wyświetlone na wykresie stanowią oznaczenie dla kierunkowych wektorów, których początek znajduje się na środku układu współrzędnych a koniec jest determinowany przez wartości ładunków po przeskalowaniu. Kolejna część kodu odpowiada za estetyczne cechy wykresu i jego legendy. Końcowy wykres posiadający wszystkie obserwacje dla województw znajduje się na rysunku 46 a jego przybliżenie lepiej obrazujące wektory zmiennych

obrazuje rysunek 45. Kierunek wzrostu wartości dla danej zmiennej oznaczony jest poprzez graficzny symbol czerwonej strzałki. Informacje o korelacjach między cechami są dostarczane poprzez rodzaj kątów między wektorami.



Rysunek 45 Kierunki wektorów na wykresie Biplot. Źródło: Opracowanie własne

Ostre kąty pomiędzy dwoma cechami świadczą o dodatniej korelacji, podczas gdy rozwarte kąty świadczą o silnie ujemnym oddziaływaniu. Wraz z długością wektora, rośnie jego istotność w budowie składowych.⁶¹ Po przyjrzeniu się lokalizacji wektorów na osi układu współrzędnych zauważyć można, że najdłuższe wektory osiągają zmienne „Mieszkania oddane do użytkowania na 1000 ludności”, „Liczba ludności w wieku przedprodukcyjnym na 1000 ludności” oraz „Liczba studentów na 10000 ludności”. Świadczy to o wysokiej wadze tych zmiennych oraz ich pozytywnym wpływie na wyższe wartości salda migracji wewnętrznych. Po prawej stronie

⁶¹ PQStat Software (2023). Podręcznik Użytkownika PQStat 1.8.6. *Analiza składowych głównych. Interpretacja graficzna*. Sierpień 2014

pokazują się także cechy demograficzne określające liczbę urodzeń, przyrost naturalny i liczbę małżeństw. Ich pobliskie rozłożenie na osi wskazuje na powiązanie pomiędzy tymi zmiennymi i czyni z nich grupę cech dla regionów atrakcyjnych dla imigrantów. W mniejszym stopniu na dodatni wynik zmiennej docelowej wpływają czynniki widoczne po górnej lewej stronie wykresu. Wyróżnić można w tym skupieniu czynniki ekonomiczne takie jak wartość PKB czy przeciętne miesięczne wynagrodzenie w czwartym kwartale. Gęstość zaludnienia, liczba zezwoleń na pracę dla cudzoziemców i przeciętne trwanie życia również należą do tej grupy zmiennych o wzajemnej korelacji z uwagi na ich bliskie położenie.



Rysunek 46 Pełny wykres Biplot. Źródło: Opracowanie własne

W dolnej części wykresu na rysunku 45 wyodrębniają się tylko trzy wektory o widocznym negatywnym wpływie na zmienną docelową. W do tej grupy należą „liczba ludności w wieku poprodukcyjnym na 1000 ludności”, „stopa bezrobocia rejestrowanego” i „liczba ludności w wieku produkcyjnym na 1000 ludności”. Należy

zaznaczyć, że zmienna dotycząca ludności emerytalnej jest bardzo oddalona od pozostałych, co wyklucza znaczącą korelację. Po wyciągnięciu wniosków po analizie przestrzeni zmiennych, ocenić można grupowanie obserwacji równoważnym województwom oraz ich trajektorie. Zauważyć można podział województw dla lat 2010-2024 na rozwinięte regiony usytuowane w górnej części układu, które przyciągają ludność z regionów widocznych w dolnej części. Jako lidera regionów w pierwszej i drugiej ćwiartce wyróżnić należy województwo mazowieckie, jako te osiągające średnio najwyższe saldo migracji wewnętrznych. Podobnie jak województwa małopolskie, pomorskie i wielkopolskie, podczas badanego okresu czasu, regiony te nie osiągnęły ujemnego salda migracji wewnętrznych i stanowią rolę biegunów wzrostu i naturalne miejsca docelowe dla migrantów. W dolnej części układu zawierają się obserwacje dla województw, które z powodów niższych wartości cech przyciągających w pierwszej i drugiej ćwiartce i wyższych dla cech odpychających w trzeciej i czwartej osiągają ujemne wartości dla zmiennej docelowej. Jest to najrozleglejsza grupa województw, do której zaliczyć można województwa kujawsko-pomorskie, lubelskie, lubuskie, łódzkie, śląskie, warmińsko-mazurskie i zachodniopomorskie. Najniższe pozycje na całym wykresie Biplot należą do województwa opolskiego i województwa świętokrzyskiego. Są to główne obszary odpływu ludności. Wyróżnia się również trzy województwa o zróżnicowanym rozłożeniu na osi układu składowych. Jest to województwo dolnośląskie, które osiąga dodatnie wartości salda migracji oraz województwa podlaskie i podkarpackie, dla których zauważa się ujemne saldo migracji wewnętrznych. Świadczyć to może o dysproporcjach aglomeracyjnych w województwie dolnośląskim oraz o umiarkowanym rozwoju infrastrukturalnym dla regionów Podkarpacia i Podlasia. Wykres Biplot potwierdził podział Polskie na regiony aglomeracyjne i peryferyjne oraz wskazał, które województwa posiadają zbliżone obserwacje, grupując je wokół cech ekonomicznych, demograficznych i społecznych, dla których określono zmienne wpływające pozytywnie i negatywnie na wynik zmiennej docelowej oraz ich korelacje i rolę w reprezentacji dwóch głównych składowych.

4.5. Wnioski z przeprowadzonej analizy

Zrealizowanie wieloetapowego procesu eksploracji danych, modelowania predykcyjnego oraz redukcji wymiarowości, umożliwia ostateczne podsumowanie

uzyskanych wyników. Przeprowadzona analiza pozwala na jednoznaczne udzielenie odpowiedzi na postawione w rozdziale 3. „Analiza głównych składowych i regresji dla województw w latach 2010-2024” pytania badawcze oraz weryfikację sformułowanych hipotez. Wyniki analizy eksploracyjnej i następujących po niej wykorzystaniach narzędzi uczenia maszynowego oraz wizualizacji pozwoliły na pełne potwierdzenie głównej hipotezy badawczej o nieliniowości badanych zmiennych kształtujących saldo migracji wewnętrznych w Polsce. Model opierający się na klasycznej relacji liniowej- regresji grzbietowej osiągnął znacznie niższą skuteczność predykcyjną w porównaniu do nieliniowych algorytmów zespołowych, takich jak Random Forest czy Gradient Boosting, lecz uzyskał porównywalną wartość dla nieliniowego modelu SVR z jądrem RBF. Udowadnia to, że decyzje migracyjne Polaków nie rosną proporcjonalnie do zmian wskaźników, lecz narastają po przekroczeniu określonych progów na terenach regionów docelowych dotyczących na przykład zamożności obszaru czy jego gęstości zaludnienia. Dzięki implementacji technik wyjaśnianej sztucznej inteligencji, potwierdzono hipotezę pomocniczą o wyższości istotności dostępu do mieszkań i miejsc do realizacji edukacji wyższej nad zmiennymi ekonomicznymi dotyczącymi rynku pracy. Analiza z pomocą SHAP dla nieliniowych modeli regresyjnych wykazała, że cechy te stanowią najsilniejsze stymulanty napływu ludności. Pomimo tego, że ogólny poziom rozwoju gospodarczego reprezentowany przez produkt krajowy brutto również stanowi fundamentalny wskaźnik, to nie gwarantuje dodatniego salda migracji wewnętrznych w podobny sposób jak dwie założone cechy. W akceptowalnym stopniu potwierdzona została druga hipoteza pomocnicza zakładająca pozytywny wpływ redukcji wymiarów z metodą nieliniowych przekształceń Kernel PCA na predykcje wyników w porównaniu do pierwotnej, klasycznej metody PCA. Modele Random Forest, Gradient Boosting i Ridge osiągnęły wyższe wartości współczynnika determinacji dla zbioru testowego dla tej redukcji wymiarów. Dla dwóch z nich osiągnięto wynik przewyższający wyniki bazowe. Dowodzi to, że zachowanie topologii nieliniowej w procesie redukcji cech pozwala na optymalizację wymiarowości bez utraty krytycznych sygnałów informacyjnych. Dzięki analizie istotności cech podczas predykcji zmiennej docelowej, analiza ostatecznie udowodniła, że współczesne migracje wewnętrzne na terenie Polski opierają się w znacznie większej mierze na czynnikach przyciągających do obszarów bardziej rozwiniętych. Ukryte profile zróżnicowania przestrzennego zostały zidentyfikowane

za pomocą wykresu Biplot. Podzielił on Polskę na dwie główne grupy, z których jedna reprezentuje cztery regiony kumulujące najwyższy potencjał mieszkaniowy, akademicki i gospodarczy. W drugiej grupie województw zidentyfikowano regiony w rozwojowej stagnacji, zagrożone depopulacją i dążących w kierunku niekorzystnych trendów demograficznych, takich jak starzenia się społeczeństwa.

Wyniki przeprowadzonej analizy mogą stanowić punkt odniesienia do kształtowania polityki spójności przestrzennej, dowodząc o niewystarczalności nakładów finansowych i stymulowania rynku pracy, aby zatrzymać kontynuowanie procesu odpływu ludności z regionów peryferyjnych. Skuteczniejszą strategią może być realizowanie równoległych inwestycji w rozwój lokalnego mieszkalnictwa i utrzymanie oraz ekspansja ośrodków szkolnych i akademickich stanowiących istotne wskaźniki przyciągające dla najważniejszej z punktu widzenia demograficznego grupy docelowej, którą stanowi młoda ludność.

Zakończenie

Niniejsza praca magisterska stanowiła kompleksową próbę wielowymiarowej analizy zjawiska migracji wewnętrznych w Polsce w latach 2010–2024. Jako główny cel badawczy oznaczona była identyfikacja oraz ocena siły wpływu czynników demograficznych, ekonomicznych i społecznych, które determinują przemieszczenia ludności między województwami. W części teoretycznej szczegółowo omówiono historyczne i współczesne trendy przestrzenne, nakreślając uwarunkowania kształtujące polską demografię oraz podkreślając narastający problem polaryzacji kraju na rozwijające się ośrodki centralne i wyludniające się obszary peryferyjne.

Część empiryczna pracy opierała się na implementacji zaawansowanych technik uczenia maszynowego oraz statystyki wielowymiarowej. Wykorzystując autorski zbiór danych zebranych z publicznego źródła GUS, przeprowadzono analizę eksploracyjną i następnie zastosowano modele regresyjne w celu zbadania mechanizmów kształtujących saldo migracji. Aby rozwiązać problem współliniowości danych i wyodrębnić ukryte wzorce przestrzenne, wdrożone zostały metody redukcji wymiarowości. Wyróżniono klasyczną analizę składowych głównych PCA oraz jej nieliniowe rozwinięcie- Kernel PCA. Dodatkowo, dzięki zastosowaniu metod wyjaśnialnej sztucznej inteligencji, precyzyjnie określono wkład poszczególnych

zmiennych w wyniki predykcji zmiennej docelowej, jaką było saldo migracji wewnętrznych. Przeprowadzone badania jednoznacznie potwierdziły nieliniowy i niezwykle złożony charakter procesów migracyjnych w Polsce. Dowiedziono, że współczesna mobilność terytorialna Polaków jest napędzana przede wszystkim przez czynniki przyciągające najsilniejszych aglomeracji. Za najsilniejsze stymulanty napływu nowej ludności uznano potencjał akademicki regionu, dostępność infrastruktury mieszkaniowej oraz ogólny poziom zamożności reprezentowany przez Produkt Krajowy Brutto. Jednocześnie wykazano, że zastosowanie zaawansowanych algorytmów zespołowych oraz nieliniowej redukcji wymiarów pozwala na znaczną optymalizację zdolności predykcyjnych modeli analitycznych w naukach społeczno-ekonomicznych. Wnioski płynące z niniejszej pracy wyraźnie uwypuklają głęboki podział przestrzenny Polski na nieliczne dominujące rozwinięte aglomeracje oraz szeroką grupę terytoriów dotkniętych postępującą depopulacją. Wnioski mogą stanowić wskazówkę dla podmiotów kształtujących politykę spójności regionalnej, sugerując, że przeciwdziałanie marginalizacji słabiej rozwiniętych województw wymaga nie tylko stymulowania lokalnego rynku pracy, ale przede wszystkim intensywnych inwestycji w sferę mieszkalnictwa i rozwój infrastruktury edukacyjnej.

Literatura

Anderson B. Przewodnik po wielowspółliniowości i VIF w regresji. 29 Lipiec 2023

Antczak E. Lewndowska-Gwarda K. Dynamika procesu starzenia się ludności w Polsce. Ocena z wykorzystaniem metod strukturalno-geograficznych. str. 90. Grudzień 2018.

Białek J. Gadecki H. Szacowanie współczynników w teście normalności Shapiro-Wilka. Maj 2009

Cognity.pl Czym są lasy losowe i jak działają? 10 Październik 2024

Czopek A. ANALIZA PORÓWNAWCZA EFEKTYWNOŚCI
METOD REDUKCJI ZMIENNYCH – ANALIZA SKŁADOWYCH GŁÓWNYCH
I ANALIZA CZYNNIKOWA. 2013

Dolińska, A. (2025). Migracje poakcesyjne młodzieży z regionów peryferyjnych a wykształcenie rodziców – ryzyko utraty kapitału społeczno-gospodarczego. Dowody empiryczne z wybranych powiatów województwa dolnośląskiego. W: A. Do-lińska, R. Jończy, J. Rokitowska-Malcher (red.), Migracje Polaków w pierwszych dekadach XXI wieku w kontekście przemian społeczno-gospodarczych. Wybrane zagadnienia (str. 13-24). Wydawnictwo Uniwersytetu Ekonomicznego we Wrocławiu.

Dutkowski J. Eksploracyjna analiza danych. Metody rzutowania: analiza składowych głównych oraz skalowanie wielowymiarowe. 22 Maj 2007

Fuhrmann M. Ruszczyk A. Kierunki i przyczyny migracji zagranicznych i wewnętrznych Polaków. Zmiany salda migracji zagranicznych i wewnętrznych Polaków i ich przyczyny. 2020

Fuhrmann M. ZPE Konsekwencje migracji wewnętrznych i zagranicznych Polaków

Gawryszewski, A. LUDNOŚĆ POLSKI W XX WIEKU, str. 127, Instytut Geografii i Przestrzennego Zagospodarowania im. Stanisława Leszczyckiego PAN, Warszawa 2005

Geeksforgeeks.org. EDA- Exploratory Data Analysis in Python. 30 Kwiecień 2026.
<https://www.geeksforgeeks.org/data-analysis/exploratory-data-analysis-in-python/>

Główny Urząd Statystyczny. Cudzoziemcy wykonujący pracę w Polsce w maju 04.11.2025 r.
2025

Główny Urząd Statystyczny. Migracje długookresowe ludności w latach 1989-2002- na podstawie ankiety migracyjnej 2002. Warszawa. Grudzień. 2004

Główny Urząd Statystyczny. (2026) Pojęcia stosowane w statystyce publicznej. Migracje wewnętrzne.

Główny Urząd Statystyczny. Sytuacja społeczno-gospodarcza kraju w 2025 r. Warszawa Grudzień 2026

Główny Urząd Statystyczny. Sytuacja społeczno-gospodarcza Warszawa województw Nr 4/2024 Warszawa 2025

Graphpad.com Choosing a normality test.
https://www.graphpad.com/guides/prism/latest/statistics/stat_choosing_a_normality_test.htm

Górny A, Kaczmarczyk P. Uwarunkowania i mechanizmy migracji zarobkowych w świetle wybranych koncepcji teoretycznych str. 40. Listopad 2003

Help.qlik.com Ocena modeli regresji. https://help.qlik.com/pl-PL/cloud-services/Subsystems/Hub/Content/Sense_Hub/AutoML/scoring-regression.htm

Hoffmann H. Kernel PCA for Novelty Detection. Max Planck Institute for Human Cognitive and Brain Sciences, Amalienstr. 33, 80799 Munich, Germany

Hryniewicz J. Witkowski J. Potrykowska A. Migracje a sytuacja demograficzna Polski. Warszawa 2019

Jaskułowski K. GŁÓWNE TEORIE MIGRACJI MIĘDZYNARODOWYCH: PRZEGLĄD, Kr y t y k a , PERSPEKTYWY str.130 2016

Jończy R. Wpływ migracji zagranicznych na dysharmonię rozwoju województwa opolskiego (ze szczególnym uwzględnieniem rynku pracy). Opole: Instytut Śląski 2006

Kaczmarczyk P. Tyrowicz J. Współczesne procesy migracyjne w Polsce a aktywność organizacji pozarządowych w obszarach powiązanych z rynkiem pracy. Warszawa, listopad 2007

Kotarski H. Kapitał ludzki i kapitał społeczny a rozwój województwa podkarpackiego 2013

Krzanowski W.J. Principles of Multivariate Analysis: A User's Perspective Oxford University Press, 2000

Kubel-Grabau A. Gov.pl Monitorowanie stopy bezrobocia 4 marzec 2021
Gov.pl Bezrobocie w końcu 2025 roku. Przedstawiamy wstępne dane 9 styczeń 2026

Lewandowska-Gwarda K. Antczak E. Migracje wewnętrzne w polskich miastach – analiza z wykorzystaniem przestrzennej dynamicznej metody przesunięć udziałów. str 2. 2015

Lin J. Fukuyama J. A comparative analysis of machine learning models in SHAP analysis str. 2. 8 Kwiecień 2026.

Lota S. Analiza wyjaśnialności algorytmów uczenia maszynowego w zadaniach detekcji ataków w programowalnych sieciach komputerowych. Łódź 2025.

Maciążek P. Cowzdrowiu.pl GUS: Długość życia Polaków znów rośnie. "Przełamany trend pandemii" 30 lipiec 2025

Malesa P. Czynniki determinujące liczbę studentów w Polsce ze szczególnym uwzględnieniem trendów demograficznych. 2015

Mankiw N. G. Makroekonomia str. 504 2008

Netka K. Netka.gda.pl Polska się wyludnia. Staje się krajem starców. Po wprowadzeniu Programu 500+ nieco wzrosła liczba narodzin ale to za mało. Potrzebne są kolejne przedsięwzięcia, by dobrze wykształconych ludzi zatrzymać w swej ojczyźnie. Najlepiej jest w Pomorskiem, ale... 19 czerwiec 2017

Norovsambuu M. Investigating hyperparameter tuning for popular statistical learning algorithms. 2023

Okolski M. Wyzwania Demograficzne Europy i Polski. str 41. 2010

Parent E. Nextjournal. Principle component analysis and biplots in Python. 10 Wrzesień 2024.

Paweł Janukowicz, Nierówności regionalne w Polsce – Polska A i B wciąż wyraźnie podzielone, Projekt Inwestor, 6 Marzec, 2025

Płaszczycza M. Statystyka od A do Z. PCA - Założenia oraz kryteria wyboru. 2013

Praca zbiorowa pod redakcją Anny Tucholskiej. Europejskie wyzwania dla Polski i jej regionów. Ministerstwo Rozwoju Regionalnego. Warszawa 2010

PQStat Software (2023). Podręcznik Użytkownika PQStat 1.8.6. Analiza składowych głównych. Interpretacja graficzna. Sierpień 2014

Rudnicki J. Wierchowski M. Dardzińska J. Instytut Pamięci Narodowej we Wrocławiu. Ekspatriacje z Kresów Wschodnich 1944-1959. Maj 2021.

SciPy.org. Anderson. 2008
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.anderson.html>

Sihombing D. Comparison of algorithm performance, Random Forest Regression, SVR, and Gradient Boosting in predicting academic grades based on student life style. Wrzesień 2025

Simic M. Baeldung.com Gradient Boosting Trees vs. Random Forests. 28 Luty 2025.

Słomski D. Te regiony stanowią o sile polskiej gospodarki [TABELA]. Business Insider. <https://businessinsider.com.pl/gospodarka/pkb-polski-z-podzialem-na-województwa-nowe-dane-gus-tabela/bvf341s>

Skoneczny S. Softinery.com Python – regresja liniowa. <https://softinery.com/pl/blog/python-regresja-liniowa/>

Sojka E. Statystyka w praktyce. Odległość geograficzna jako determinanta migracji — na przykładzie województwa śląskiego. 2017

Statsoft.pl Regresja Wieloraka. https://www.statsoft.pl/textbook/stathome_stat.html?https%3A%2F%2Fwww.statsoft.pl%2Ftextbook%2Fstmulreg.html

Szczepaniak-Sienniak J. Relacje międzypokoleniowe we współczesnych polskich rodzinach. str. 10 2014

Waluszko F. Business Insider Rekordowa liczba cudzoziemców w ZUS. Z tych krajów przybywa ich najwięcej. 5 Luty 2026

Wątroba J. Prosto o dopasowaniu prostych, czyli analiza regresji liniowej w praktyce. StatSoft Polska. z o.o. 2011

Young N. T. Caballero M. D Predictive and explanatory models might miss informative features in educational . data 26 Marzec 2021

Zhu R. Ridge Regression and the Bias-variance Trade-off. 20 Sierpień 2024

Żróbek-Różańska A. Zysk E. Wieś i rolnictwo, NR 4 Czy rozlewające się miasto odmładza Podmiejską wieś? Studium podolsztyńskich gmin wiejskich. 2015

Żołędowski C. Wpływ pandemii COVID-19 na procesy migracji i sytuację migrantów-przypadek Polski 2022

Spis rysunków

Rysunek 1 Mapa kierunków migracji po II wojnie światowej w Polsce.	12
Rysunek 2 Tendencja migracji wewnętrznych na pobyt stały w latach 1974- 1998. .	13
Rysunek 3 Tendencja migracji w miastach na pobyt stały w latach 1988-2024. Źródło: GUS. Migracje wewnętrzne ludności na pobyt stały według województw w latach 1974-2024.	15
Rysunek 4 Tendencja migracji na wsiach na pobyt stały w latach 1988-2024. Źródło: GUS. Migracje wewnętrzne ludności na pobyt stały według województw w latach 1974-2024.	15
Rysunek 5 Wartość salda migracji w poszczególnych powiatach Polski w 2020 roku. Źródło: Zintegrowana Platforma Edukacyjna.ZPE.gov.pl <i>Kierunki i przyczyny migracji</i>	

<i>zagranicznych i wewnętrznych Polaków. Zmiany salda migracji zagranicznych i wewnętrznych Polaków i ich przyczyny.</i>	17
https://zpe.gov.pl/a/przeczytaj/DqkplBP8y	
Rysunek 6 Przeciętne miesięczne wynagrodzenia brutto 2017-2025. Źródło: GUS.	
Sytuacja społeczno-gospodarcza kraju w 2025 r. Warszawa Grudzień 2026	24
Rysunek 7 Wykres liczby studentów w Polsce. Źródło: Ministerstwo Nauki	
Szkolnictwa Wyższego (2013). Kancelaria Prezydenta RP (2013)	26
Rysunek 8 Przykładowy wykres rozrzutu dla dwóch cech. Źródło:	
https://www.statsoft.pl/textbook/stathome_stat.html?https%3A%2F%2Fwww.statsoft.pl%2Ftextbook%2Fstmulreg.html	33
Rysunek 9 Wzór liniowej regresji. Źródło: J. Wątroba, <i>Prosto o dopasowaniu prostych, czyli analiza regresji liniowej w praktyce</i> . StatSoft Polska. z o.o. 2011	33
Rysunek 10 Wzór regresji grzbietowej. Źródło: Zhu R. <i>Ridge Regression and the Bias-variance Trade-off</i> . 20 Sierpień 2024.	35
Rysunek 11 Funkcja regresji SVR. Źródło: Sihombing D. Comparison of algorithm performance, Random Forest Regression. Wrzesień 2025	36
Rysunek 12 Wzór jądra RBF. Źródło: Norovsambuu M. <i>Investigating hyperparameter tuning for popular statistical learning algorithm</i> . 10 Lipiec 2025	37
Rysunek 13 Tabela obrazująca sposób dodawania kolejnych drzew w modelu Gradient Boosting. Źródło: Simic M. Baeldung.com <i>Gradient Boosting Trees vs. Random Forests</i> . 28 Luty 2025. https://www.baeldung.com/cs/gradient-boosting-trees-vs-random-forests	38
Rysunek 14 Wzór na wariancję zmiennej losowej dla analizy PCA Źródło: Dutkowski J. <i>Eksploracyjna analiza danych. Metody rzutowania: analiza składowych głównych oraz skalowanie wielowymiarowe</i> . 22 Maj 2007	40
Rysunek 15 Wzór na pierwszą składową dla analizy PCA. Źródło: Dutkowski J. <i>Eksploracyjna analiza danych. Metody rzutowania: analiza składowych głównych oraz skalowanie wielowymiarowe</i> . 22 Maj 2007	41
Rysunek 16 Współczynnik korelacji- Ładunek czynnikowy. Źródło: A. Czopek <i>ANALIZA PORÓWNAWCZA EFEKTYWNOŚCI METOD REDUKCJI ZMIENNYCH – ANALIZA SKŁADOWYCH GŁÓWNYCH I ANALIZA CZYNNIKOWA</i> 2013	42
Rysunek 17 Wzór scentrowanej macierzy jądrowej. Źródło: Wikipedia <i>Kernel principal komponent analysis</i> . https://en.wikipedia.org/wiki/Kernel_principal_component_analysis	42
Rysunek 18 Macierz korelacji zmiennych- część 1. Źródło: Opracowanie własne	49
Rysunek 19 Macierz korelacji zmiennych- część 2. Źródło: Opracowanie własne	50
Rysunek 20 Histogramy cech- część 1. Źródło: Opracowanie własne	51
Rysunek 21 Histogramy cech- część 2. Źródło: Opracowanie własne	52
Rysunek 22 Histogramy cech- część 3. Źródło: Opracowanie własne	53
Rysunek 23 Histogramy cech- część 4. Źródło: Opracowanie własne	54
Rysunek 24 Wykres Boxplot zestandaryzowanych cech. Źródło: Opracowanie własne	56
Rysunek 25 Kod dobrania hiperparametrów z metodą GridSearch Źródło: Opracowanie własne	57
Rysunek 26 Wyniki modeli regresji przed redukcją wymiarowości. Źródło: Opracowanie własne	58
Rysunek 27 Wykres Permutation Feature Importance dla modelu Ridge regression Źródło: Opracowanie własne	59
Rysunek 28 Wykres Permutation Feature Importance dla modelu SVR Źródło: Opracowanie własne	60

Rysunek 29 Wykres Permutation Feature Importance dla modelu Random Forest Źródło: Opracowanie własne	61
Rysunek 30 Wykres Permutation Feature Importance dla modelu Gradient Boosting Źródło: Opracowanie własne	62
Rysunek 31 Kod obsługujący obliczenie wartości SHAP. Źródło: Opracowanie własne	64
Rysunek 32 Wykres SHAP Summary Plot- Ridge Regression Źródło: Opracowanie własne	65
Rysunek 33 Wykres SHAP Summary Plot- SVR (RBF) Źródło: Opracowanie własne	65
Rysunek 34 Wykres SHAP Summary Plot- Random Forest Źródło: Opracowanie własne	66
Rysunek 35 Wykres SHAP Summary Plot- Gradient Boosting Źródło: Opracowanie własne	66
Rysunek 36 Wykres piargowy i wykres skumulowanej wyjściowej wariancji. Źródło: Opracowanie własne	68
Rysunek 37 Tabela wyników regresji dla przedziału wartości k od 3 do 5. Źródło: Opracowanie własne	69
Rysunek 38 Tabela wyników regresji dla przedziału wartości k od 7 do 14. Źródło: Opracowanie własne	70
Rysunek 39 Algorytm konfiguracji porównania wyników analizy regresji dla jądrowej redukcji wymiarów Źródło: Opracowanie własne	71
Rysunek 40 Tabela najwyższych wyników regresji jądrowej dla przedziału wartości k od 7 do 14. Źródło: Opracowanie własne	72
Rysunek 41 Tabela wyników regresji jądrowej dla przedziału wartości k od 3 do 5. Źródło: Opracowanie własne	73
Rysunek 42 Tabela Wykres pokazujący zależność pomiędzy ilością składowych a jakości predykcji R^2 . Źródło: Opracowanie własne	74
Rysunek 43 Macierz ładunków czynnikowych dla czterech składowych. Źródło: Opracowanie własne	74
Rysunek 44 Kod implementujący wykres Biplot. Źródło: Opracowanie własne	76
Rysunek 45 Kierunki wektorów na wykresie Biplot. Źródło: Opracowanie własne	77
Rysunek 46 Pełny wykres Biplot. Źródło: Opracowanie własne	78